

Министерство образования Республики Беларусь
Учреждение образования
«Белорусский государственный университет информатики и радиоэлектроники»
Факультет компьютерных систем и сетей
Кафедра информатики

Машинное обучение

Лабораторные работы №№1-8

Выполнила:
магистрант специальности ИиТРПО
Евтушенко Елизавета Юрьевна
2 курс, группа 858341

Проверил:
Стержанов Максим Валерьевич

Лабораторная работа №1

Логистическая регрессия в качестве нейронной сети

В работе предлагается использовать набор данных *notMNIST*, который состоит из изображений размерностью 28×28 первых 10 букв латинского алфавита (*A* ... *J*, соответственно). Обучающая выборка содержит порядка 500 тыс. изображений, а тестовая – около 19 тыс.

Данные можно скачать по ссылке:

- https://commondatastorage.googleapis.com/books1000/notMNIST_large.tar.gz (https://commondatastorage.googleapis.com/books1000/notMNIST_large.tar.gz) (большой набор данных);
- https://commondatastorage.googleapis.com/books1000/notMNIST_small.tar.gz (https://commondatastorage.googleapis.com/books1000/notMNIST_small.tar.gz) (маленький набор данных);

Описание данных на английском языке доступно по ссылке: <http://yaroslavvb.blogspot.sg/2011/09/notmnist-dataset.html> (<http://yaroslavvb.blogspot.sg/2011/09/notmnist-dataset.html>).

Задание 1

Загрузите данные и отобразите на экране несколько из изображений с помощью языка Python.

In [0]:

```
import warnings  
  
warnings.filterwarnings('ignore')
```

In [0]:

```
SMALL_DS_URL = (  
    'https://commondatastorage.googleapis.com/books1000/notMNIST_small.tar.gz')  
LARGE_DS_URL = (  
    'https://commondatastorage.googleapis.com/books1000/notMNIST_large.tar.gz')
```

In [0]:

```
%matplotlib inline  
  
import matplotlib.pyplot as plt  
import seaborn as sns  
from matplotlib import rcParams  
  
rcParams['figure.figsize'] = 8, 6  
  
sns.set()  
sns.set_palette(sns.color_palette('hls'))
```

In [0]:

```
from urllib.request import urlretrieve
import tarfile
import os

def tar_to_dir(_tar_url, _key):
    dir_name_ = 'dataset_' + _key
    local_file_name_ = dir_name_ + '.f'

    urlretrieve(_tar_url, local_file_name_)

    with tarfile.open(local_file_name_, 'r:gz') as tar_:
        tar_.extractall(dir_name_)

    os.remove(local_file_name_)

    return dir_name_
```

In [0]:

```
def get_examples(_dataframe, _label_column_name, _data_column_name):
    n_ = _dataframe[_label_column_name].nunique()

    examples_ = _dataframe.sample(n_)[_data_column_name]

    return examples_
```

In [0]:

```
from math import ceil
import numpy as np

def print_examples(_examples):
    fig = plt.figure(figsize = (8, 4))

    height_ = 2
    width_ = ceil(_examples.count() / height_)

    for i, item_ in enumerate(_examples):

        ax = fig.add_subplot(height_, width_, i + 1)
        ax.axis('off')
        ax.imshow(item_, cmap = 'gray', interpolation = 'none')

    plt.show()
```

In [0]:

```
from imageio import imread
import pandas as pd

def image_to_array(_image):
    try:
        array_ = imread(_image)

        return True, array_
    except:
        return False, None

def get_inner_dir(_dir_path):
    return [x[0] for x in os.walk(_dir_path)][1]

def remove_duplicates(_dataframe, _data_column_name):
    return (_dataframe
            .loc[_dataframe[_data_column_name]
                  .astype(str).drop_duplicates().index])

def dir_to_dataframe(_dir_path):
    dataframes_ = []
    inner_dir_path_ = get_inner_dir(_dir_path)
    for subdir_ in sorted(os.listdir(inner_dir_path_)):
        letter_ = subdir_
        data_ = []
        files_ = os.listdir(os.path.join(inner_dir_path_, subdir_))
        for f in files_:
            file_path_ = os.path.join(inner_dir_path_, subdir_, f)
            can_read_, im = image_to_array(file_path_)

            if can_read_:
                data_.append(im)

        g = [letter_] * len(data_)
        e = np.array(data_)
        h = pd.DataFrame()
        h['data'] = data_
        h['label'] = letter_
        dataframes_.append(h)

    result_ = pd.concat(dataframes_, ignore_index = True)
    unique_ = remove_duplicates(result_, 'data')

    return unique_
```

```
In [0]:
```

```
def tar_to_dataframe(_tar_url, _key):  
    dir_name_ = tar_to_dir(_tar_url, _key)  
    inner_dir_ = get_inner_dir(dir_name_)  
    dataframe_ = dir_to_dataframe(dir_name_)  
    examples_ = get_examples(dataframe_, 'label', 'data')  
    print_examples(examples_)  
  
    return dataframe_
```

```
In [9]:
```

```
small_dataframe = tar_to_dataframe(SMALL_DS_URL, 'small')
```



```
In [10]:
```

```
large_dataframe = tar_to_dataframe(LARGE_DS_URL, 'large')
```



Задание 2

Проверьте, что классы являются сбалансированными, т.е. количество изображений, принадлежащих каждому из классов, примерно одинаково (в данной задаче 10 классов).

In [0]:

```
def print_balance(_dataframe, _label_column_name):  
    values_ = (_dataframe[_label_column_name]  
               .value_counts().sort_values(ascending = False))  
  
    print((':>10') * len(values_)).format(*values_))
```

In [12]:

```
print_balance(small_dataframe, 'label')
```

1853	1850	1850	1848	1848	1848	1847
1847	1845	1596				

In [13]:

```
print_balance(large_dataframe, 'label')
```

47226	47102	47012	46890	46771	46663	46577	4
6521	46098	41086					

Как видим, классы сбалансированы.

Задание 3

Разделите данные на три подвыборки: обучающую (200 тыс. изображений), валидационную (10 тыс. изображений) и контрольную (тестовую) (19 тыс. изображений).

In [0]:

```
def split(_dataframe, _n_train, _n_test, _n_val):  
  
    assert _dataframe.shape[0] >= _n_train + _n_test + _n_val  
  
    to_be_split_ = _dataframe.copy(deep = True)  
  
    seed_ = 666  
  
    train_ = to_be_split_.sample(n = _n_train, random_state = seed_)  
  
    to_be_split_ = to_be_split_.drop(train_.index)  
    test_ = to_be_split_.sample(n = _n_test, random_state = seed_)  
  
    val_ = (to_be_split_  
           .drop(test_.index).sample(n = _n_val, random_state = seed_))  
  
    return train_, test_, val_
```

In [15]:

```
large_dataframe.shape[0]
```

Out[15]:

```
461946
```

In [16]:

```
train, test, validation = split(large_dataframe, 200000, 10000, 19000)

print_balance(train, 'label')
print_balance(test, 'label')
print_balance(validation, 'label')
```

	20415	20350	20317	20290	20278	20191	20170	2
0124	20100	17765						
	1049	1043	1033	1029	1021	1016	995	
981	961	872						
	2014	1945	1934	1931	1912	1903	1898	
1887	1864	1712						

Видно, что удалось сохранить баланс между классами.

Задание 4

Проверьте, что данные из обучающей выборки не пересекаются с данными из валидационной и контрольной выборок. Другими словами, избавьтесь от дубликатов в обучающей выборке.

In [0]:

```
def no_duplicates(_dataframe, _data_column_name):

    original_length_ = _dataframe.shape[0]

    unique_length_ = (_dataframe[_data_column_name]
                      .astype(str).unique().shape[0])

    print(str(original_length_) + ' -- ' + str(unique_length_))

    return original_length_ == unique_length_
```

In [18]:

```
print(no_duplicates(small_dataframe, 'data'))
```

```
18232 -- 18232
True
```

In [19]:

```
print(no_duplicates(large_dataframe, 'data'))
```

```
461946 -- 461946
True
```

In [0]:

```
small_dataframe.to_pickle("./small.pkl")
large_dataframe.to_pickle("./large.pkl")
```

Дубликатов не обнаружено, так как они были удалены на шаге построения датасета из файлов.

Задание 5

Постройте простейший классификатор (например, с помощью логистической регрессии). Постройте график зависимости точности классификатора от размера обучающей выборки (50, 100, 1000, 50000). Для построения классификатора можете использовать библиотеку SkLearn (<http://scikit-learn.org>). (<http://scikit-learn.org>).

In [0]:

```
def dataframe_to_x_y(_dataframe):
    x_ = np.stack(_dataframe['data']).reshape(_dataframe.shape[0], -1)
    y_ = _dataframe['label'].to_numpy()
    return x_, y_
```

In [0]:

```
X_train, y_train = dataframe_to_x_y(train)
X_test, y_test = dataframe_to_x_y(test)
```

In [0]:

```
sizes = [50, 100, 1000, 50000]
clfs = {}
scores = {}
```

In [0]:

```
from sklearn.linear_model import LogisticRegression
for size_ in sizes:
    clf_ = (LogisticRegression(max_iter = 100)
            .fit(X_train[:size_], y_train[:size_]))
    clfs[size_] = clf_

```

In [25]:

```
print(*clfs[50000].predict(X_test[:10]), sep = '\t')
```

I C B H C G B E G I

In [26]:

```
print(*y_test[:10], sep = '\t')
```

C C B H C G B E G H

In [0]:

```
for size_ in sizes:  
    scores[size_] = clfs[size_].score(X_test, y_test)
```

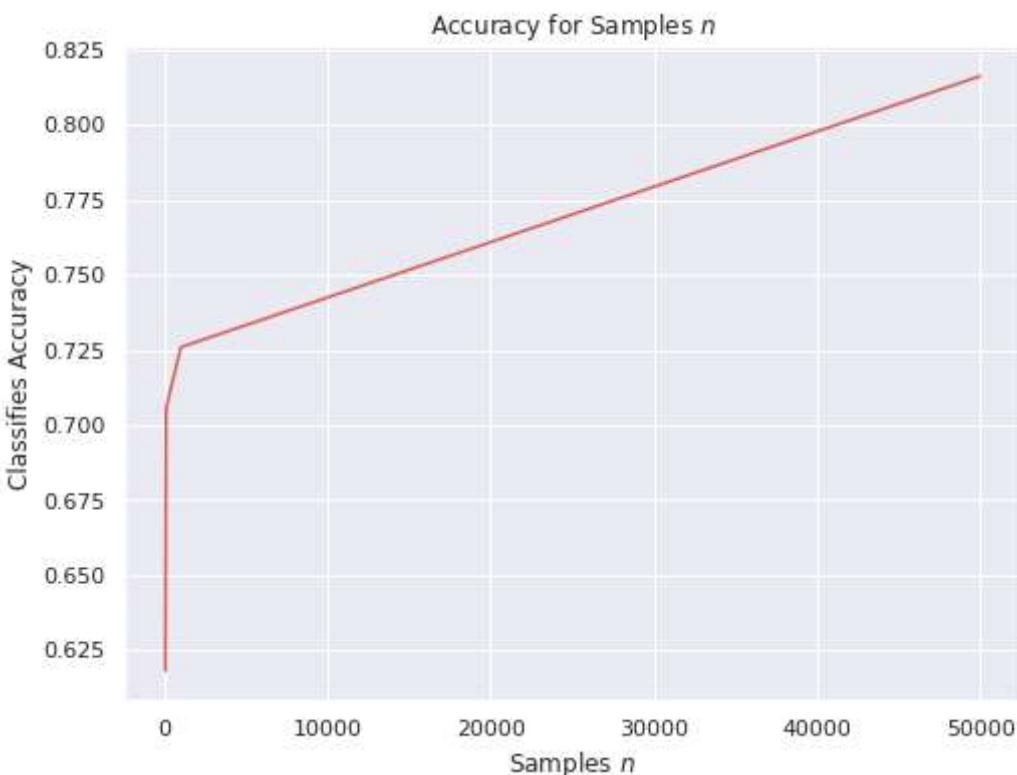
In [28]:

```
print(scores)
```

{50: 0.6183, 100: 0.7057, 1000: 0.7259, 50000: 0.8161}

In [29]:

```
sns.lineplot(sizes, [scores[s] for s in sizes])  
  
plt.xlabel('Samples $n$')  
plt.ylabel('Classifies Accuracy')  
  
plt.title('Accuracy for Samples $n$')  
  
plt.show()
```



На графике видим, что с увеличением выборки качество классификации растёт с размером выборки.

Лабораторная работа №2

Реализация глубокой нейронной сети

В работе предлагается использовать набор данных *notMNIST*, который состоит из изображений размерностью 28×28 первых 10 букв латинского алфавита (*A* ... *J*, соответственно). Обучающая выборка содержит порядка 500 тыс. изображений, а тестовая – около 19 тыс.

Данные можно скачать по ссылке:

- https://commondatastorage.googleapis.com/books1000/notMNIST_large.tar.gz (https://commondatastorage.googleapis.com/books1000/notMNIST_large.tar.gz) (большой набор данных);
- https://commondatastorage.googleapis.com/books1000/notMNIST_small.tar.gz (https://commondatastorage.googleapis.com/books1000/notMNIST_small.tar.gz) (маленький набор данных);

Описание данных на английском языке доступно по ссылке: <http://yaroslavvb.blogspot.sg/2011/09/notmnist-dataset.html> (<http://yaroslavvb.blogspot.sg/2011/09/notmnist-dataset.html>).

Задание 1

Реализуйте полносвязную нейронную сеть с помощью библиотеки *TensorFlow*. В качестве алгоритма оптимизации можно использовать, например, стохастический градиент (*Stochastic Gradient Descent*, *SGD*). Определите количество скрытых слоев от 1 до 5, количество нейронов в каждом из слоев до нескольких сотен, а также их функции активации (кусочно-линейная, сигмоидная, гиперболический тангенс и т.д.).

Загрузим файл с датасетом, обработанным в лабораторной работе №1.

In [0]:

```
import warnings  
  
warnings.filterwarnings('ignore')
```

In [2]:

```
from google.colab import drive  
  
drive.mount('/content/drive', force_remount = True)
```

Mounted at /content/drive

In [0]:

```
BASE_DIR = '/content/drive/My Drive/Colab Files/mo-2'

import sys
sys.path.append(BASE_DIR)

import os
os.chdir(BASE_DIR)
```

In [0]:

```
import pandas as pd

dataframe = pd.read_pickle("./large.pkl")
```

In [5]:

```
dataframe['data'].shape
```

Out[5]:

```
(461946,)
```

In [0]:

```
! pip install tensorflow-gpu --pre --quiet
```

In [0]:

```
import tensorflow as tf
```

In [0]:

```
import numpy as np
```

In [0]:

```
dataframe_test = dataframe.sample(frac = 0.1)
dataframe = dataframe.drop(dataframe_test.index)
```

In [10]:

```
x = np.asarray(list(dataframe['data']))[..., np.newaxis]
x = tf.keras.utils.normalize(x, axis = 1)
x.shape
```

Out[10]:

```
(415751, 28, 28, 1)
```

In [11]:

```
x_test = np.asarray(list(dataframe_test['data']))[..., np.newaxis]
x_test = tf.keras.utils.normalize(x_test, axis = 1)
x_test.shape
```

Out[11]:

(46195, 28, 28, 1)

In [0]:

```
IMAGE_DIM_0, IMAGE_DIM_1 = x.shape[1], x.shape[2]
```

In [13]:

```
from tensorflow.keras.utils import to_categorical
y = (to_categorical(dataframe['label']
                     .astype('category').cat.codes.astype('int32')))

y.shape
```

Out[13]:

(415751, 10)

In [14]:

```
y_test = (to_categorical(dataframe_test['label']
                           .astype('category').cat.codes.astype('int32')))

y_test.shape
```

Out[14]:

(46195, 10)

In [0]:

```
LAYER_WIDTH = 5000
```

In [0]:

```
CLASSES_N = y.shape[1]
```

In [0]:

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense, Reshape

model = tf.keras.Sequential()

model.add(Reshape((IMAGE_DIM_0 * IMAGE_DIM_1,),
                  input_shape = (IMAGE_DIM_0, IMAGE_DIM_1, 1)))
model.add(Dense(LAYER_WIDTH, activation = 'relu'))
model.add(Dense(LAYER_WIDTH, activation = 'sigmoid'))
model.add(Dense(LAYER_WIDTH, activation = 'tanh'))
model.add(Dense(LAYER_WIDTH, activation = 'elu'))
model.add(Dense(LAYER_WIDTH, activation = 'softmax'))
model.add(Dense(CLASSES_N))
```

In [0]:

```
def cat_cross_from_logits(y_true, y_pred):
    return tf.keras.losses.categorical_crossentropy(
        y_true, y_pred, from_logits = True)

model.compile(optimizer = 'sgd',
              loss = cat_cross_from_logits,
              metrics = ['categorical_accuracy'])
```

In [19]:

```
model.summary()
```

Model: "sequential"

Layer (type)	Output Shape	Param #
=====		
reshape (Reshape)	(None, 784)	0
dense (Dense)	(None, 5000)	3925000
dense_1 (Dense)	(None, 5000)	25005000
dense_2 (Dense)	(None, 5000)	25005000
dense_3 (Dense)	(None, 5000)	25005000
dense_4 (Dense)	(None, 5000)	25005000
dense_5 (Dense)	(None, 10)	50010
=====		
Total params: 103,995,010		
Trainable params: 103,995,010		
Non-trainable params: 0		

In [0]:

```
VAL_SPLIT_RATE = 0.1
```

In [0]:

```
EPOCHS_N = 10
```

In [0]:

```
history = model.fit(x = x, y = y, epochs = EPOCHS_N,
                      validation_split = VAL_SPLIT_RATE, verbose = 0)
```

In [0]:

```
%matplotlib inline

import matplotlib.pyplot as plt
import seaborn as sns
from matplotlib import rcParams

rcParams['figure.figsize'] = 8, 6

sns.set()
sns.set_palette(sns.color_palette('hls'))

def plot_accuracy(_history,
                  _train_acc_name = 'accuracy',
                  _val_acc_name = 'val_accuracy'):

    plt.plot(_history.history[_train_acc_name])
    plt.plot(_history.history[_val_acc_name])

    plt.title('Model accuracy')

    plt.ylabel('Accuracy')
    plt.xlabel('Epoch')

    plt.legend(['Train', 'Validation'], loc = 'right')

    plt.show()

def plot_loss(_history):

    plt.plot(_history.history['loss'])
    plt.plot(_history.history['val_loss'])

    plt.title('Model loss')

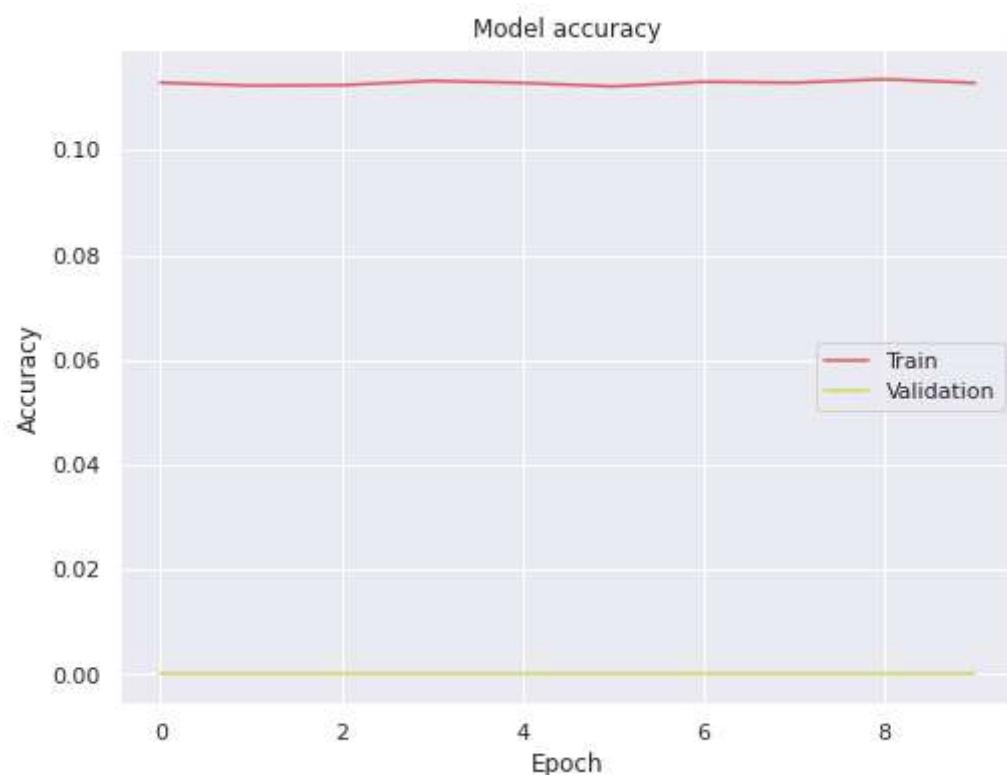
    plt.ylabel('Loss')
    plt.xlabel('Epoch')

    plt.legend(['Train', 'Validation'], loc = 'right')

    plt.show()
```

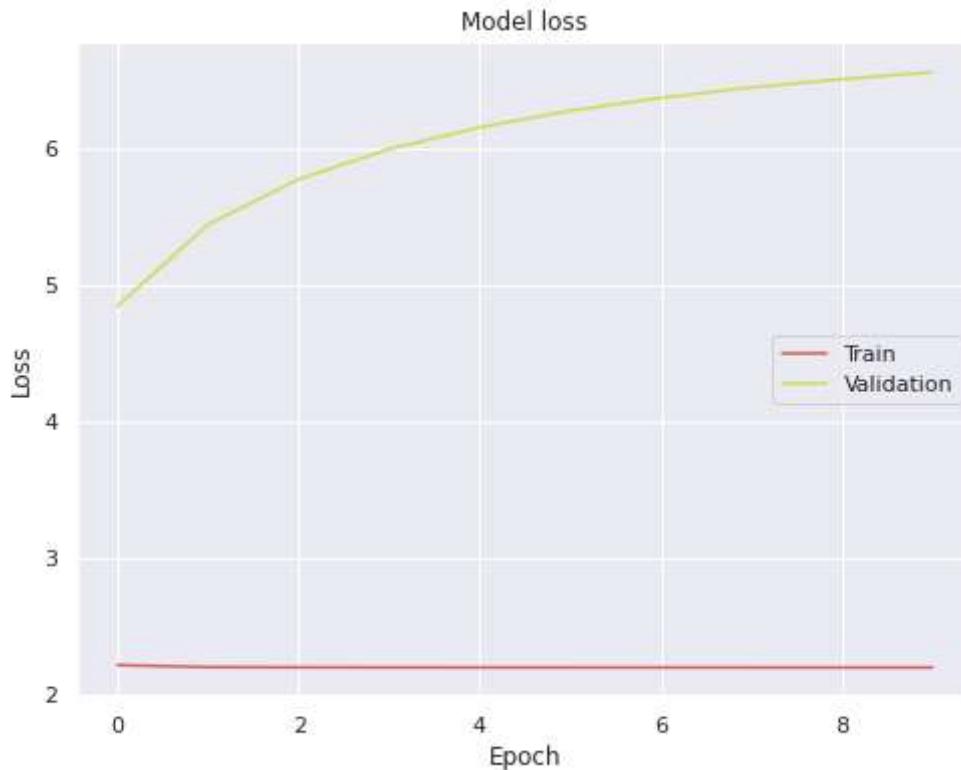
In [24]:

```
plot_accuracy(history, 'categorical_accuracy', 'val_categorical_accuracy')
```



In [25]:

```
plot_loss(history)
```



In [26]:

```
results = model.evaluate(x_test, y_test)  
print('Test loss, test accuracy:', results)
```

```
1444/1444 [=====] - 5s 3ms/step - loss: 2.6277 - categorical_accuracy: 0.1022  
Test loss, test accuracy: [2.627650260925293, 0.10221885144710541]
```

Задание 2

Как улучшилась точность классификатора по сравнению с логистической регрессией?

Стало хуже — на тестовой выборке точность составила 10%. Похоже, что данная модель совершенно не подходит для решения этой задачи.

Задание 3

Используйте регуляризацию и метод сброса нейронов (*dropout*) для борьбы с переобучением. Как улучшилось качество классификации?

In [0]:

```
REG_RATE = 0.001
```

In [0]:

```
from tensorflow.keras.regularizers import l2  
  
l2_reg = l2(REG_RATE)
```

In [0]:

```
DROPOUT_RATE = 0.2
```

In [0]:

```
from tensorflow.keras.layers import Dropout  
  
dropout_layer = Dropout(DROPOUT_RATE)
```

In [0]:

```
model_2 = tf.keras.Sequential()  
  
model_2.add(Reshape((IMAGE_DIM_0 * IMAGE_DIM_1,),  
                    input_shape = (IMAGE_DIM_0, IMAGE_DIM_1, 1)))  
model_2.add(Dense(LAYER_WIDTH, activation = 'relu',  
                 kernel_regularizer = l2_reg))  
model_2.add(dropout_layer)  
model_2.add(Dense(LAYER_WIDTH, activation = 'sigmoid',  
                 kernel_regularizer = l2_reg))  
model_2.add(dropout_layer)  
model_2.add(Dense(LAYER_WIDTH, activation = 'tanh',  
                 kernel_regularizer = l2_reg))  
model_2.add(dropout_layer)  
model_2.add(Dense(LAYER_WIDTH, activation = 'sigmoid',  
                 kernel_regularizer = l2_reg))  
model_2.add(dropout_layer)  
model_2.add(Dense(LAYER_WIDTH, activation = 'relu',  
                 kernel_regularizer = l2_reg))  
model_2.add(dropout_layer)  
model_2.add(Dense(CLASSES_N))
```

In [0]:

```
model_2.compile(optimizer = 'sgd',  
                 loss = cat_crossentropy_from_logits,  
                 metrics = ['categorical_accuracy'])
```

In [33]:

```
model_2.summary()
```

Model: "sequential_1"

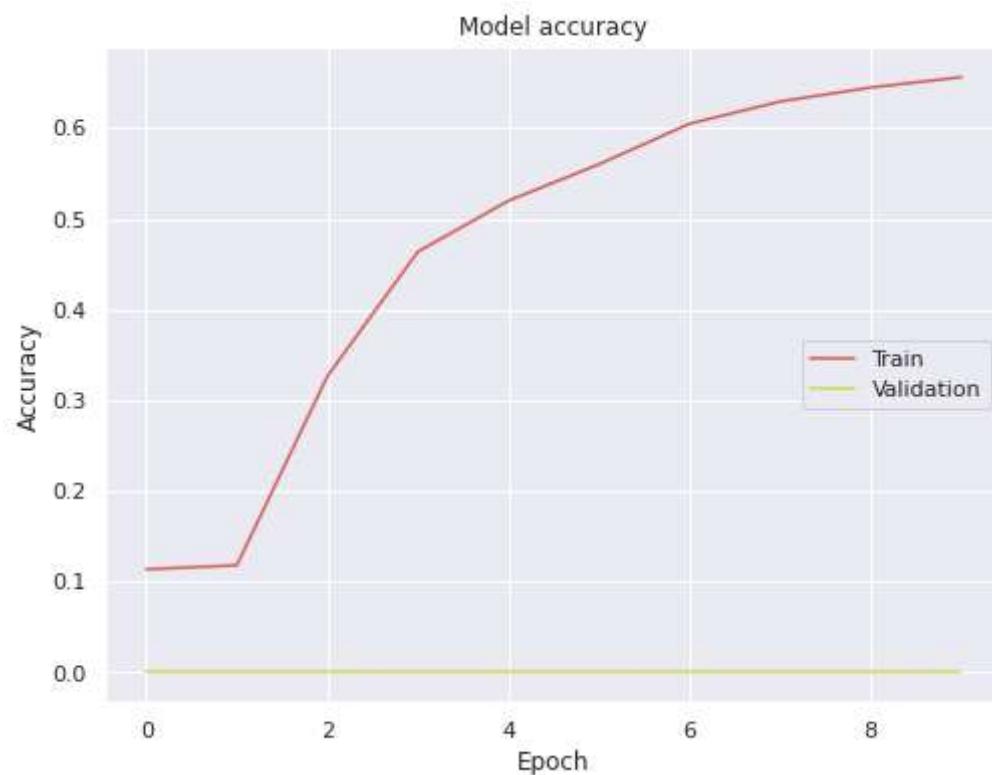
Layer (type)	Output Shape	Param #
=====		
reshape_1 (Reshape)	(None, 784)	0
dense_6 (Dense)	(None, 5000)	3925000
dropout (Dropout)	(None, 5000)	0
dense_7 (Dense)	(None, 5000)	25005000
dense_8 (Dense)	(None, 5000)	25005000
dense_9 (Dense)	(None, 5000)	25005000
dense_10 (Dense)	(None, 5000)	25005000
dense_11 (Dense)	(None, 10)	50010
=====		
Total params:	103,995,010	
Trainable params:	103,995,010	
Non-trainable params:	0	

In [0]:

```
history_2 = model_2.fit(x = x, y = y, epochs = EPOCHS_N,
                         validation_split = VAL_SPLIT_RATE, verbose = 0)
```

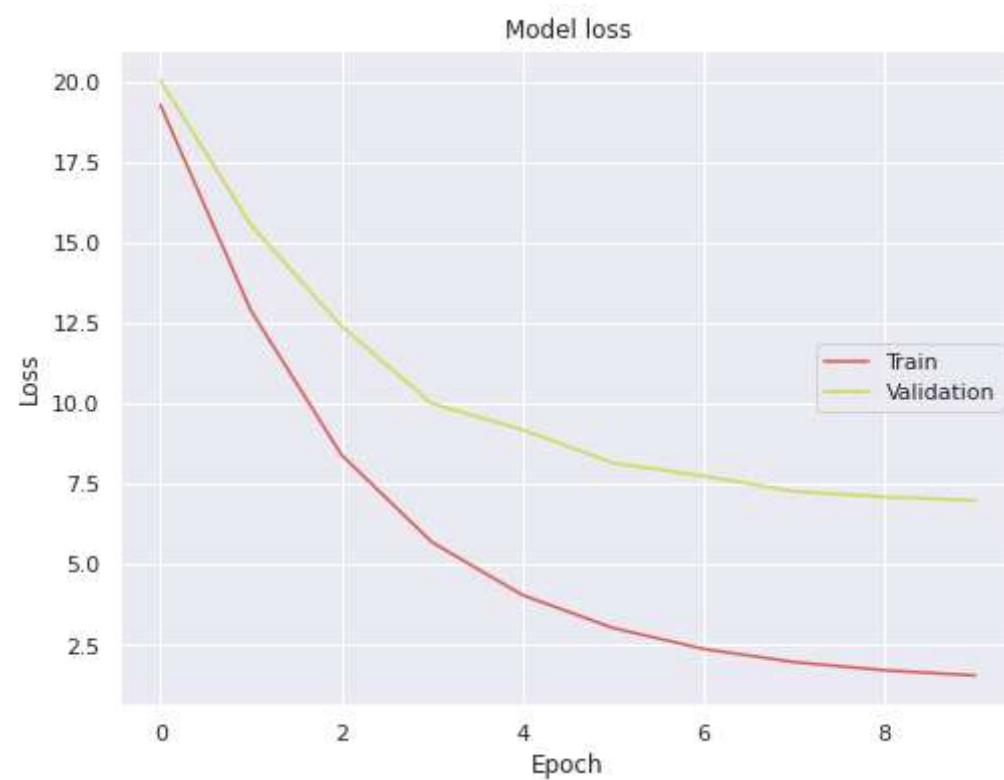
In [35]:

```
plot_accuracy(history_2, 'categorical_accuracy', 'val_categorical_accuracy')
```



In [36]:

```
plot_loss(history_2)
```



In [37]:

```
results_2 = model_2.evaluate(x_test, y_test)

print('Test loss, test accuracy:', results_2)
```

```
1444/1444 [=====] - 8s 6ms/step - loss: 1.9703 - categorical_accuracy: 0.6346
Test loss, test accuracy: [1.9703369140625, 0.634570837020874]
```

Регуляризация и сброс нейронов значительно помогли — модель показывает 63% точности на тестовой выборке.

Задание 4

Воспользуйтесь динамически изменяемой скоростью обучения (*learning rate*). Наилучшая точность, достигнутая с помощью данной модели составляет 97.1%. Какую точность демонстрирует Ваша реализованная модель?

In [0]:

```
from tensorflow.keras.optimizers import SGD

dyn_lr_sgd = SGD(lr = 0.01, momentum = 0.9)

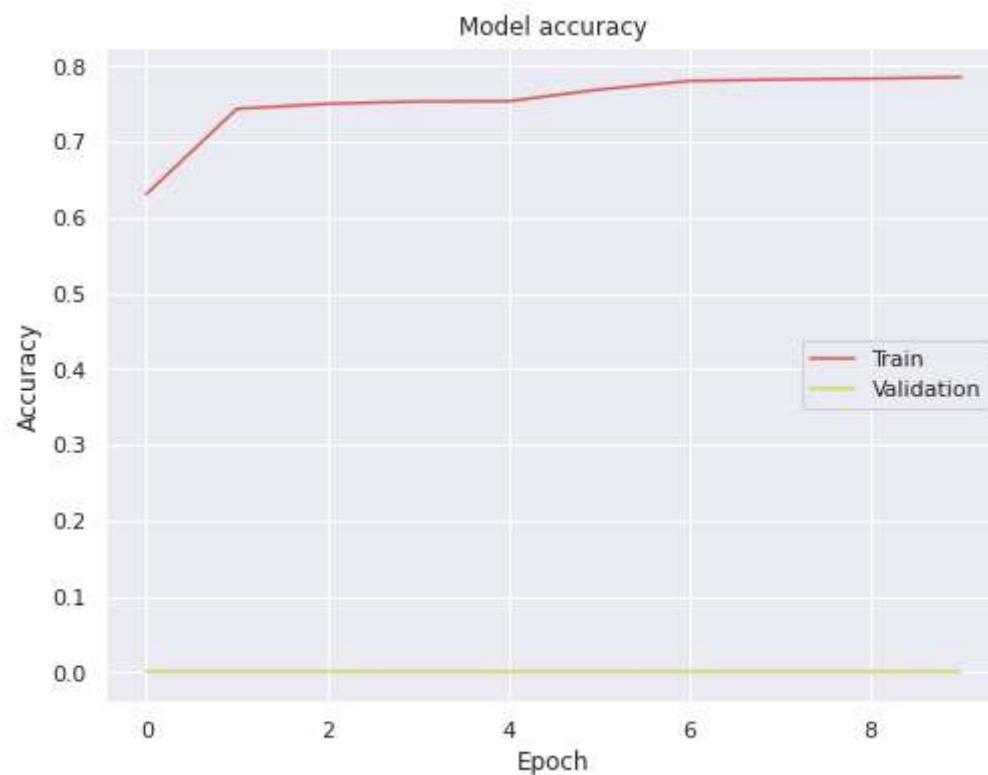
model_2.compile(optimizer = dyn_lr_sgd,
                 loss = cat_crossentropy,
                 metrics = ['categorical_accuracy'])
```

In [0]:

```
history_3 = model_2.fit(x = x, y = y, epochs = EPOCHS_N,
                        validation_split = VAL_SPLIT_RATE, verbose = 0)
```

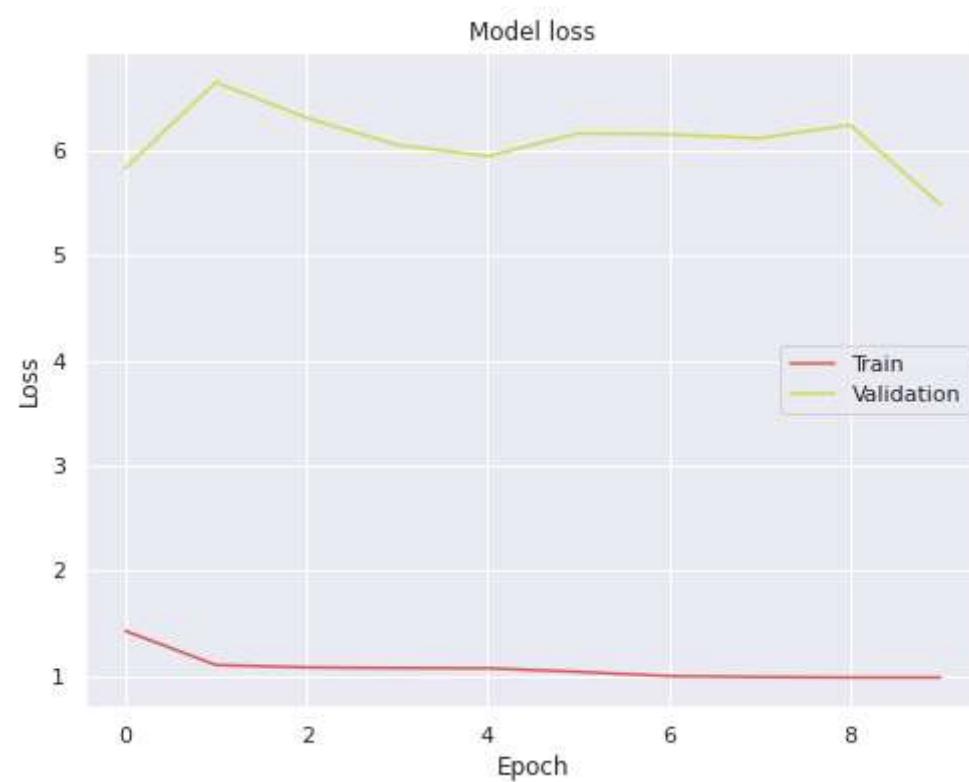
In [40]:

```
plot_accuracy(history_3, 'categorical_accuracy', 'val_categorical_accuracy')
```



In [41]:

```
plot_loss(history_3)
```



In [42]:

```
results_3 = model_2.evaluate(x_test, y_test)
print('Test loss, test accuracy:', results_3)
```

```
1444/1444 [=====] - 8s 6ms/step - loss: 1.5546 - categorical_accuracy: 0.6496
Test loss, test accuracy: [1.5545647144317627, 0.6495941281318665]
```

Динамически изменяемая скорость обучения совсем немного улучшила результат — 64% на тестовой выборке.

Можно сделать вывод, что модель с полносвязными слоями может использоваться для решения задачи распознавания изображений, однако она очевидно не является наилучшей.

Лабораторная работа №3

Реализация сверточной нейронной сети

В работе предлагается использовать набор данных *notMNIST*, который состоит из изображений размерностью 28×28 первых 10 букв латинского алфавита (*A* ... *J*, соответственно). Обучающая выборка содержит порядка 500 тыс. изображений, а тестовая – около 19 тыс.

Данные можно скачать по ссылке:

- https://commondatastorage.googleapis.com/books1000/notMNIST_large.tar.gz
(https://commondatastorage.googleapis.com/books1000/notMNIST_large.tar.gz) (большой набор данных);
- https://commondatastorage.googleapis.com/books1000/notMNIST_small.tar.gz
(https://commondatastorage.googleapis.com/books1000/notMNIST_small.tar.gz) (маленький набор данных);

Описание данных на английском языке доступно по ссылке: <http://yaroslavvb.blogspot.sg/2011/09/notmnist-dataset.html> (<http://yaroslavvb.blogspot.sg/2011/09/notmnist-dataset.html>).

Задание 1

Реализуйте нейронную сеть с двумя сверточными слоями, и одним полно связанным с нейронами с кусочно-линейной функцией активации. Какова точность построенной модели?

Загрузим файл с датасетом, обработанным в лабораторной работе №1.

In [0]:

```
import warnings  
  
warnings.filterwarnings('ignore')
```

In [2]:

```
from google.colab import drive  
  
drive.mount('/content/drive', force_remount = True)
```

Mounted at /content/drive

In [0]:

```
BASE_DIR = '/content/drive/My Drive/Colab Files/mo-2'

import sys
sys.path.append(BASE_DIR)

import os
os.chdir(BASE_DIR)
```

In [0]:

```
import pandas as pd

dataframe = pd.read_pickle("./large.pkl")
```

In [0]:

```
! pip install tensorflow-gpu --pre --quiet
```

In [0]:

```
import tensorflow as tf
```

In [0]:

```
# To fix memory leak: https://github.com/tensorflow/tensorflow/issues/33009

tf.compat.v1.disable_eager_execution()
```

In [0]:

```
import numpy as np
```

In [0]:

```
dataframe_test = dataframe.sample(frac = 0.1)

dataframe = dataframe.drop(dataframe_test.index)
```

In [10]:

```
x = np.asarray(list(dataframe['data']))[..., np.newaxis]
x = tf.keras.utils.normalize(x, axis = 1)
x.shape
```

Out[10]:

(415751, 28, 28, 1)

In [11]:

```
x_test = np.asarray(list(dataframe_test['data']))[..., np.newaxis]
x_test = tf.keras.utils.normalize(x_test, axis = 1)
x_test.shape
```

Out[11]:

```
(46195, 28, 28, 1)
```

In [0]:

```
%matplotlib inline

import matplotlib.pyplot as plt
import seaborn as sns
from matplotlib import rcParams

rcParams['figure.figsize'] = 8, 6

sns.set()
sns.set_palette(sns.color_palette('hls'))

def plot_accuracy(_history,
                  _train_acc_name = 'accuracy',
                  _val_acc_name = 'val_accuracy'):

    plt.plot(_history.history[_train_acc_name])
    plt.plot(_history.history[_val_acc_name])

    plt.title('Model accuracy')

    plt.ylabel('Accuracy')
    plt.xlabel('Epoch')

    plt.legend(['Train', 'Validation'], loc = 'right')

    plt.show()

def plot_loss(_history):

    plt.plot(_history.history['loss'])
    plt.plot(_history.history['val_loss'])

    plt.title('Model loss')

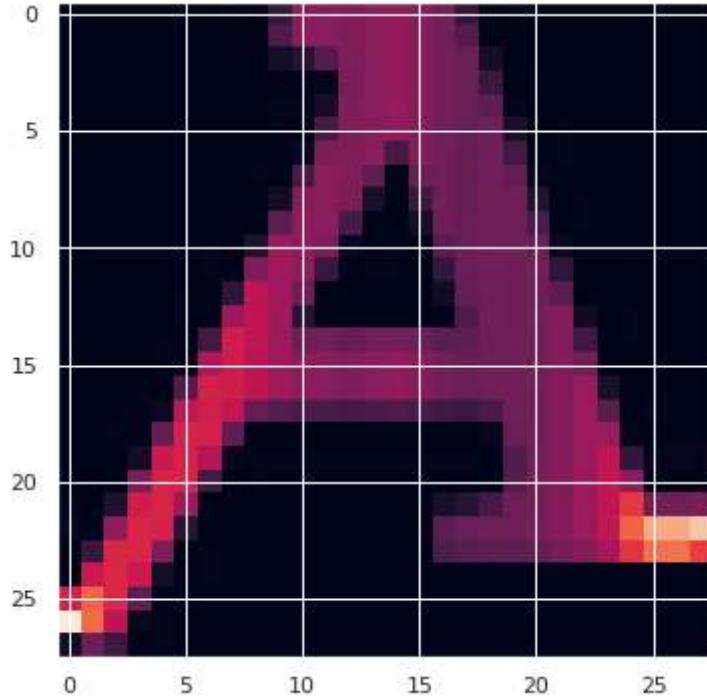
    plt.ylabel('Loss')
    plt.xlabel('Epoch')

    plt.legend(['Train', 'Validation'], loc = 'right')

    plt.show()
```

In [13]:

```
plt.imshow(x[0].squeeze())  
plt.show()
```



In [0]:

```
IMAGE_DIM_0, IMAGE_DIM_1 = x.shape[1], x.shape[2]
```

In [15]:

```
from tensorflow.keras.utils import to_categorical  
  
y = to_categorical(dataframe['label']  
                    .astype('category').cat.codes.astype('int32'))  
  
y.shape
```

Out[15]:

```
(415751, 10)
```

In [16]:

```
y_test = to_categorical(dataframe_test['label']
                        .astype('category').cat.codes.astype('int32'))  
  
y_test.shape
```

Out[16]:

```
(46195, 10)
```

In [0]:

```
CLASSES_N = y.shape[1]
```

In [0]:

```
DENSE_LAYER_WIDTH = 5000
```

In [19]:

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Conv2D, Dense, Flatten  
  
model = tf.keras.Sequential()  
  
model.add(Conv2D(16, 3, padding = 'same', activation = 'relu',
                 input_shape = (IMAGE_DIM_0, IMAGE_DIM_1, 1)))
model.add(Conv2D(32, 3, padding = 'same', activation = 'relu'))
model.add(Flatten())
model.add(Dense(DENSE_LAYER_WIDTH, activation = 'relu'))
model.add(Dense(CLASSES_N))
```

WARNING:tensorflow:From /usr/local/lib/python3.6/dist-packages/tensorflow/python/ops/resource_variable_ops.py:1666: calling BaseResourceVariable.__init__(from tensorflow.python.ops.resource_variable_ops) with constraint is deprecated and will be removed in a future version.

Instructions for updating:

If using Keras pass *_constraint arguments to layers.

In [0]:

```
def cat_cross_from_logits(y_true, y_pred):
    return tf.keras.losses.categorical_crossentropy(
        y_true, y_pred, from_logits = True)  
  
model.compile(optimizer = 'sgd',
                 loss = cat_cross_from_logits,
                 metrics = ['categorical_accuracy'])
```

In [21]:

```
model.summary()
```

Model: "sequential"

Layer (type)	Output Shape	Param #
=====		
conv2d (Conv2D)	(None, 28, 28, 16)	160
conv2d_1 (Conv2D)	(None, 28, 28, 32)	4640
flatten (Flatten)	(None, 25088)	0
dense (Dense)	(None, 5000)	125445000
dense_1 (Dense)	(None, 10)	50010
=====		
Total params:	125,499,810	
Trainable params:	125,499,810	
Non-trainable params:	0	

In [0]:

```
VAL_SPLIT_RATE = 0.1
```

In [0]:

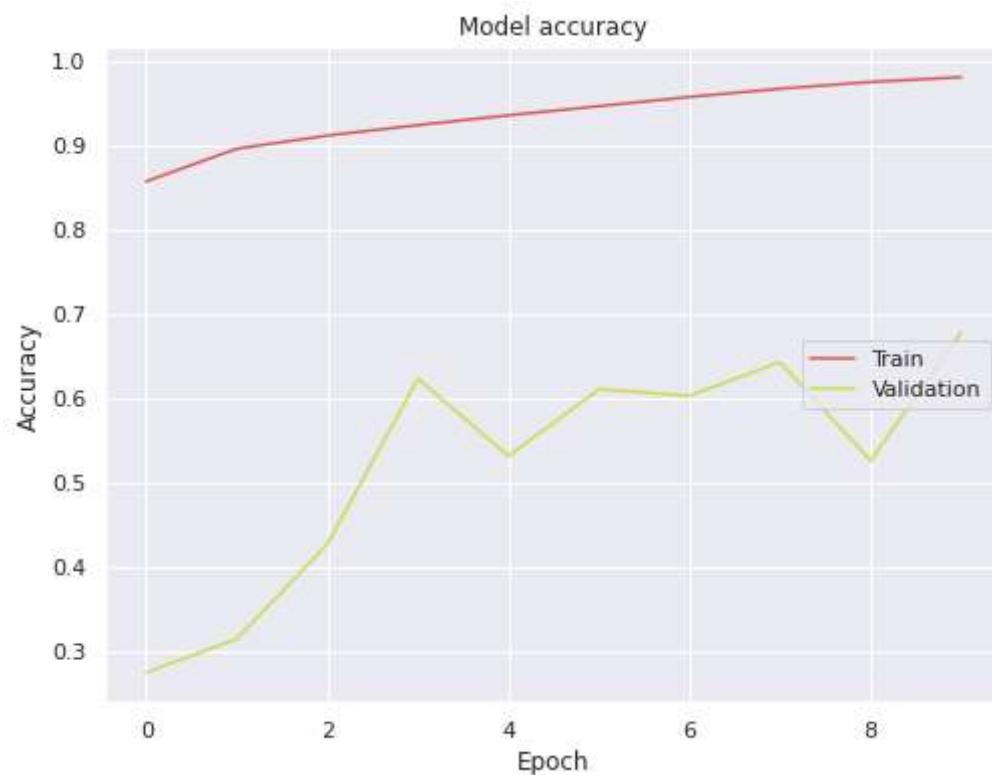
```
EPOCHS_N = 10
```

In [0]:

```
history = model.fit(x = x, y = y, epochs = EPOCHS_N,
                      validation_split = VAL_SPLIT_RATE, verbose = 0)
```

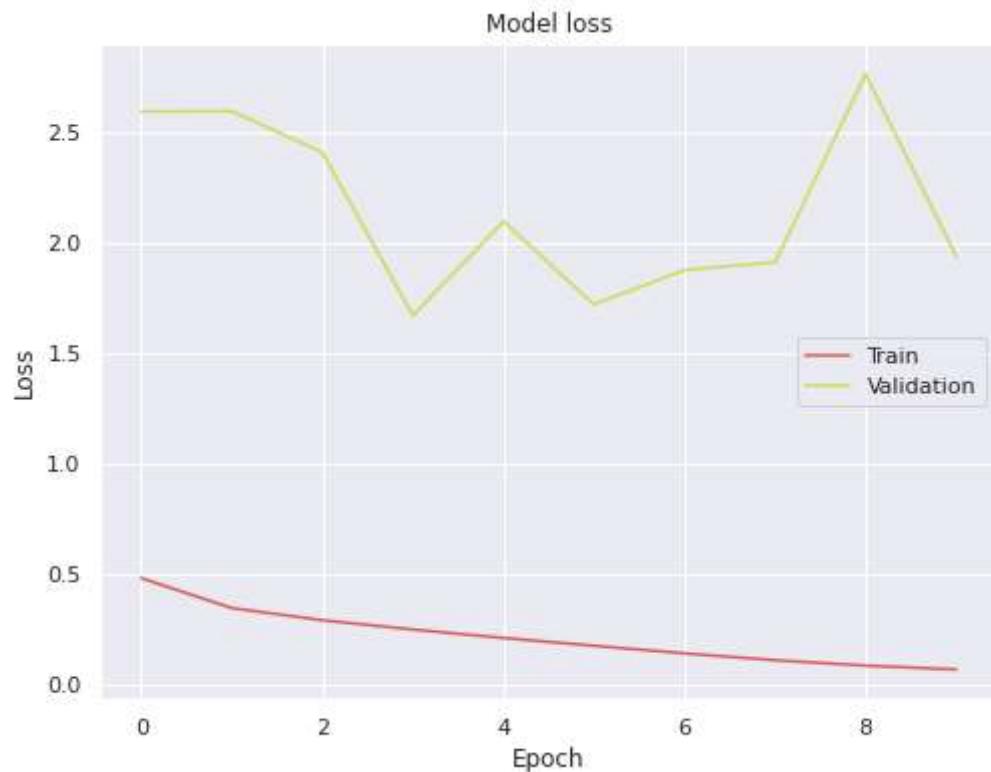
In [25]:

```
plot_accuracy(history, 'categorical_accuracy', 'val_categorical_accuracy')
```



In [26]:

```
plot_loss(history)
```



In [27]:

```
results = model.evaluate(x_test, y_test)  
print('Test loss, test accuracy:', results)
```

Test loss, test accuracy: [0.47965525410249255, 0.9042104]

Точность построенной модели на тестовой выборке составила 90%.

Задание 2

Замените один из сверточных слоев на слой, реализующий операцию пулинга (*Pooling*) с функцией максимума или среднего. Как это повлияло на точность классификатора?

In [0]:

```
from tensorflow.keras.layers import MaxPooling2D

model_2 = tf.keras.Sequential()

model_2.add(Conv2D(16, 3, padding = 'same', activation = 'relu',
                  input_shape = (IMAGE_DIM_0, IMAGE_DIM_1, 1)))
model_2.add(MaxPooling2D())
model_2.add(Flatten())
model_2.add(Dense(DENSE_LAYER_WIDTH, activation = 'relu'))
model_2.add(Dense(CLASSES_N))
```

In [0]:

```
model_2.compile(optimizer = 'sgd',
                 loss = cat_crossentropy,
                 metrics = ['categorical_accuracy'])
```

In [30]:

```
model_2.summary()
```

Model: "sequential_1"

Layer (type)	Output Shape	Param #
conv2d_2 (Conv2D)	(None, 28, 28, 16)	160
max_pooling2d (MaxPooling2D)	(None, 14, 14, 16)	0
flatten_1 (Flatten)	(None, 3136)	0
dense_2 (Dense)	(None, 5000)	15685000
dense_3 (Dense)	(None, 10)	50010

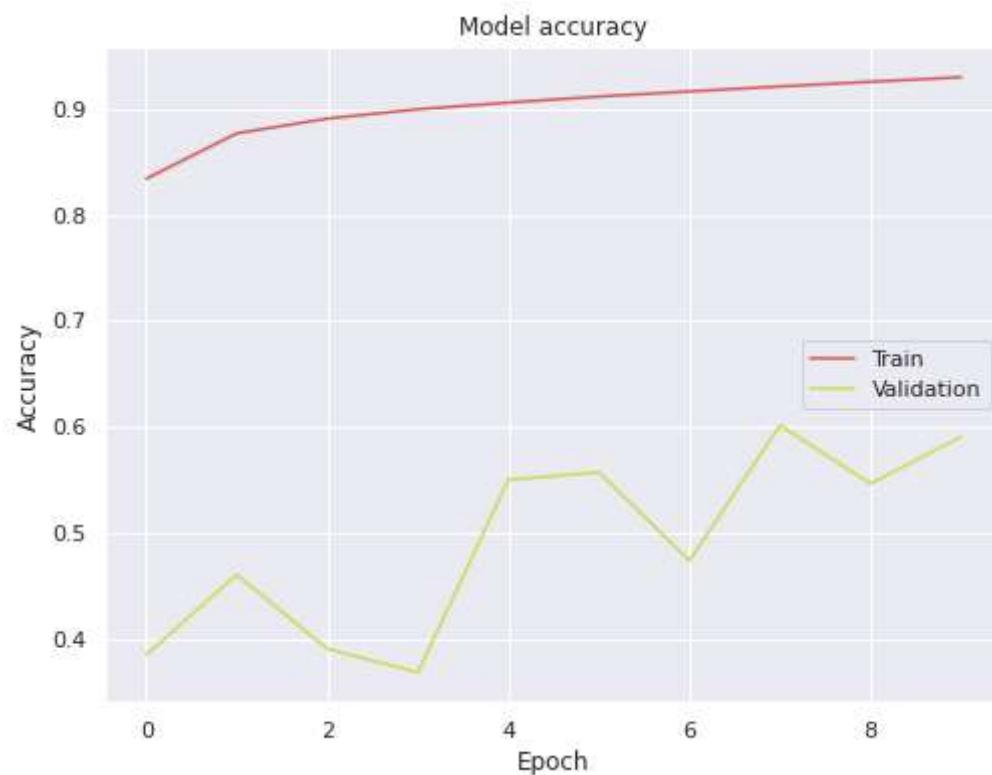
Total params: 15,735,170
Trainable params: 15,735,170
Non-trainable params: 0

In [0]:

```
history_2 = model_2.fit(x = x, y = y, epochs = EPOCHS_N,
                         validation_split = VAL_SPLIT_RATE, verbose = 0)
```

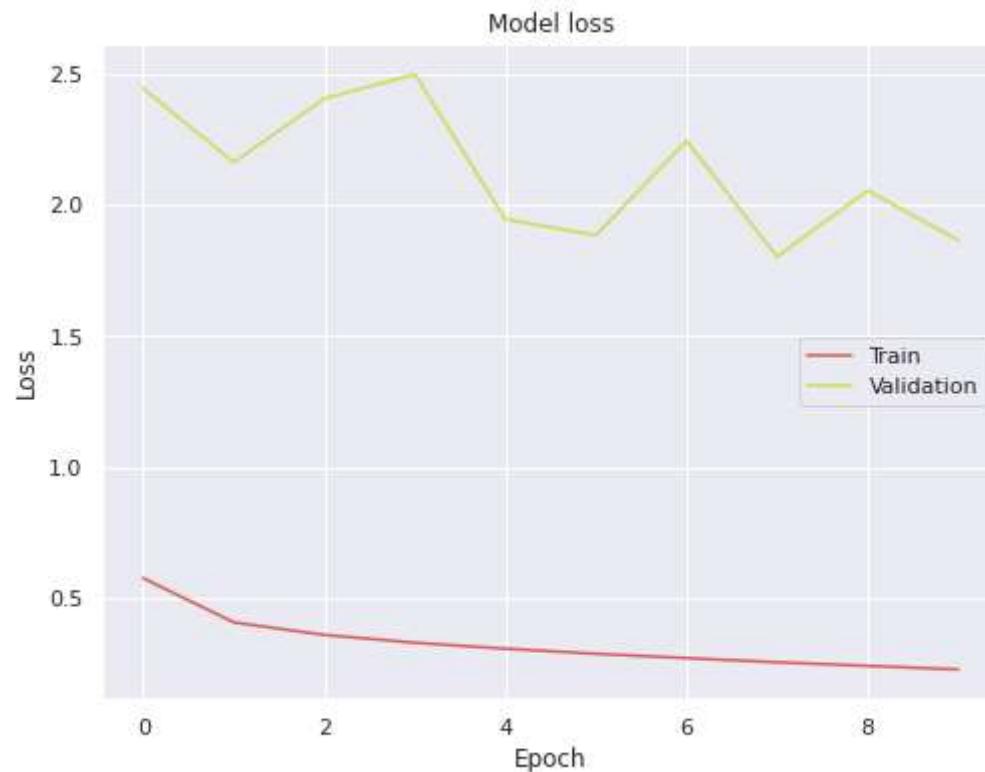
In [32]:

```
plot_accuracy(history_2, 'categorical_accuracy', 'val_categorical_accuracy')
```



In [33]:

```
plot_loss(history_2)
```



In [34]:

```
results_2 = model_2.evaluate(x_test, y_test)  
print('Test loss, test accuracy:', results_2)
```

Test loss, test accuracy: [0.44243563031696087, 0.88264966]

Замена свёрточного слоя на операцию пулинга немножко снизила точность на тестовой выборке — до 88%.

Задание 3

Реализуйте классическую архитектуру сверточных сетей LeNet-5 (<http://yann.lecun.com/exdb/lenet/>) (<http://yann.lecun.com/exdb/lenet/>).

In [0]:

```
from tensorflow.keras.layers import AveragePooling2D

model_3 = tf.keras.Sequential()

model_3.add(Conv2D(6, kernel_size = (5, 5), strides = (1, 1),
                  activation = 'tanh', padding = 'same',
                  input_shape = (IMAGE_DIM_0, IMAGE_DIM_1, 1)))
model_3.add(AveragePooling2D(pool_size = (2, 2), strides = (2, 2),
                            padding = 'valid'))
model_3.add(Conv2D(16, kernel_size = (5, 5), strides = (1, 1),
                   activation = 'tanh', padding = 'valid'))
model_3.add(AveragePooling2D(pool_size = (2, 2), strides = (2, 2),
                            padding = 'valid'))
model_3.add(Flatten())
model_3.add(Dense(120, activation = 'tanh'))
model_3.add(Dense(84, activation = 'tanh'))
model_3.add(Dense(CLASSES_N, activation = 'softmax'))
```

In [0]:

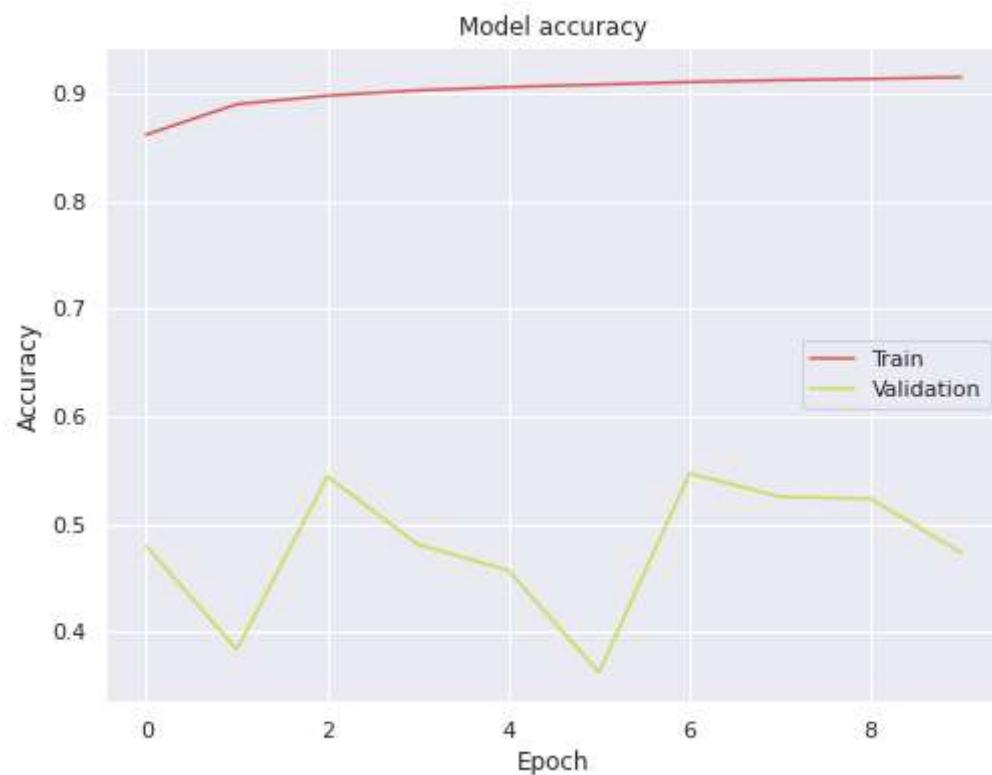
```
model_3.compile(optimizer = 'adam',
                 loss = 'categorical_crossentropy',
                 metrics = ['categorical_accuracy'])
```

In [0]:

```
history_3 = model_3.fit(x = x, y = y, epochs = EPOCHS_N,
                         validation_split = VAL_SPLIT_RATE, verbose = 0)
```

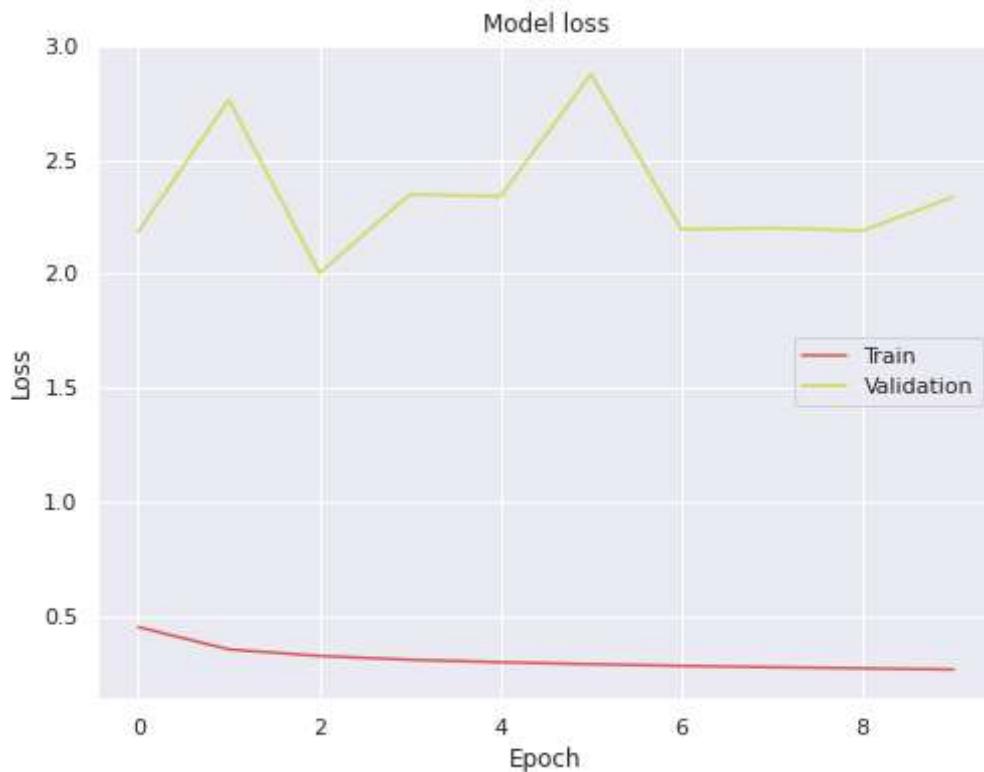
In [38]:

```
plot_accuracy(history_3, 'categorical_accuracy', 'val_categorical_accuracy')
```



In [39]:

```
plot_loss(history_3)
```



In [40]:

```
results_3 = model_3.evaluate(x_test, y_test)
```

```
print('Test loss, test accuracy:', results_3)
```

```
Test loss, test accuracy: [0.49397167890073673, 0.8667388]
```

Удивительно, но *LeNet-5* показала результат хуже, чем первая и вторая — 86% на тестовой выборке. Объяснить это можно различиями в размерностях слоёв.

Задание 4

Сравните максимальные точности моделей, построенных в лабораторных работах 1-3. Как можно объяснить полученные различия?

Результаты на валидационной выборке:

- логистическая регрессия — 81%;

- модель с только полносвязными слоями — 10%;
 - с регуляризацией и сбросом нейронов — 63%;
 - с адаптивным шагом — 64%;
- модель с двумя свёрточными слоями и одним полносвязным — 90%;
- модель с одним свёрточным слоем, операцией пулинга и одним полносвязным — 88%;
- *LeNet-5* — два свёрточных слоя, две операции пулинга, два полносвязных слоя — 86%.

Объяснение превосходства свёрточных сетей над полносвязными — такая архитектура лучше сочетается с природой изображений.

Лабораторная работа №4

Реализация приложения по распознаванию номеров домов

Набор изображений из *Google Street View* с изображениями номеров домов, содержащий 10 классов, соответствующих цифрам от 0 до 9.

- 73257 изображений цифр в обучающей выборке;
- 26032 изображения цифр в тестовой выборке;
- 531131 изображения, которые можно использовать как дополнение к обучающей выборке;
- В двух форматах:
 - Оригинальные изображения с выделенными цифрами;
 - Изображения размером 32×32, содержащие одну цифру;
- Данные первого формата можно скачать по ссылкам:
 - <http://ufldl.stanford.edu/housenumbers/train.tar.gz> (<http://ufldl.stanford.edu/housenumbers/train.tar.gz>) (обучающая выборка);
 - <http://ufldl.stanford.edu/housenumbers/test.tar.gz> (<http://ufldl.stanford.edu/housenumbers/test.tar.gz>) (тестовая выборка);
 - <http://ufldl.stanford.edu/housenumbers/extrtar.gz> (<http://ufldl.stanford.edu/housenumbers/extrtar.gz>) (дополнительные данные);
- Данные второго формата можно скачать по ссылкам:
 - http://ufldl.stanford.edu/housenumbers/train_32x32.mat (http://ufldl.stanford.edu/housenumbers/train_32x32.mat) (обучающая выборка);
 - http://ufldl.stanford.edu/housenumbers/test_32x32.mat (http://ufldl.stanford.edu/housenumbers/test_32x32.mat) (тестовая выборка);
 - http://ufldl.stanford.edu/housenumbers/extr_32x32.mat (http://ufldl.stanford.edu/housenumbers/extr_32x32.mat) (дополнительные данные);
- Описание данных на английском языке доступно по ссылке:
 - <http://ufldl.stanford.edu/housenumbers/> (<http://ufldl.stanford.edu/housenumbers/>)

Задание 1

Реализуйте глубокую нейронную сеть (полносвязную или сверточную) и обучите ее на синтетических данных (например, наборы *MNIST* (<http://yann.lecun.com/exdb/mnist/>) (<http://yann.lecun.com/exdb/mnist/>)) или *notMNIST*).

Ознакомьтесь с имеющимися работами по данной тематике: англоязычная статья (<http://static.googleusercontent.com/media/research.google.com/en//pubs/archive/42241.pdf> (<http://static.googleusercontent.com/media/research.google.com/en//pubs/archive/42241.pdf>)), видео на *YouTube* (https://www.youtube.com/watch?v=vGPI_JvLoN0) (https://www.youtube.com/watch?v=vGPI_JvLoN0).

Используем архитектуру *LeNet-5* и обучим сеть сначала на данных из набора *MNIST*.

In [0]:

```
import warnings  
  
warnings.filterwarnings('ignore')
```

In [2]:

```
from google.colab import drive  
  
drive.mount('/content/drive', force_remount = True)
```

Mounted at /content/drive

In [0]:

```
! pip install tensorflow-gpu --pre --quiet
```

In [0]:

```
import tensorflow as tf  
from tensorflow import keras  
  
# To fix memory Leak: https://github.com/tensorflow/tensorflow/issues/33009  
  
tf.compat.v1.disable_eager_execution()
```

In [0]:

```
import numpy as np
```

In [0]:

```
from tensorflow.keras.datasets import mnist  
  
(x_train, y_train), (x_test, y_test) = mnist.load_data()
```

In [0]:

```
x_train = tf.keras.utils.normalize(x_train, axis = 1)  
x_test = tf.keras.utils.normalize(x_test, axis = 1)
```

In [0]:

```
x_train = x_train[..., np.newaxis]  
x_test = x_test[..., np.newaxis]
```

In [9]:

```
from tensorflow.keras.utils import to_categorical

y_train, y_test = to_categorical(y_train), to_categorical(y_test)

y_train.shape
```

Out[9]:

(60000, 10)

In [0]:

```
IMAGE_DIM_0, IMAGE_DIM_1 = x_train.shape[1], x_train.shape[2]
```

In [0]:

```
CLASSES_N = y_train.shape[1]
```

In [12]:

```
x_train.shape, x_test.shape
```

Out[12]:

((60000, 28, 28, 1), (10000, 28, 28, 1))

In [13]:

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import AveragePooling2D, Conv2D, Dense, Flatten

model = tf.keras.Sequential()

model.add(Conv2D(6, kernel_size = (5, 5), strides = (1, 1),
                activation = 'tanh', padding = 'same',
                input_shape = (IMAGE_DIM_0, IMAGE_DIM_1, 1)))
model.add(AveragePooling2D(pool_size = (2, 2), strides = (2, 2),
                           padding = 'valid'))
model.add(Conv2D(16, kernel_size = (5, 5), strides = (1, 1),
                 activation = 'tanh', padding = 'valid'))
model.add(AveragePooling2D(pool_size = (2, 2), strides = (2, 2),
                           padding = 'valid'))
model.add(Flatten())
model.add(Dense(120, activation = 'tanh'))
model.add(Dense(84, activation = 'tanh'))
model.add(Dense(CLASSES_N, activation = 'softmax'))
```

WARNING:tensorflow:From /usr/local/lib/python3.6/dist-packages/tensorflow/python/ops/resource_variable_ops.py:1666: calling BaseResourceVariable.__init__(from tensorflow.python.ops.resource_variable_ops) with constraint is deprecated and will be removed in a future version.

Instructions for updating:

If using Keras pass *_constraint arguments to layers.

In [0]:

```
# 'sparse_categorical_crossentropy' gave NAN loss
```

```
model.compile(optimizer = 'adam',
              loss = 'categorical_crossentropy',
              metrics = ['categorical_accuracy'])
```

In [15]:

```
model.summary()
```

Model: "sequential"

Layer (type)	Output Shape	Param #
=====		
conv2d (Conv2D)	(None, 28, 28, 6)	156
=====		
average_pooling2d (AveragePo	(None, 14, 14, 6)	0
=====		
conv2d_1 (Conv2D)	(None, 10, 10, 16)	2416
=====		
average_pooling2d_1 (Average	(None, 5, 5, 16)	0
=====		
flatten (Flatten)	(None, 400)	0
=====		
dense (Dense)	(None, 120)	48120
=====		
dense_1 (Dense)	(None, 84)	10164
=====		
dense_2 (Dense)	(None, 10)	850
=====		
Total params: 61,706		
Trainable params: 61,706		
Non-trainable params: 0		

In [0]:

```
EPOCHS_N = 20
```

In [0]:

```
history = model.fit(x = x_train, y = y_train, validation_split = 0.15,
                      epochs = EPOCHS_N, verbose = 0)
```

In [0]:

```
%matplotlib inline

import matplotlib.pyplot as plt
import seaborn as sns
from matplotlib import rcParams

rcParams['figure.figsize'] = 8, 6

sns.set()
sns.set_palette(sns.color_palette('hls'))

def plot_accuracy(_history,
                  _train_acc_name = 'accuracy',
                  _val_acc_name = 'val_accuracy'):

    plt.plot(_history.history[_train_acc_name])
    plt.plot(_history.history[_val_acc_name])

    plt.title('Model accuracy')

    plt.ylabel('Accuracy')
    plt.xlabel('Epoch')

    plt.legend(['Train', 'Validation'], loc = 'right')

    plt.show()

def plot_loss(_history,
              _train_loss_name = 'loss',
              _val_loss_name = 'val_loss'):

    plt.plot(_history.history[_train_loss_name])
    plt.plot(_history.history[_val_loss_name])

    plt.title('Model loss')

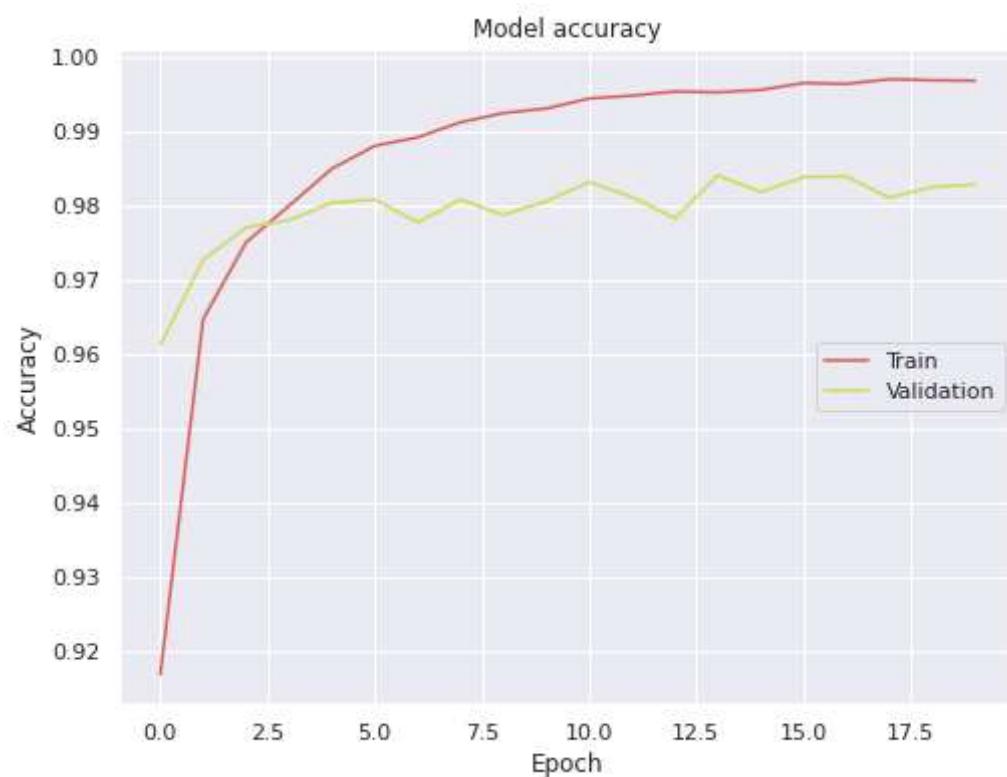
    plt.ylabel('Loss')
    plt.xlabel('Epoch')

    plt.legend(['Train', 'Validation'], loc = 'right')

    plt.show()
```

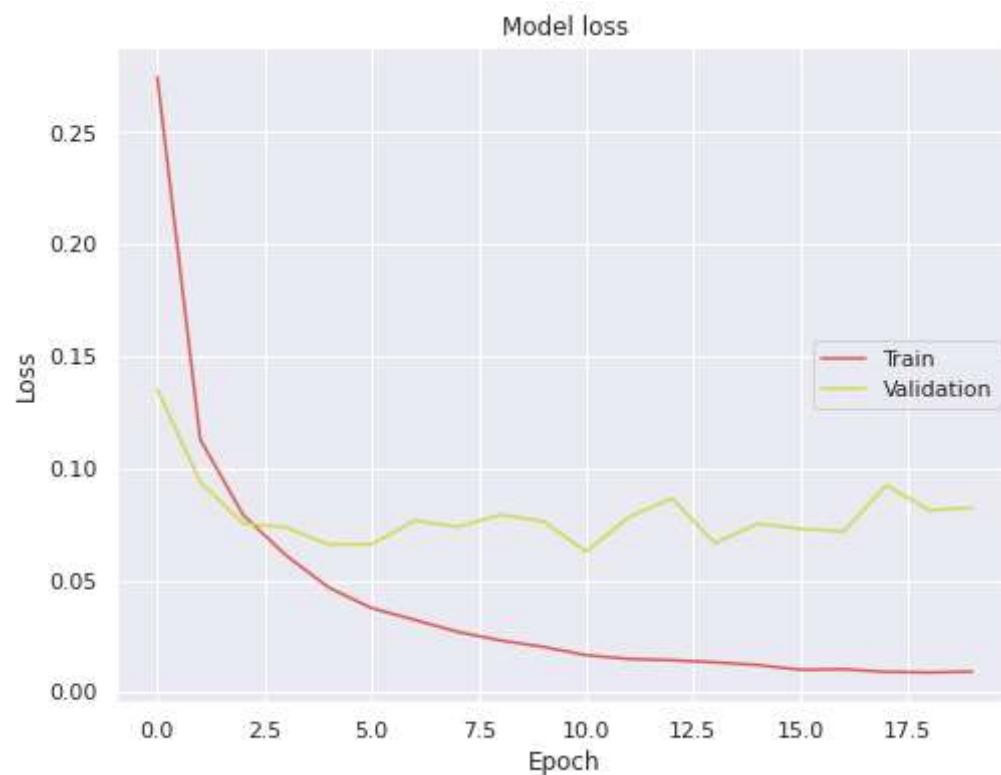
In [19]:

```
plot_accuracy(history, 'categorical_accuracy', 'val_categorical_accuracy')
```



In [20]:

```
plot_loss(history)
```



In [21]:

```
results = model.evaluate(x_test, y_test)  
print('Test loss, test accuracy:', results)
```

Test loss, test accuracy: [0.0783945622475956, 0.9802]

Удалось достичь отличного результата — точность распознавания на тестовой выборке составила 98%.

Задание 2

После уточнения модели на синтетических данных попробуйте обучить ее на реальных данных (набор Google Street View). Что изменилось в модели?

Одна цифра

In [0]:

```
DS_URL_FOLDER = 'http://ufldl.stanford.edu/housenumbers/'

FIRST_DS_EXT = '.tar.gz'
SECOND_DS_EXT = '_32x32.mat'

TRAIN_DS_NAME = 'train'
TEST_DS_NAME = 'test'
EXTRA_DS_NAME = 'extra'
```

In [0]:

```
from urllib.request import urlretrieve
import tarfile
import os

def load_file(_url_folder, _name, _ext, _key, _local_ext = ''):

    file_url_ = _url_folder + _name + _ext

    local_file_name_ = _name + '_' + _key + _local_ext

    urlretrieve(file_url_, local_file_name_)

    return local_file_name_

def tar_gz_to_dir(_url_folder, _name, _ext, _key):

    local_file_name_ = load_file(_url_folder, _name, _ext, _key, _ext)

    dir_name_ = _name + '_' + _key

    with tarfile.open(local_file_name_, 'r:gz') as tar_:
        tar_.extractall(dir_name_)

    os.remove(local_file_name_)

    return dir_name_
```

In [0]:

```
second_ds_train_file = load_file(DS_URL_FOLDER, TRAIN_DS_NAME, SECOND_DS_EXT,
                                  'second')
second_ds_test_file = load_file(DS_URL_FOLDER, TEST_DS_NAME, SECOND_DS_EXT,
                                 'second')
second_ds_extra_file = load_file(DS_URL_FOLDER, EXTRA_DS_NAME, SECOND_DS_EXT,
                                  'second')
```

In [0]:

```
from scipy import io

second_ds_train = io.loadmat(second_ds_train_file)
second_ds_test = io.loadmat(second_ds_test_file)
second_ds_extra = io.loadmat(second_ds_extra_file)
```

In [26]:

```
X_second_ds_train = np.moveaxis(second_ds_train['X'], -1, 0)
X_second_ds_test = np.moveaxis(second_ds_test['X'], -1, 0)
X_second_ds_extra = np.moveaxis(second_ds_extra['X'], -1, 0)

y_second_ds_train = second_ds_train['y']
y_second_ds_test = second_ds_test['y']
y_second_ds_extra = second_ds_extra['y']

print(X_second_ds_train.shape, y_second_ds_train.shape)
print(X_second_ds_test.shape, y_second_ds_test.shape)
print(X_second_ds_extra.shape, y_second_ds_extra.shape)
```

```
(73257, 32, 32, 3) (73257, 1)
(26032, 32, 32, 3) (26032, 1)
(531131, 32, 32, 3) (531131, 1)
```

In [0]:

```
%matplotlib inline

import matplotlib.pyplot as plt
```

In [0]:

```
import seaborn as sns

from matplotlib import rcParams

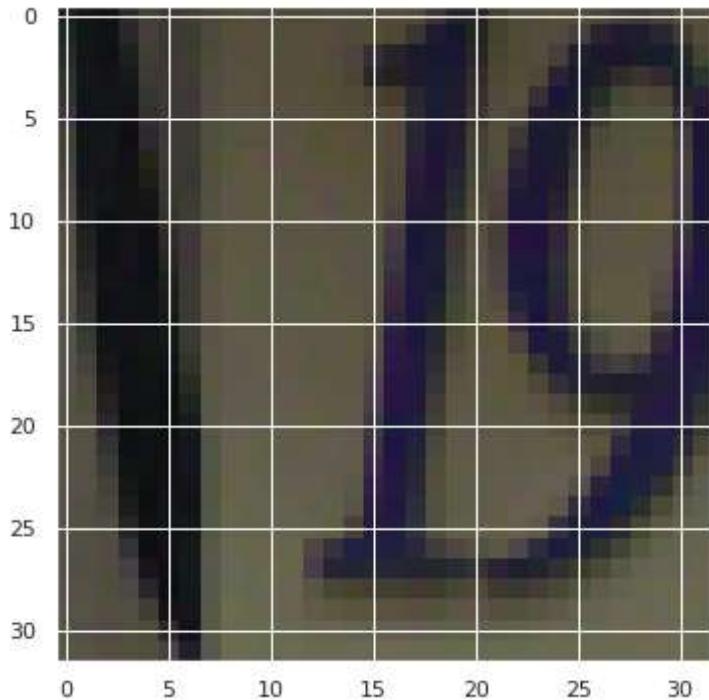
rcParams['figure.figsize'] = 8, 6

sns.set()

sns.set_palette(sns.color_palette('hls'))
```

In [29]:

```
plt.imshow(X_second_ds_train[0])  
plt.show()
```



In [0]:

```
IMAGE_DIM_0_2 = X_second_ds_train.shape[-3]  
IMAGE_DIM_1_2 = X_second_ds_train.shape[-2]  
IMAGE_DIM_2_2 = X_second_ds_train.shape[-1]
```

In [0]:

```
y_second_ds_train_cat = to_categorical(y_second_ds_train)  
y_second_ds_test_cat = to_categorical(y_second_ds_test)
```

In [0]:

```
CLASSES_N_2 = y_second_ds_train_cat.shape[1]
```

In [0]:

```
model_2 = tf.keras.Sequential()

model_2.add(Conv2D(6, kernel_size = (5, 5), strides = (1, 1),
                  activation = 'tanh', padding = 'same',
                  input_shape = (IMAGE_DIM_0_2, IMAGE_DIM_1_2, IMAGE_DIM_2_2)))
model_2.add(AveragePooling2D(pool_size = (2, 2), strides = (2, 2),
                            padding = 'valid'))
model_2.add(Conv2D(16, kernel_size = (5, 5), strides = (1, 1),
                   activation = 'tanh', padding = 'valid'))
model_2.add(AveragePooling2D(pool_size = (2, 2), strides = (2, 2),
                            padding = 'valid'))
model_2.add(Flatten())
model_2.add(Dense(120, activation = 'tanh'))
model_2.add(Dense(84, activation = 'tanh'))
model_2.add(Dense(CLASSES_N_2, activation = 'softmax'))
```

In [0]:

```
model_2.compile(optimizer = 'adam',
                 loss = 'categorical_crossentropy',
                 metrics = ['categorical_accuracy'])
```

In [35]:

```
model_2.summary()
```

Model: "sequential_1"

Layer (type)	Output Shape	Param #
conv2d_2 (Conv2D)	(None, 32, 32, 6)	456
average_pooling2d_2 (Average)	(None, 16, 16, 6)	0
conv2d_3 (Conv2D)	(None, 12, 12, 16)	2416
average_pooling2d_3 (Average)	(None, 6, 6, 16)	0
flatten_1 (Flatten)	(None, 576)	0
dense_3 (Dense)	(None, 120)	69240
dense_4 (Dense)	(None, 84)	10164
dense_5 (Dense)	(None, 11)	935

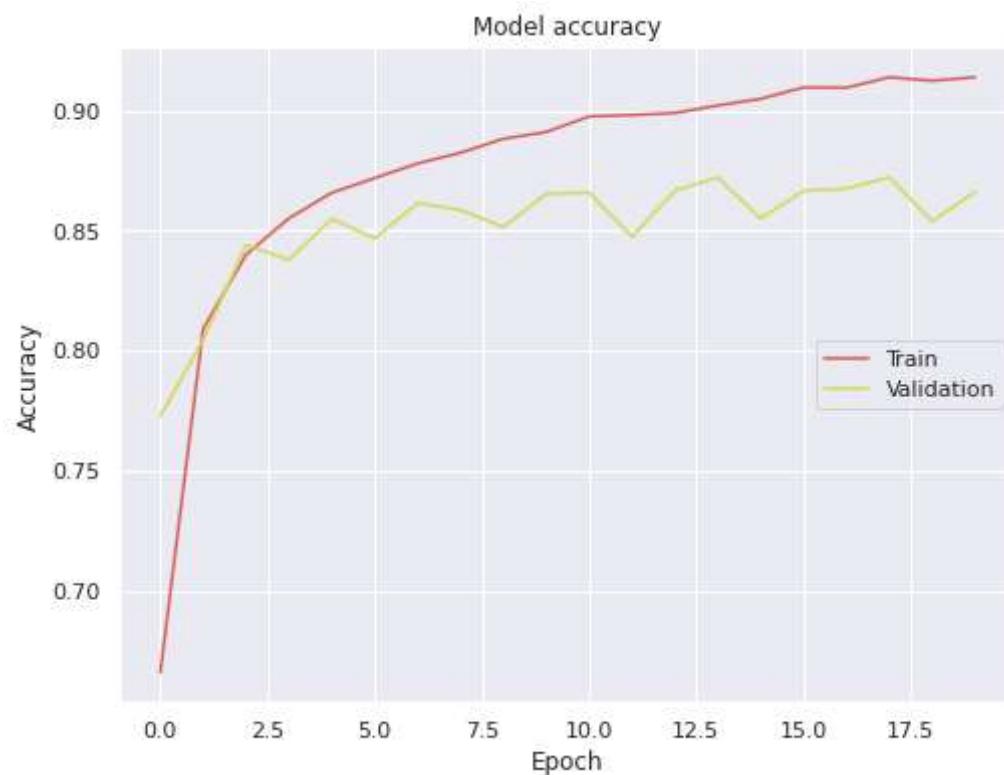
Total params: 83,211
Trainable params: 83,211
Non-trainable params: 0

In [0]:

```
history_2 = model_2.fit(x = X_second_ds_train, y = y_second_ds_train_cat,
                         validation_split = 0.15, epochs = EPOCHS_N, verbose = 0)
```

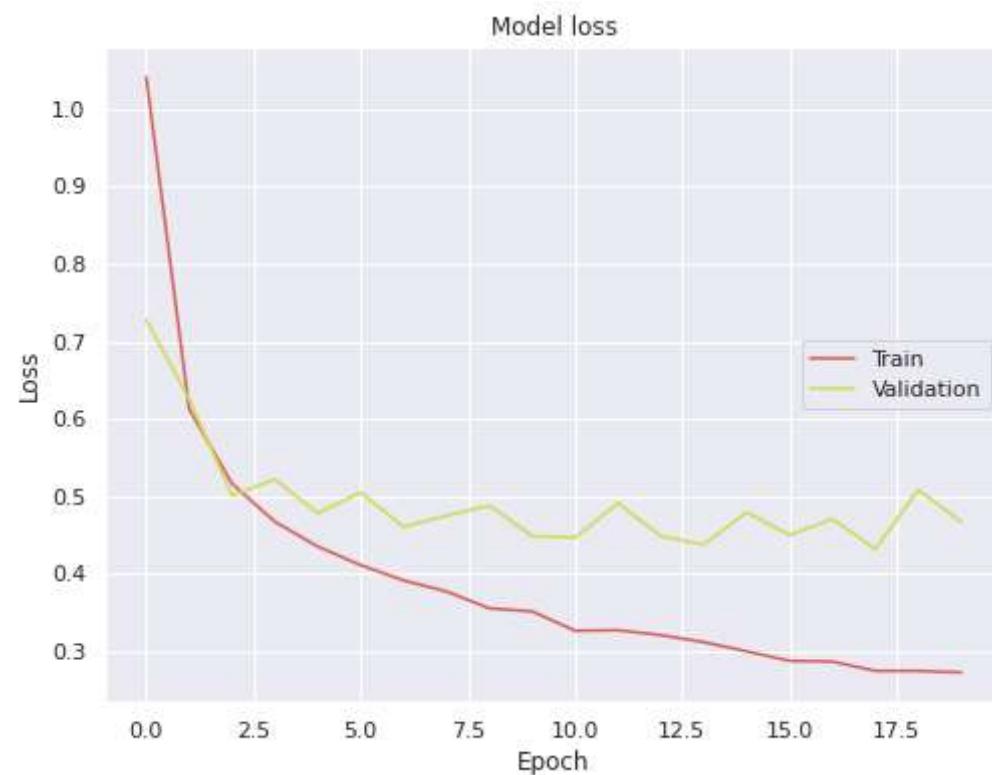
In [37]:

```
plot_accuracy(history_2, 'categorical_accuracy', 'val_categorical_accuracy')
```



In [38]:

```
plot_loss(history_2)
```



In [39]:

```
results = model_2.evaluate(X_second_ds_test, y_second_ds_test_cat)
print('Test loss, test accuracy:', results)
```

Test loss, test accuracy: [0.5283718607362679, 0.8493777]

Здесь в модели изменилось то, что добавился ещё один класс — *нет цифры*.

Эти данные более сложны для распознавания, что повлияло на результат — точность распознавания на тестовой выборке составила 84%.

Несколько цифр

Загрузим первый датасет — реальные изображения с несколькими цифрами и рамками границ.

In [0]:

```
from imageio import imread
import pandas as pd

def image_to_array(_image):
    try:
        array_ = imread(_image)

        return True, array_
    except:
        return False, None

def dir_to_dataframe(_dir_path):
    data_ = []
    files_ = sorted(os.listdir(_dir_path))

    for f in files_:
        file_path_ = os.path.join(_dir_path, f)

        can_read_, im = image_to_array(file_path_)

        if can_read_:
            data_.append(im)

    dataframe_ = pd.DataFrame()
    dataframe_[ 'data' ] = np.array(data_)

    return dataframe_
```

In [0]:

```
PROCESS = False
```

In [0]:

```
if PROCESS:  
    first_ds_train_dir = tar_gz_to_dir(  
        DS_URL_FOLDER, TRAIN_DS_NAME, FIRST_DS_EXT, 'first')  
    first_ds_test_dir = tar_gz_to_dir(  
        DS_URL_FOLDER, TEST_DS_NAME, FIRST_DS_EXT, 'first')
```

In [0]:

```
if PROCESS:  
    first_ds_train_subdir = os.path.join(first_ds_train_dir, 'train')  
    first_ds_test_subdir = os.path.join(first_ds_test_dir, 'test')
```

In [0]:

```
if PROCESS:  
    first_ds_train_images_df = dir_to_dataframe(first_ds_train_subdir)  
    first_ds_test_images_df = dir_to_dataframe(first_ds_test_subdir)
```

In [0]:

```
import h5py  
  
if PROCESS:  
    first_ds_train_boxes_mat = h5py.File(  
        os.path.join(first_ds_train_subdir, 'digitStruct.mat'), 'r')  
    first_ds_test_boxes_mat = h5py.File(  
        os.path.join(first_ds_test_subdir, 'digitStruct.mat'), 'r')
```

In [0]:

```
import numpy as np
import pickle
import h5py

def mat_to_pickle(_mat_path, _key):

    f = h5py.File(_mat_path, 'r')

    metadata = {}

    metadata['height'] = []
    metadata['label'] = []
    metadata['left'] = []
    metadata['top'] = []
    metadata['width'] = []

    def print_attrs(name, obj):

        vals = []

        if obj.shape[0] == 1:
            vals.append(int(obj[0][0]))
        else:
            for k in range(obj.shape[0]):

                vals.append(int(f[obj[k][0]][0][0]))

        metadata[name].append(vals)

    for item in f['/digitStruct/bbox']:

        f[item[0]].visititems(print_attrs)

    with open('{}.pickle'.format(_key), 'wb') as pf:

        pickle.dump(metadata, pf, pickle.HIGHEST_PROTOCOL)
```

In [0]:

```
if PROCESS:
    mat_to_pickle(
        os.path.join(first_ds_train_subdir, 'digitStruct.mat'), 'train_bbox')
    mat_to_pickle(
        os.path.join(first_ds_test_subdir, 'digitStruct.mat'), 'test_bbox')
```

In [0]:

```
if PROCESS:
    train_bbox_data = np.load('train_bbox.pickle', allow_pickle = True)
    test_bbox_data = np.load('test_bbox.pickle', allow_pickle = True)
```

In [0]:

```
if PROCESS:  
    plt.imshow(first_ds_train_images_df['data'][0])  
  
    plt.show()
```

In [0]:

```
MAX_DIGITS = 6
```

In [0]:

```
def to_full_df(_ds_images_df, _bbox_data):  
    LENGTH = len(_bbox_data['height'])  
  
    BBOX_SHAPE_TUPLE = (LENGTH, MAX_DIGITS)  
  
    bbox_heights = np.zeros(BBOX_SHAPE_TUPLE)  
    bbox_labels = np.zeros(BBOX_SHAPE_TUPLE)  
    bbox_lefts = np.zeros(BBOX_SHAPE_TUPLE)  
    bbox_tops = np.zeros(BBOX_SHAPE_TUPLE)  
    bbox_widths = np.zeros(BBOX_SHAPE_TUPLE)  
  
    for i in range(LENGTH):  
        j = 0  
  
        l = len(_bbox_data['height'][i])  
  
        while j < l:  
            bbox_heights[i][j] = _bbox_data['height'][i][j]  
            bbox_labels[i][j] = _bbox_data['label'][i][j]  
            bbox_lefts[i][j] = _bbox_data['left'][i][j]  
            bbox_tops[i][j] = _bbox_data['top'][i][j]  
            bbox_widths[i][j] = _bbox_data['width'][i][j]  
  
            j = j + 1  
  
    data_dict_ = {  
        'data': _ds_images_df['data'],  
  
        'height_0': bbox_heights[:, 0],  
        'label_0': bbox_labels[:, 0],  
        'left_0': bbox_lefts[:, 0],  
        'top_0': bbox_tops[:, 0],  
        'width_0': bbox_widths[:, 0],  
  
        'height_1': bbox_heights[:, 1],  
        'label_1': bbox_labels[:, 1],  
        'left_1': bbox_lefts[:, 1],  
        'top_1': bbox_tops[:, 1],  
        'width_1': bbox_widths[:, 1],  
  
        'height_2': bbox_heights[:, 2],  
        'label_2': bbox_labels[:, 2],  
        'left_2': bbox_lefts[:, 2],  
        'top_2': bbox_tops[:, 2],  
        'width_2': bbox_widths[:, 2],  
  
        'height_3': bbox_heights[:, 3],  
        'label_3': bbox_labels[:, 3],  
        'left_3': bbox_lefts[:, 3],  
        'top_3': bbox_tops[:, 3],  
        'width_3': bbox_widths[:, 3],  
  
        'height_4': bbox_heights[:, 4],  
        'label_4': bbox_labels[:, 4],  
        'left_4': bbox_lefts[:, 4],  
        'top_4': bbox_tops[:, 4],
```

```

'width_4': bbox_widths[:, 4],  

'height_5': bbox_heights[:, 5],  

'label_5': bbox_labels[:, 5],  

'left_5': bbox_lefts[:, 5],  

'top_5': bbox_tops[:, 5],  

'width_5': bbox_widths[:, 5],  

}  
  

full_ds_ = pd.DataFrame(data_dict_,  

                         columns = [  

                                         'data',  

                                         'height_0',  

                                         'label_0',  

                                         'left_0',  

                                         'top_0',  

                                         'width_0',  

                                         'height_1',  

                                         'label_1',  

                                         'left_1',  

                                         'top_1',  

                                         'width_1',  

                                         'height_2',  

                                         'label_2',  

                                         'left_2',  

                                         'top_2',  

                                         'width_2',  

                                         'height_3',  

                                         'label_3',  

                                         'left_3',  

                                         'top_3',  

                                         'width_3',  

                                         'height_4',  

                                         'label_4',  

                                         'left_4',  

                                         'top_4',  

                                         'width_4',  

                                         'height_5',  

                                         'label_5',  

                                         'left_5',  

                                         'top_5',  

                                         'width_5',  

                                     ])  
  

return full_ds_

```

In [0]:

```

if PROCESS:  

    first_ds_train_full_df = to_full_df(  

        first_ds_train_images_df, train_bbox_data)  

    first_ds_test_full_df = to_full_df(  

        first_ds_test_images_df, test_bbox_data)

```

In [0]:

```
def no_more_than_two_digits(_full_df):  
  
    _2_digits_df = _full_df[_full_df['height_2'] == 0.0].reset_index()  
  
    _2_digits_df = _2_digits_df.drop(columns = [  
        'height_2',  
        'label_2',  
        'left_2',  
        'top_2',  
        'width_2',  
  
        'height_3',  
        'label_3',  
        'left_3',  
        'top_3',  
        'width_3',  
  
        'height_4',  
        'label_4',  
        'left_4',  
        'top_4',  
        'width_4',  
  
        'height_5',  
        'label_5',  
        'left_5',  
        'top_5',  
        'width_5'  
    ])  
  
    return _2_digits_df
```

In [0]:

```
if PROCESS:  
    first_ds_train_2_digits_df = no_more_than_two_digits(  
        first_ds_train_full_df)  
    first_ds_test_2_digits_df = no_more_than_two_digits(  
        first_ds_test_full_df)
```

In [0]:

```
from math import ceil

def get_image_central_square(_image):

    dim_0 = _image.shape[0]
    dim_1 = _image.shape[1]

    if dim_0 == 0 or dim_1 == 0:

        print(_image.shape)

    cutoff_ = ceil(abs(dim_0 - dim_1) / 2)

    if dim_0 > dim_1:
        cut_image_ = _image[cutoff_: -cutoff_,
                            :, :]
    elif dim_0 < dim_1:
        cut_image_ = _image[:, cutoff_: -cutoff_,
                            :]
    else:
        cut_image_ = _image[:, :, :]

    return cut_image_
```

In [0]:

```
NEW_IMAGE_DIM = 50
```

In [0]:

```
import cv2

def resize_image(_image, _dim_0 = NEW_IMAGE_DIM, _dim_1 = NEW_IMAGE_DIM):

    try:
        resized_ = cv2.resize(_image, dsize = (_dim_0, _dim_1),
                             interpolation = cv2.INTER_CUBIC)
    except:
        print(_image.shape)

    return resized_
```

In [0]:

```
def process_image(_image):

    squared_ = get_image_central_square(_image)

    resized_ = resize_image(squared_)

    return resized_
```

In [0]:

```
def get_digits_n_from_row(_row):  
  
    if _row['height_1'] != 0.0:  
        return 2  
  
    if _row['height_0'] != 0.0:  
        return 1  
  
    return 0
```

In [0]:

```
def to_new_format_dataframe(_dataframe):  
  
    df_copy_ = _dataframe.copy()  
  
    rrrr = df_copy_.apply(lambda row: process_image(row['data']), axis = 1)  
  
    df_copy_.drop(columns = ['data'])  
  
    df_copy_['data'] = rrrr  
  
    nnnn = df_copy_.apply(lambda row: get_digits_n_from_row(row), axis = 1)  
  
    df_copy_['digits_n'] = nnnn  
  
    df_copy_['digit_0'] = df_copy_['label_0'].astype(int)  
    df_copy_['digit_1'] = df_copy_['label_1'].astype(int)  
  
    df_copy_ = df_copy_.drop(columns = [  
                                         'height_0',  
                                         'label_0',  
                                         'left_0',  
                                         'top_0',  
                                         'width_0',  
  
                                         'height_1',  
                                         'label_1',  
                                         'left_1',  
                                         'top_1',  
                                         'width_1'  
                                         ])  
  
    return df_copy_
```

In [0]:

```
if PROCESS:  
    train_resized_df = to_new_format_dataframe(first_ds_train_2_digits_df)  
    test_resized_df = to_new_format_dataframe(first_ds_test_2_digits_df)
```

In [0]:

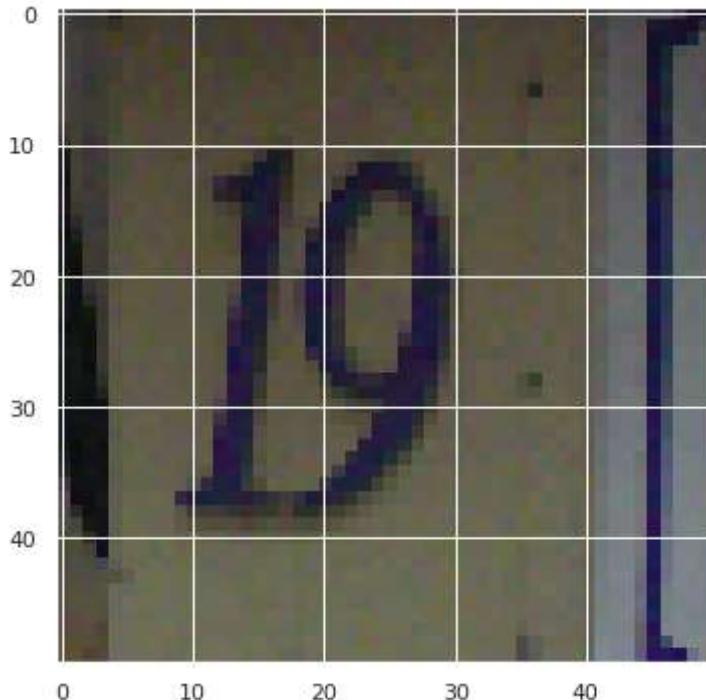
```
if PROCESS:  
    train_resized_df.to_pickle(  
        '/content/drive/My Drive/Colab Files/mo-2/multidigit_train.pkl')  
    test_resized_df.to_pickle(  
        '/content/drive/My Drive/Colab Files/mo-2/multidigit_test.pkl')
```

In [0]:

```
train_multidigit_df = pd.read_pickle(  
    '/content/drive/My Drive/Colab Files/mo-2/multidigit_train.pkl')  
test_multidigit_df = pd.read_pickle(  
    '/content/drive/My Drive/Colab Files/mo-2/multidigit_test.pkl')
```

In [64]:

```
plt.imshow(train_multidigit_df['data'][0])  
plt.show()
```



In [65]:

```
print('digits_n:', train_multidigit_df['digits_n'][0], '\t',  
      'digit_0:', train_multidigit_df['digit_0'][0], '\t',  
      'digit_1:', train_multidigit_df['digit_1'][0])
```

digits_n: 2 digit_0: 1 digit_1: 9

In [0]:

```
inputs = keras.Input(shape = (NEW_IMAGE_DIM, NEW_IMAGE_DIM, IMAGE_DIM_2_2))
```

In [0]:

```
from tensorflow.keras.layers import Dropout, MaxPooling2D

l_d_0_0 = Conv2D(16, kernel_size = (5, 5), strides = (1, 1),
                 activation = 'relu', padding = 'same')(inputs)
l_d_0_1 = MaxPooling2D(pool_size = (2, 2), strides = 2,
                       padding = 'valid')(l_d_0_0)
l_d_0_2 = Dropout(0.2)(l_d_0_0)

l_d_1_0 = Conv2D(32, kernel_size = (5, 5), strides = (1, 1),
                 activation = 'relu', padding = 'same')(l_d_0_2)
l_d_1_1 = MaxPooling2D(pool_size = (2, 2), strides = 1,
                       padding = 'valid')(l_d_1_0)
l_d_1_2 = Dropout(0.2)(l_d_1_0)

l_d_2_0 = Conv2D(64, kernel_size = (5, 5), strides = (1, 1),
                 activation = 'relu', padding = 'same')(l_d_1_2)
l_d_2_1 = MaxPooling2D(pool_size = (2, 2), strides = 2,
                       padding = 'valid')(l_d_2_0)
l_d_2_2 = Dropout(0.2)(l_d_2_0)

l_fl_0 = Flatten()(l_d_2_2)
l_dense_0 = Dense(2400, activation = 'relu')(l_fl_0)

output_common = Dense(1200, activation = 'relu')(l_dense_0)

digits_n_output = Dense(2, activation = 'softmax', name = 'digits_n')(output_common)
digit_0_output = Dense(10, activation = 'softmax', name = 'digit_0')(output_common)
digit_1_output = Dense(11, activation = 'softmax', name = 'digit_1')(output_common)
```

In [0]:

```
def digits_n_loss(n_logits, n_labels):
    return tf.reduce_mean(
        tf.compat.v1.losses.softmax_cross_entropy(n_logits, n_labels))

def digit_0_loss(digit_0_logits, digit_0_labels):
    return tf.reduce_mean(
        tf.compat.v1.losses.softmax_cross_entropy(digit_0_logits, digit_0_labels))

def digit_1_loss(digit_1_logits, digit_1_labels):
    return tf.reduce_mean(
        tf.compat.v1.losses.softmax_cross_entropy(digit_1_logits, digit_1_labels))

losses = {
    'digits_n': digits_n_loss,
    'digit_0': digit_0_loss,
    'digit_1': digit_1_loss
}

loss_weights = {
    'digits_n': 1.0,
    'digit_0': 1.0,
    'digit_1': 1.0
}
```

In [0]:

```
model_3 = keras.Model(inputs = inputs,
                      outputs = [
                          digits_n_output,
                          digit_0_output,
                          digit_1_output])
```

In [70]:

```
model_3.summary()
```

Model: "model"

Layer (type)	Output Shape	Param #	Connected to
input_1 (InputLayer)	[None, 50, 50, 3]	0	
conv2d_4 (Conv2D)[0]	(None, 50, 50, 16)	1216	input_1[0]
dropout (Dropout)[0]	(None, 50, 50, 16)	0	conv2d_4[0]
conv2d_5 (Conv2D)[0]	(None, 50, 50, 32)	12832	dropout[0]
dropout_1 (Dropout)[0]	(None, 50, 50, 32)	0	conv2d_5[0]
conv2d_6 (Conv2D)[0][0]	(None, 50, 50, 64)	51264	dropout_1
dropout_2 (Dropout)[0]	(None, 50, 50, 64)	0	conv2d_6[0]
flatten_2 (Flatten)[0][0]	(None, 160000)	0	dropout_2
dense_6 (Dense)[0][0]	(None, 2400)	384002400	flatten_2
dense_7 (Dense)[0]	(None, 1200)	2881200	dense_6[0]
digits_n (Dense)[0]	(None, 2)	2402	dense_7[0]
digit_0 (Dense)[0]	(None, 10)	12010	dense_7[0]
digit_1 (Dense)[0]	(None, 11)	13211	dense_7[0]

=====

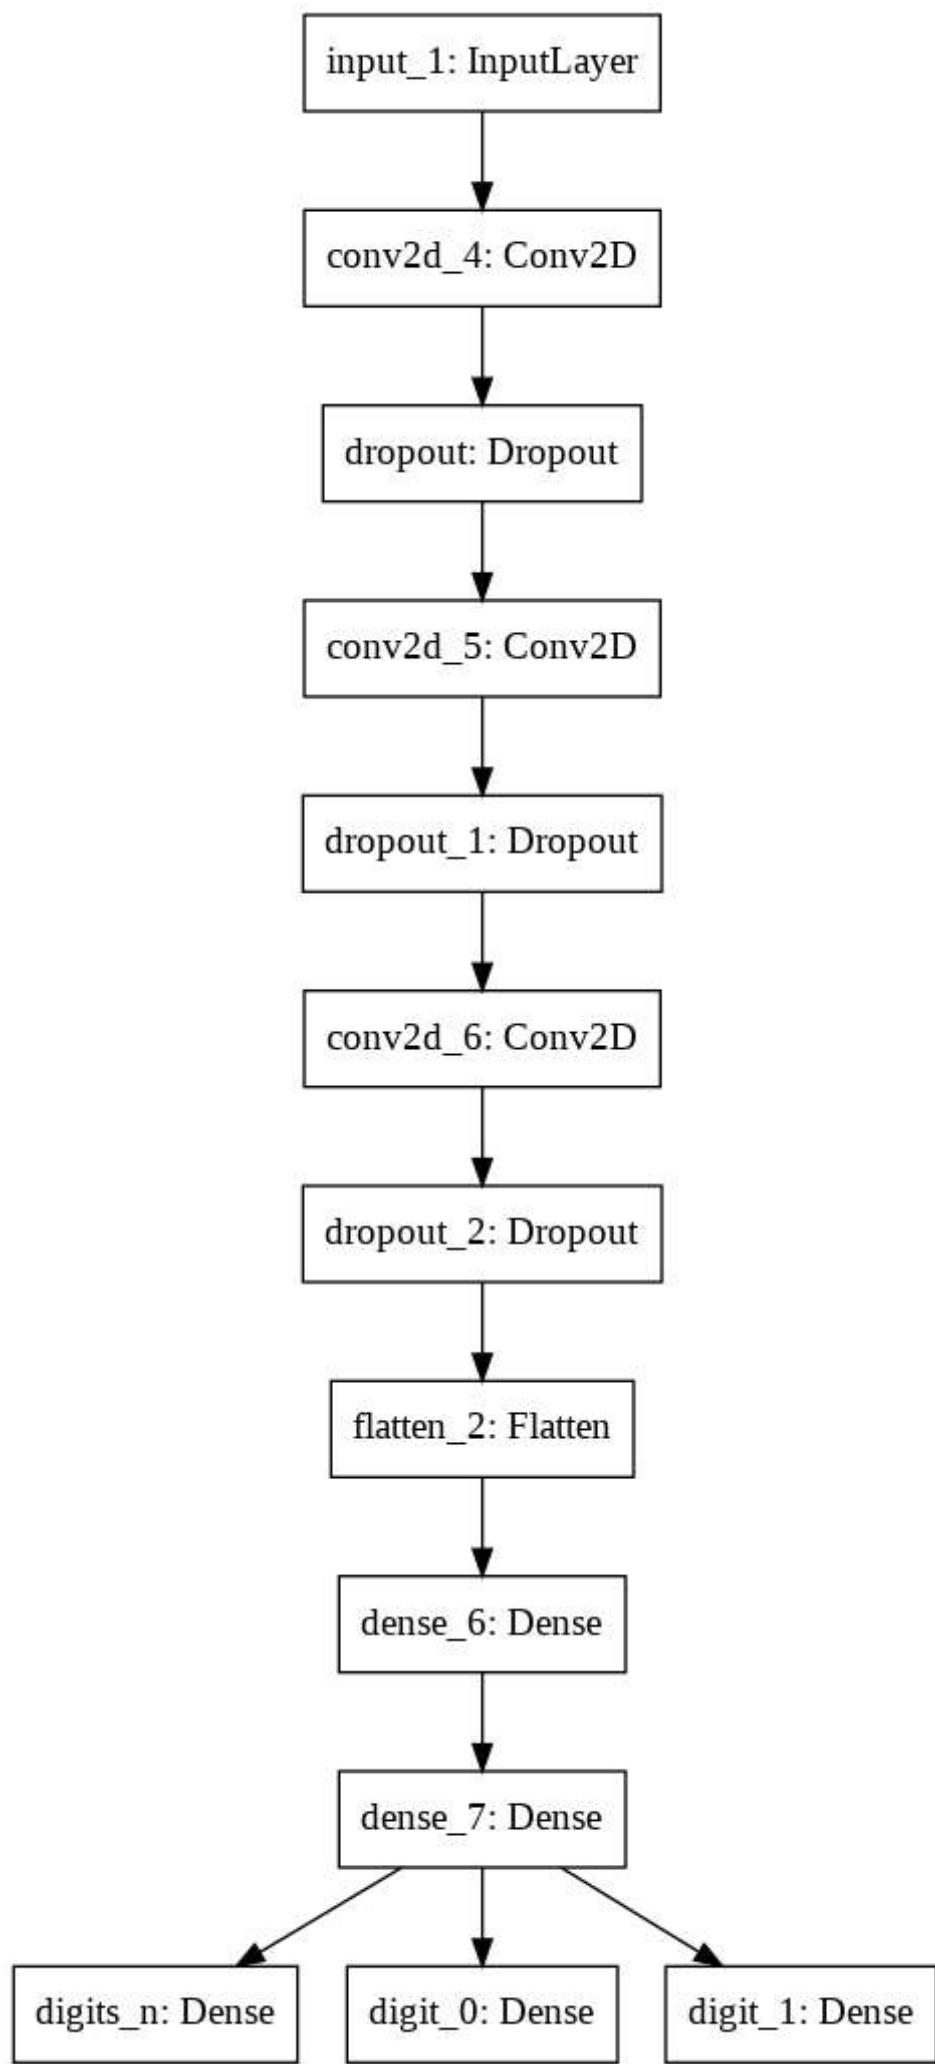
Total params: 386,976,535
Trainable params: 386,976,535
Non-trainable params: 0



In [71]:

```
keras.utils.plot_model(model_3, 'multidigit.png')
```

Out[71]:



In [0]:

```
X_multidigit = tf.keras.utils.normalize(np.asarray(list(train_multidigit_df['data'])), axis=0)

y_n_multidigit = (to_categorical(train_multidigit_df['digits_n'])
                   .astype('category')
                   .cat.codes.astype('int32'))
y_d_0_multidigit = (to_categorical(train_multidigit_df['digit_0'])
                     .astype('category')
                     .cat.codes.astype('int32'))
y_d_1_multidigit = (to_categorical(train_multidigit_df['digit_1'])
                     .astype('category')
                     .cat.codes.astype('int32'))

y_multidigit = [
    y_n_multidigit,
    y_d_0_multidigit,
    y_d_1_multidigit
]
```

In [0]:

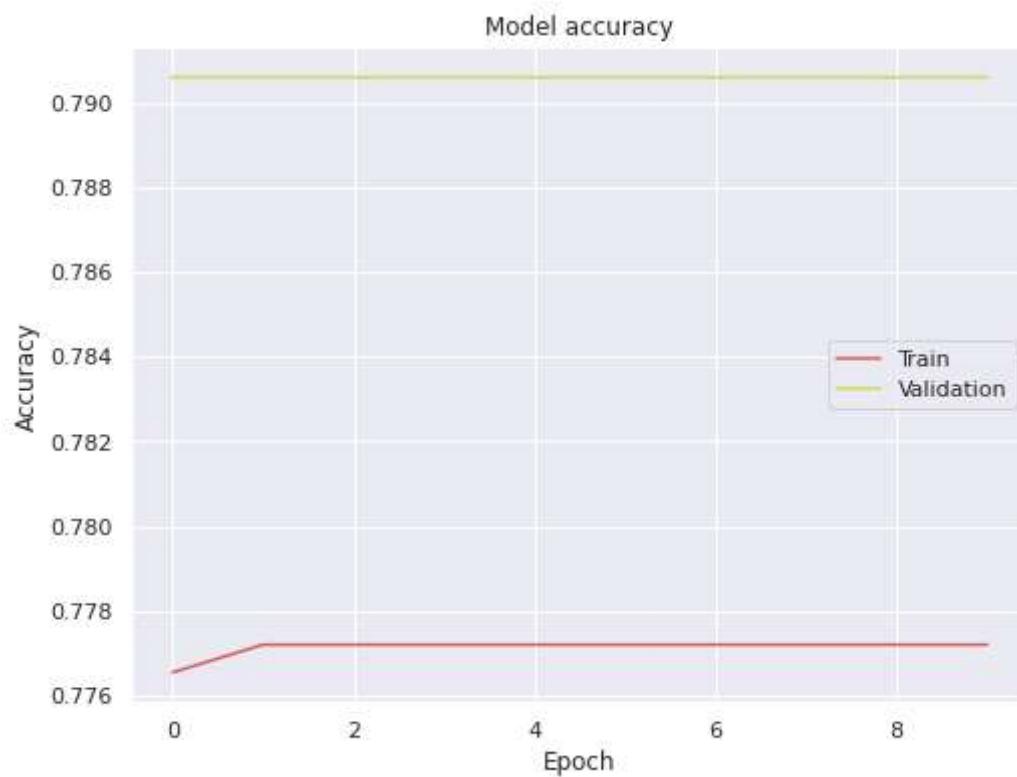
```
model_3.compile(optimizer = 'adam',
                 loss = losses, loss_weights = loss_weights,
                 metrics = ['categorical_accuracy'])
```

In [0]:

```
history_3 = model_3.fit(x = X_multidigit,
                        y = y_multidigit,
                        epochs = 10,
                        validation_split = 0.15,
                        verbose = 0)
```

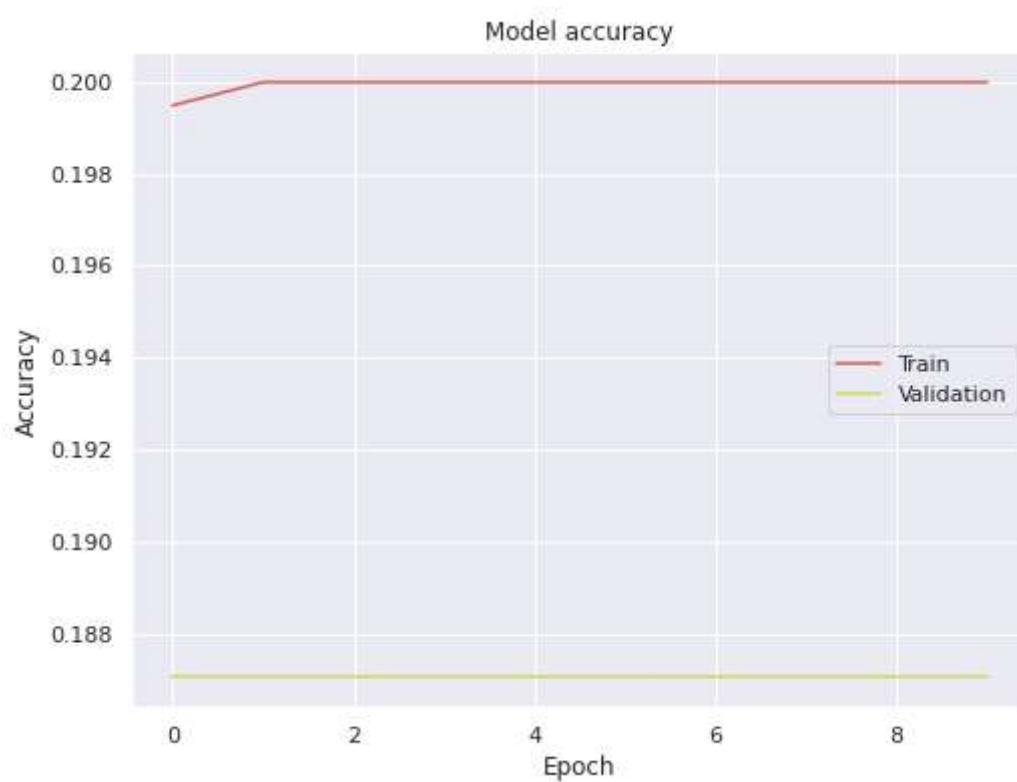
In [75]:

```
plot_accuracy(history_3, 'digits_n_categorical_accuracy', 'val_digits_n_categorical_accuracy')
```



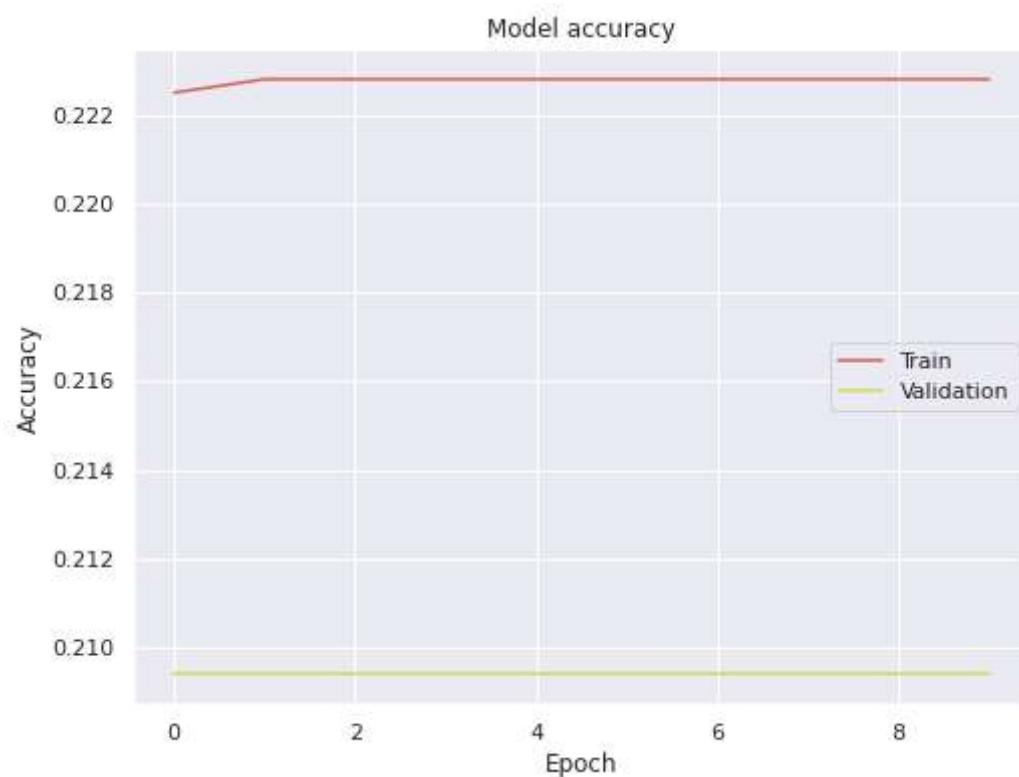
In [76]:

```
plot_accuracy(history_3, 'digit_0_categorical_accuracy', 'val_digit_0_categorical_accuracy')
```



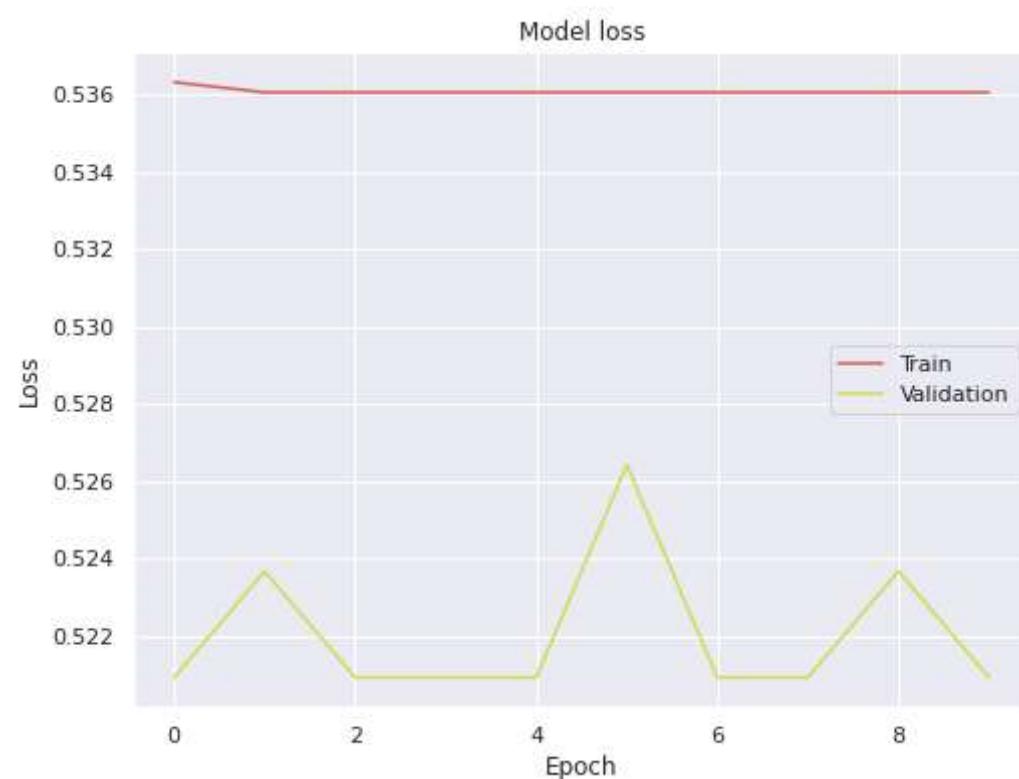
In [77]:

```
plot_accuracy(history_3, 'digit_1_categorical_accuracy', 'val_digit_1_categorical_accuracy')
```



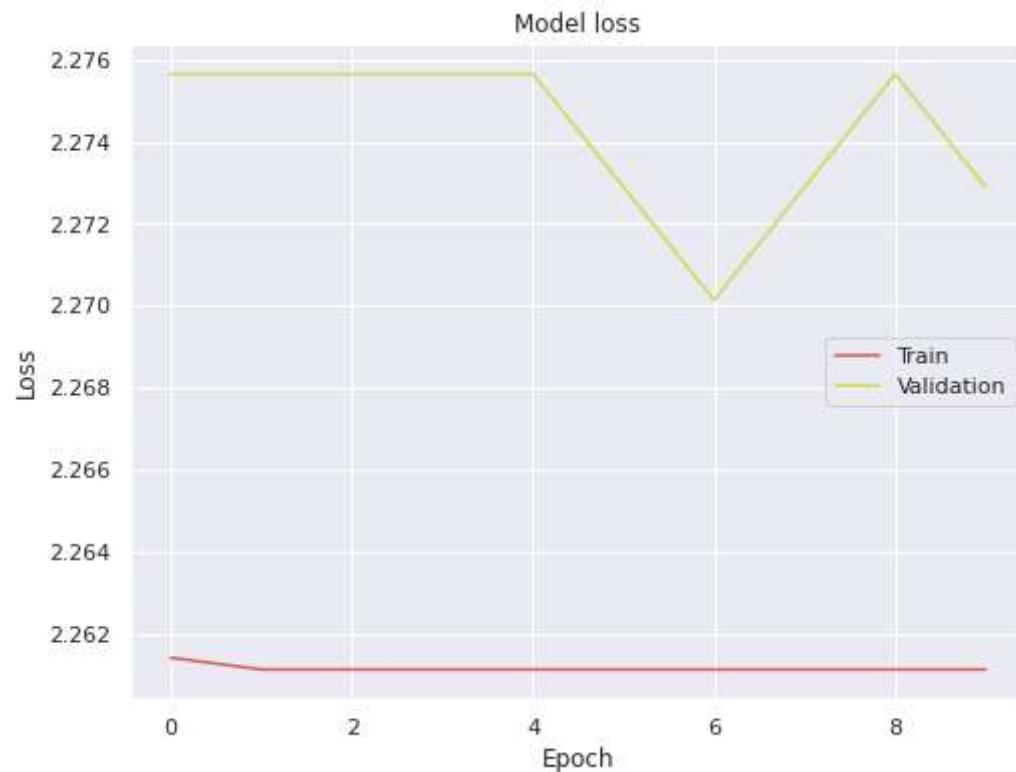
In [78]:

```
plot_loss(history_3, 'digits_n_loss', 'val_digits_n_loss')
```



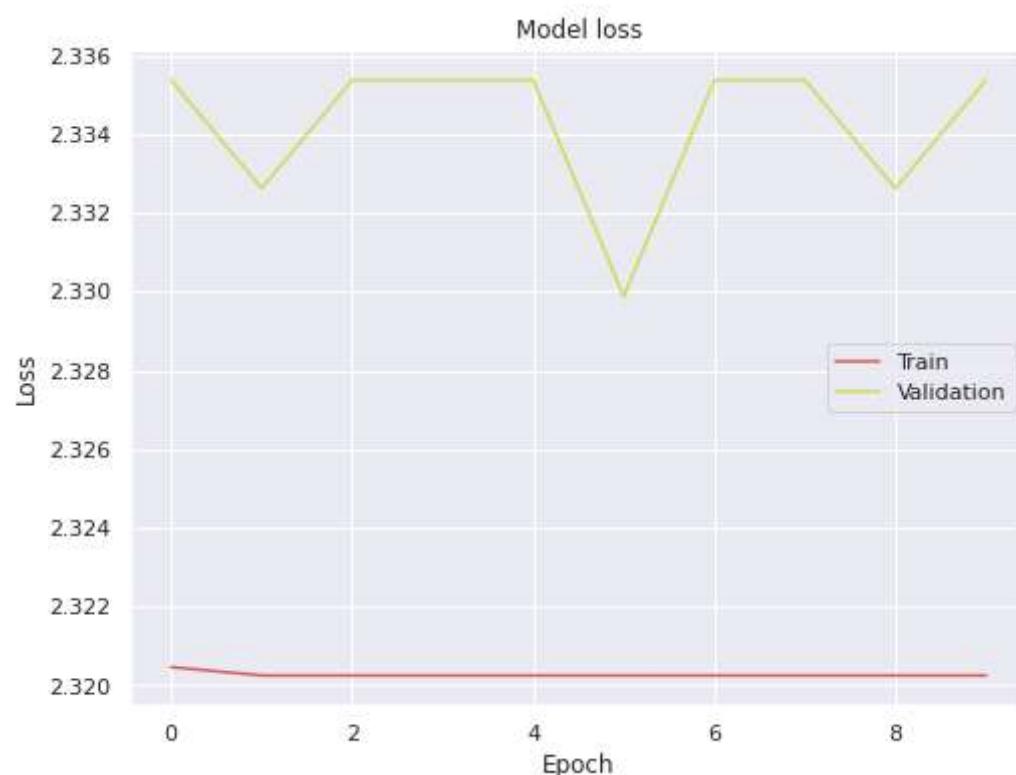
In [79]:

```
plot_loss(history_3, 'digit_0_loss', 'val_digit_0_loss')
```



In [80]:

```
plot_loss(history_3, 'digit_1_loss', 'val_digit_1_loss')
```



In [0]:

```
X_test_multidigit = tf.keras.utils.normalize(
    np.asarray(list(test_multidigit_df['data']))), axis = 1)

y_n_test_multidigit = (to_categorical(test_multidigit_df['digits_n']
                                         .astype('category')
                                         .cat.codes.astype('int32')))

y_d_0_test_multidigit = (to_categorical(test_multidigit_df['digit_0']
                                         .astype('category')
                                         .cat.codes.astype('int32')))

y_d_1_test_multidigit = (to_categorical(test_multidigit_df['digit_1']
                                         .astype('category')
                                         .cat.codes.astype('int32')))

y_test_multidigit = [
    y_n_test_multidigit,
    y_d_0_test_multidigit,
    y_d_1_test_multidigit
]
```

In [82]:

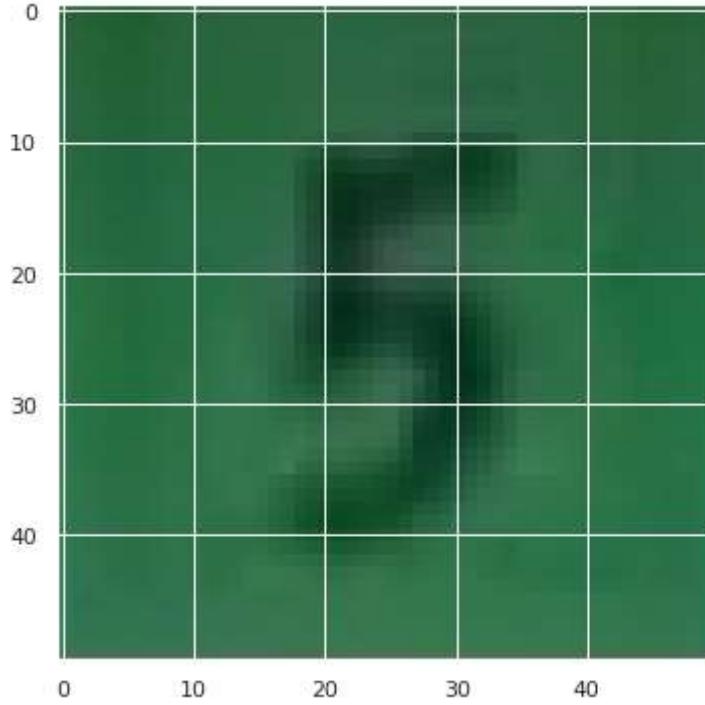
```
results_3 = model_3.evaluate(X_test_multidigit, y_test_multidigit)

for i, k in enumerate(history_3.history.keys()):
    if i < len(results_3):
        print(k, '\t', results_3[i])
```

```
loss      5.093077011154151
digits_n_loss     0.5423692
digit_0_loss      2.236772
digit_1_loss      2.3139274
digits_n_categorical_accuracy  0.7709198
digit_0_categorical_accuracy   0.22437494
digit_1_categorical_accuracy  0.22908017
```

In [83]:

```
plt.imshow(test_multidigit_df['data'][0])  
plt.show()
```



In [84]:

```
prediction_3 = model_3.predict(np.asarray([test_multidigit_df['data'][0]]))  
  
print('digits_n:', prediction_3[0].squeeze(), '\n',  
      'digit_0:', prediction_3[1].squeeze(), '\n',  
      'digit_1:', prediction_3[2].squeeze())
```

```
digits_n: [0. 1.]  
digit_0: [1. 0. 0. 0. 0. 0. 0. 0. 0.]  
digit_1: [1. 0. 0. 0. 0. 0. 0. 0. 0.]
```

Задание 3

Сделайте множество снимков изображений номеров домов с помощью смартфона на ОС *Android*. Также можно использовать библиотеки *OpenCV*, *Simple CV* или *Rugame* для обработки изображений с общедоступных камер видеонаблюдения (например, <https://www.earthcam.com/>) (<https://www.earthcam.com/>).

В качестве примера использования библиотеки *TensorFlow* на смартфоне можете воспользоваться демонстрационным приложением от *Google* (<https://github.com/tensorflow/tensorflow/tree/master/tensorflow/examples/android>) (<https://github.com/tensorflow/tensorflow/tree/master/tensorflow/examples/android>).

Задание 4

Реализуйте приложение для ОС *Android*, которое может распознавать цифры в номерах домов, используя разработанный ранее классификатор. Какова доля правильных классификаций?

Лабораторная работа №5

Применение сверточных нейронных сетей (бинарная классификация)

Набор данных *DogsVsCats*, который состоит из изображений различной размерности, содержащих фотографии собак и кошек.

Обучающая выборка включает в себя 25 тыс. изображений (12,5 тыс. кошек: *cat.0.jpg*, ..., *cat.12499.jpg* и 12,5 тыс. собак: *dog.0.jpg*, ..., *dog.12499.jpg*), а контрольная выборка содержит 12,5 тыс. неразмеченных изображений.

Скачать данные, а также проверить качество классификатора на тестовой выборке можно на сайте Kaggle: <https://www.kaggle.com/c/dogs-vs-cats/data> (<https://www.kaggle.com/c/dogs-vs-cats/data>)

Задание 1

Загрузите данные. Разделите исходный набор данных на обучающую, валидационную и контрольную выборки.

In [0]:

```
import warnings  
  
warnings.filterwarnings('ignore')
```

In [2]:

```
from google.colab import drive  
  
drive.mount('/content/drive', force_remount = True)
```

Mounted at /content/drive

In [0]:

```
BASE_DIR = '/content/drive/My Drive/Colab Files/mo-2/dogs-vs-cats'  
  
import sys  
  
sys.path.append(BASE_DIR)  
  
import os
```

In [0]:

```
TRAIN_ARCHIVE_NAME = 'train.zip'  
TEST_ARCHIVE_NAME = 'test1.zip'  
  
LOCAL_DIR_NAME = 'dogs-vs-cats'
```

In [0]:

```
from zipfile import ZipFile

with ZipFile(os.path.join(BASE_DIR, TRAIN_ARCHIVE_NAME), 'r') as zip_:
    zip_.extractall(path = os.path.join(LOCAL_DIR_NAME, 'train'))

with ZipFile(os.path.join(BASE_DIR, TEST_ARCHIVE_NAME), 'r') as zip_:
    zip_.extractall(path = os.path.join(LOCAL_DIR_NAME, 'test-1'))
```

In [0]:

```
%matplotlib inline

import matplotlib.pyplot as plt
import seaborn as sns
from matplotlib import rcParams

rcParams['figure.figsize'] = 8, 6

sns.set()
sns.set_palette(sns.color_palette('hls'))

def plot_accuracy(_history,
                  _train_acc_name = 'accuracy',
                  _val_acc_name = 'val_accuracy'):

    plt.plot(_history.history[_train_acc_name])
    plt.plot(_history.history[_val_acc_name])

    plt.title('Model accuracy')

    plt.ylabel('Accuracy')
    plt.xlabel('Epoch')

    plt.legend(['Train', 'Validation'], loc = 'right')

    plt.show()

def plot_loss(_history):

    plt.plot(_history.history['loss'])
    plt.plot(_history.history['val_loss'])

    plt.title('Model loss')

    plt.ylabel('Loss')
    plt.xlabel('Epoch')

    plt.legend(['Train', 'Validation'], loc = 'right')

    plt.show()
```

In [7]:

```
from matplotlib.image import imread

dir_ = 'dogs-vs-cats/train/train'

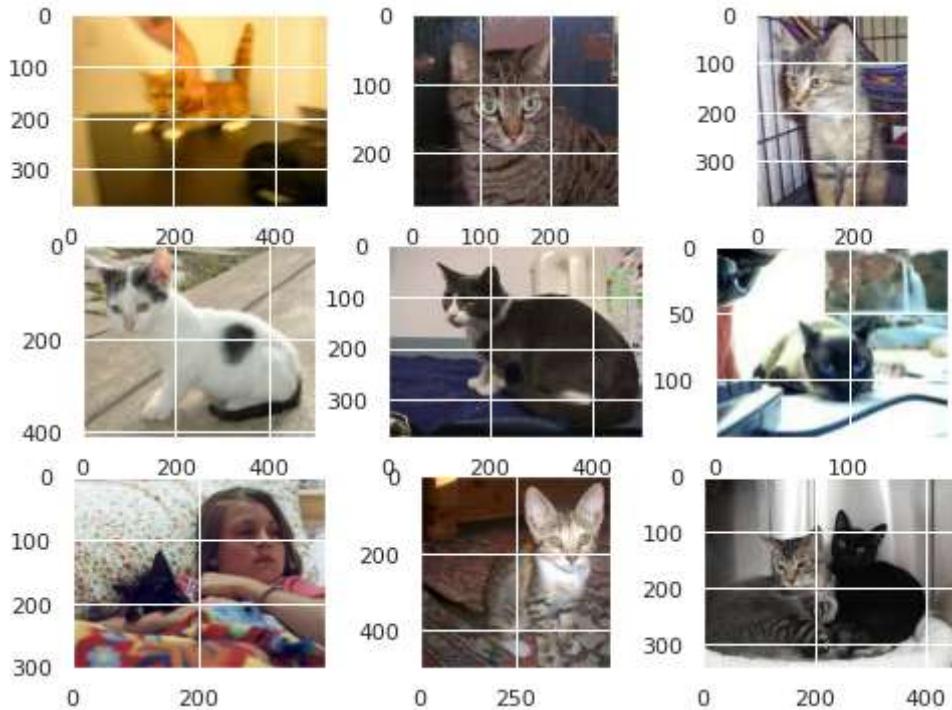
for i in range(9):

    plt.subplot(330 + 1 + i)

    image_ = imread('{}/cat.{}.jpg'.format(dir_, i))

    plt.imshow(image_)

plt.show()
```



Изображения необходимо привести к одному размеру.

In [0]:

```
NEW_IMAGE_WIDTH = 100
```

In [9]:

```
from os import listdir
from os.path import join
from numpy import asarray
from numpy import save
from keras.preprocessing.image import load_img
from keras.preprocessing.image import img_to_array

def dir_to_dataset(_dir_path):

    photos_, labels_ = [], []
    for file_ in listdir(_dir_path):
        if file_.startswith('cat'):
            label_ = 1.0
        else:
            label_ = 0.0
        photo_ = load_img(join(_dir_path, file_), target_size = (NEW_IMAGE_WIDTH, NEW_IMAGE_WIDTH))
        photo_ = img_to_array(photo_)
        photos_.append(photo_)
        labels_.append(label_)

    photos_norm_ = tf.keras.utils.normalize(photos_, axis = 1)
    return asarray(photos_norm_), asarray(labels_)
```

Using TensorFlow backend.

In [0]:

```
! pip install tensorflow-gpu --pre --quiet
```

In [0]:

```
import tensorflow as tf
```

In [0]:

```
import numpy as np
```

In [0]:

```
X_all, y_all = dir_to_dataset('dogs-vs-cats/train/train')
```

In [0]:

```
TEST_LEN_HALF = 1000
```

In [15]:

```
test_interval = np.r_[0:TEST_LEN_HALF, -TEST_LEN_HALF:-0]

X, y = X_all[TEST_LEN_HALF:-TEST_LEN_HALF], y_all[TEST_LEN_HALF:-TEST_LEN_HALF]
X_test, y_test = X_all[test_interval], y_all[test_interval]

print(X.shape, y.shape)
print(X_test.shape, y_test.shape)
```

(23000, 100, 100, 3) (23000,)
(2000, 100, 100, 3) (2000,)

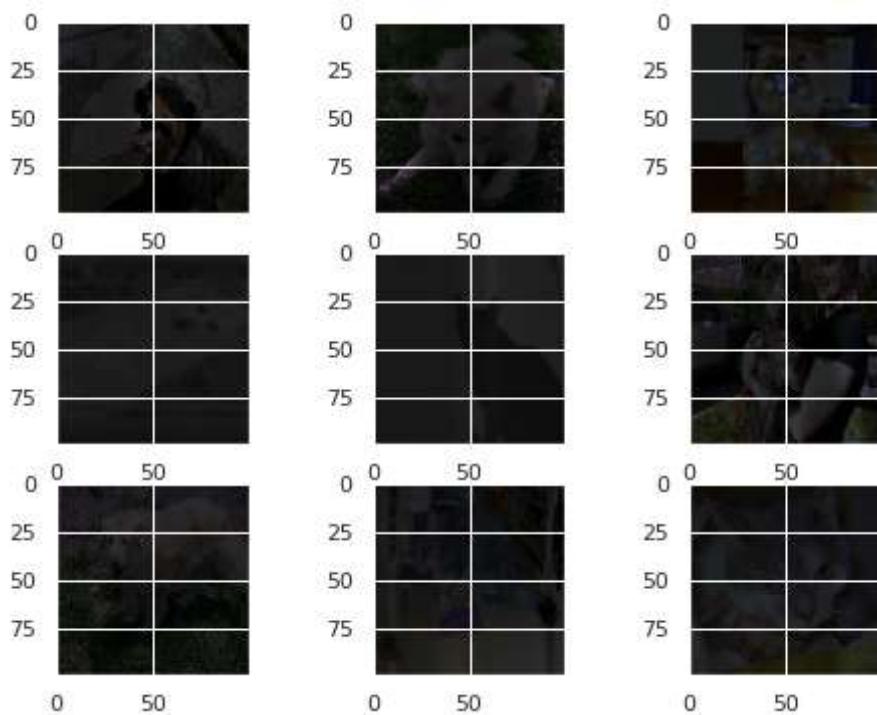
In [16]:

```
for i in range(9):

    plt.subplot(330 + 1 + i)

    plt.imshow(X[i])

plt.show()
```



Выделение валидационной выборки произойдёт автоматически по параметру `validation_split` метода `model.fit()`.

Задание 2

Реализуйте глубокую нейронную сеть с как минимум тремя сверточными слоями. Какое качество классификации получено?

In [0]:

```
from tensorflow import keras
```

In [18]:

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Conv2D, MaxPooling2D, Flatten, Dense

model = tf.keras.Sequential()

model.add(Conv2D(16, 3, padding = 'same', activation = 'relu',
                input_shape = (NEW_IMAGE_WIDTH, NEW_IMAGE_WIDTH, 3)))
model.add(MaxPooling2D())
model.add(Conv2D(32, 3, padding = 'same', activation = 'relu'))
model.add(MaxPooling2D())
model.add(Conv2D(64, 3, padding = 'same', activation = 'relu'))
model.add(MaxPooling2D())
model.add(Flatten())
model.add(Dense(512, activation = 'relu'))
model.add(Dense(1, activation = 'sigmoid'))

model.compile(optimizer = 'sgd',
              loss = 'binary_crossentropy',
              metrics = ['accuracy'])

model.summary()
```

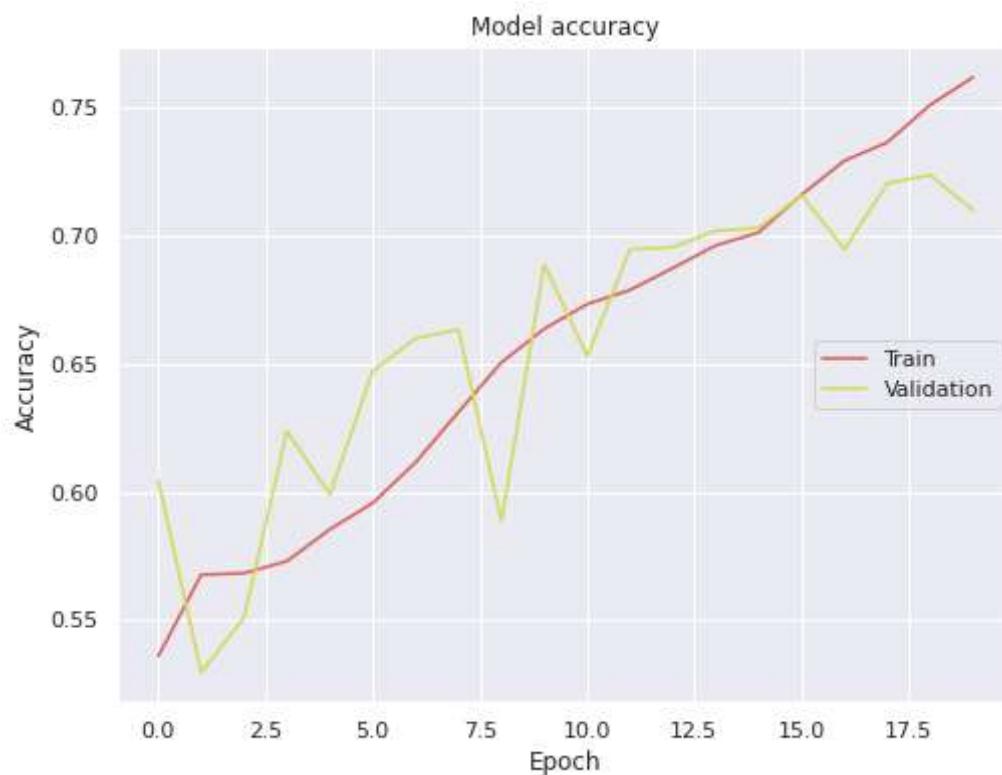
Model: "sequential"

Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 100, 100, 16)	448
max_pooling2d (MaxPooling2D)	(None, 50, 50, 16)	0
conv2d_1 (Conv2D)	(None, 50, 50, 32)	4640
max_pooling2d_1 (MaxPooling2D)	(None, 25, 25, 32)	0
conv2d_2 (Conv2D)	(None, 25, 25, 64)	18496
max_pooling2d_2 (MaxPooling2D)	(None, 12, 12, 64)	0
flatten (Flatten)	(None, 9216)	0
dense (Dense)	(None, 512)	4719104
dense_1 (Dense)	(None, 1)	513
<hr/>		
Total params: 4,743,201		
Trainable params: 4,743,201		
Non-trainable params: 0		

In [0]:

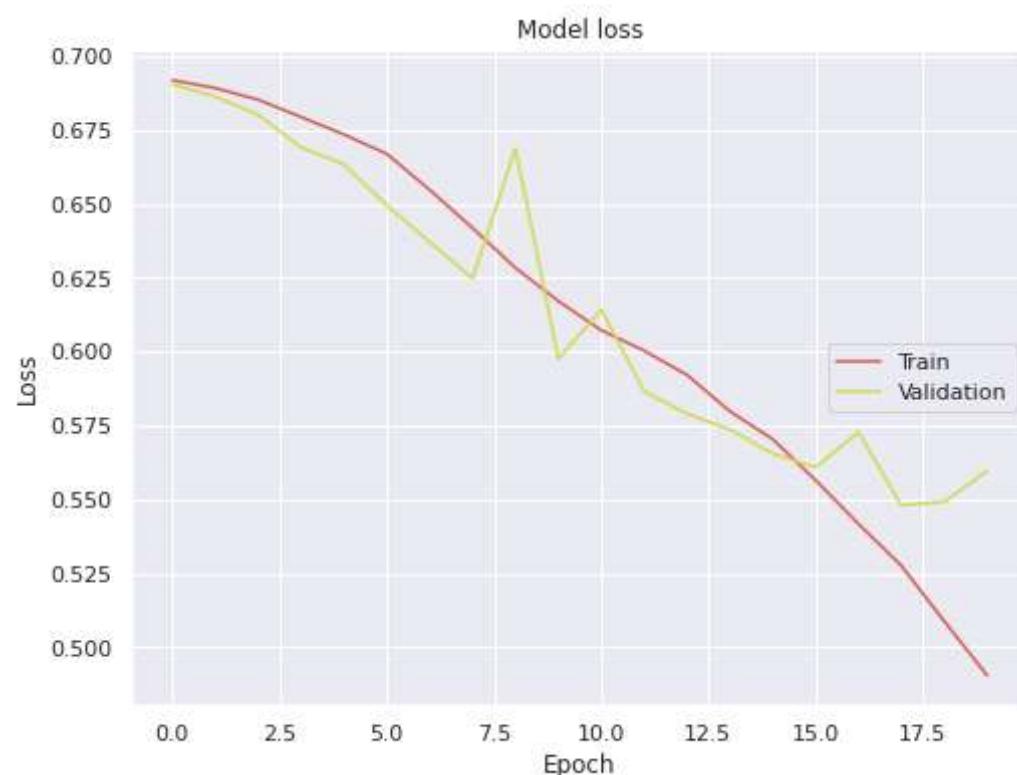
In [20]:

```
plot_accuracy(history)
```



In [21]:

```
plot_loss(history)
```



In [22]:

```
results = model.evaluate(X_test, y_test)
print('Test loss, test accuracy:', results)

63/63 [=====] - 0s 4ms/step - loss: 0.5706 - accuracy: 0.6935
Test loss, test accuracy: [0.5705881118774414, 0.6934999823570251]
```

Результат — 69% на тестовой выборке.

Задание 3

Примените дополнение данных (*data augmentation*). Как это повлияло на качество классификатора?

In [0]:

```
def augment_image(image):
    image = tf.image.convert_image_dtype(image, tf.float32)
    image = tf.image.resize_with_crop_or_pad(image,
                                             NEW_IMAGE_WIDTH + 40,
                                             NEW_IMAGE_WIDTH + 40)
    image = tf.image.random_crop(image,
                                 size = [NEW_IMAGE_WIDTH, NEW_IMAGE_WIDTH, 3])
    return image.numpy()
```

In [24]:

```
X_augmented = np.zeros_like(X)

for i, img in enumerate(X):
    X_augmented[i] = augment_image(img)

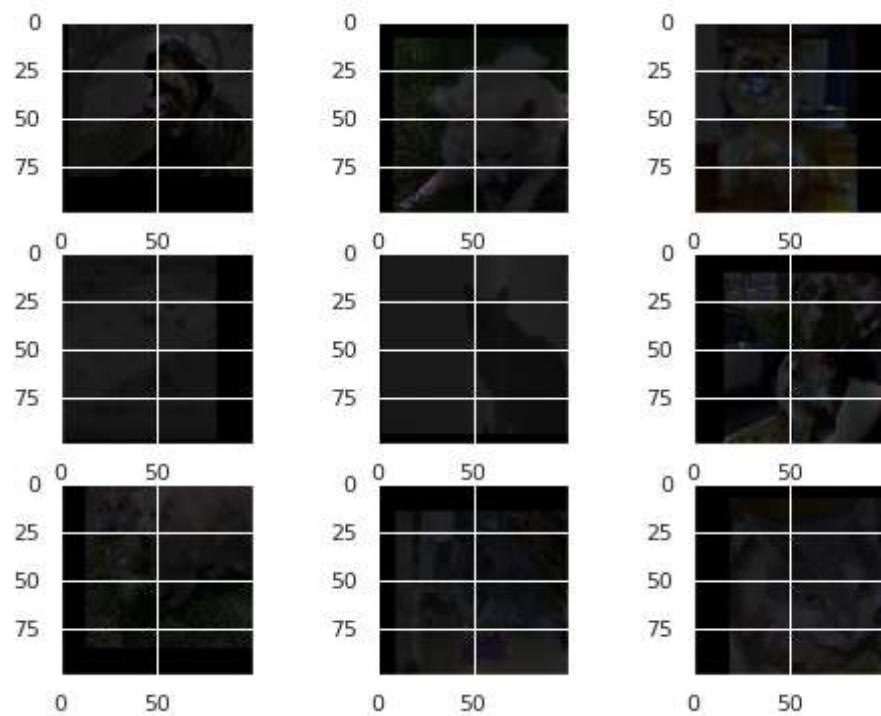
X_augmented.shape
```

Out[24]:

```
(23000, 100, 100, 3)
```

In [25]:

```
for i in range(9):  
    plt.subplot(330 + 1 + i)  
    plt.imshow(X_augmented[i])  
  
plt.show()
```



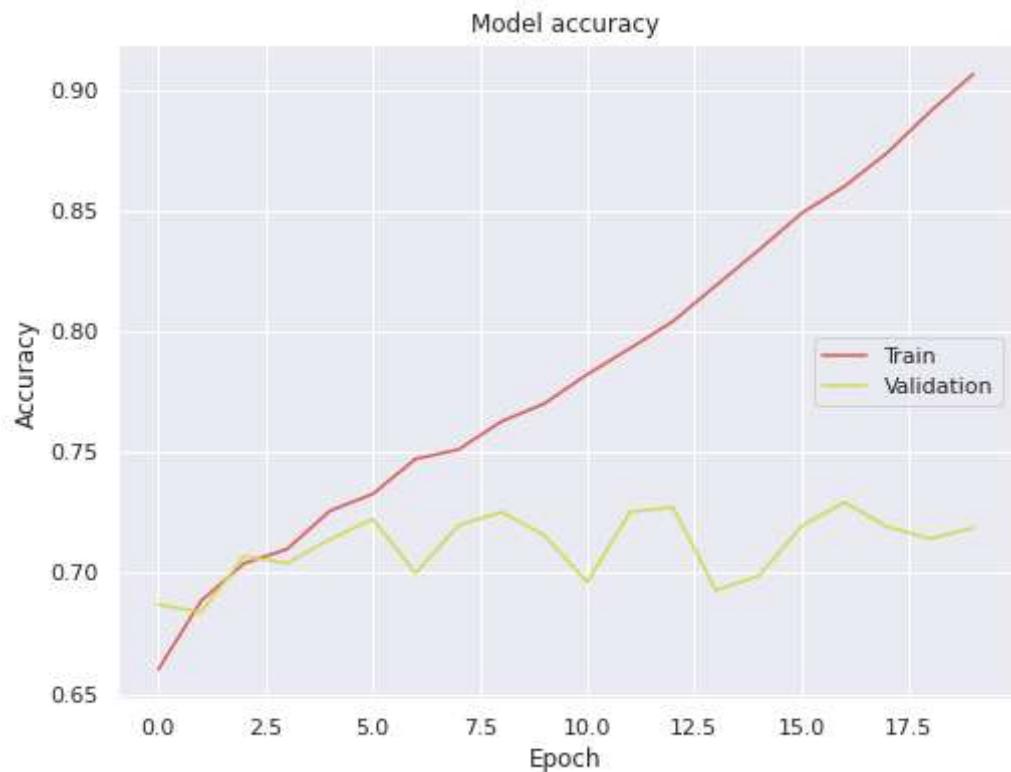
In [0]:

```
y_augmented = y
```

In [0]:

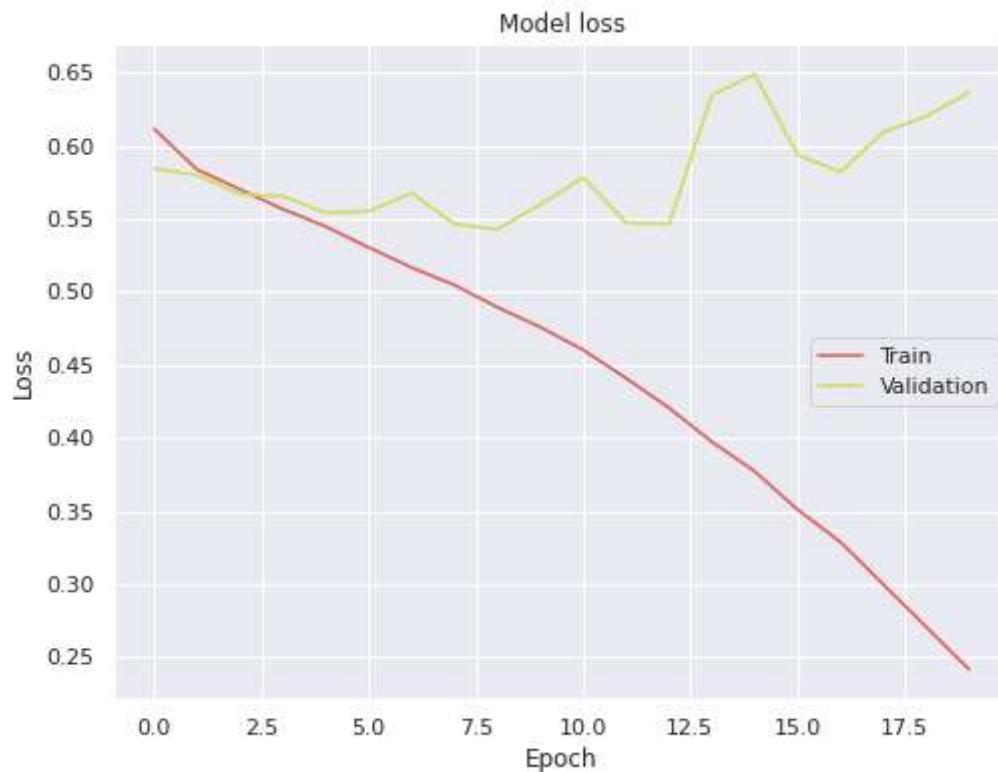
In [28]:

```
plot_accuracy(history_2)
```



In [29]:

```
plot_loss(history_2)
```



In [30]:

```
results_2 = model.evaluate(X_test, y_test)
```

```
print('Test loss, test accuracy:', results_2)
```

```
63/63 [=====] - 0s 4ms/step - loss: 0.6174 - accuracy: 0.7590
Test loss, test accuracy: [0.6173917651176453, 0.7590000033378601]
```

После того, как сеть обучилась на тех же данных, к которым был применён data augmentation, точность предсказания увеличилась — до 75%.

Задание 4

Поэкспериментируйте с готовыми нейронными сетями (например, *AlexNet*, *VGG16*, *Inception* и т.п.), применив передаточное обучение. Как это повлияло на качество классификатора?

Какой максимальный результат удалось получить на сайте *Kaggle*? Почему?

Лабораторная работа №6

Применение сверточных нейронных сетей (многоклассовая классификация)

Набор данных для распознавания языка жестов, который состоит из изображений размерности 28x28 в оттенках серого (значение пикселя от 0 до 255).

Каждое из изображений обозначает букву латинского алфавита, обозначенную с помощью жеста (изображения в наборе данных в оттенках серого).

Обучающая выборка включает в себя 27,455 изображений, а контрольная выборка содержит 7172 изображения.

Данные в виде csv-файлов можно скачать на сайте Kaggle: <https://www.kaggle.com/datamunge/sign-language-mnist> (<https://www.kaggle.com/datamunge/sign-language-mnist>)

Задание 1

Загрузите данные. Разделите исходный набор данных на обучающую и валидационную выборки.

In [0]:

```
import warnings  
warnings.filterwarnings('ignore')
```

In [2]:

```
from google.colab import drive  
drive.mount('/content/drive', force_remount = True)
```

Mounted at /content/drive

In [0]:

```
BASE_DIR = '/content/drive/My Drive/Colab Files/mo-2'  
  
import sys  
  
sys.path.append(BASE_DIR)  
  
import os
```

In [0]:

```
DATA_ARCHIVE_NAME = 'sign-language-mnist.zip'  
  
LOCAL_DIR_NAME = 'sign-language'
```

In [0]:

```
from zipfile import ZipFile

with ZipFile(os.path.join(BASE_DIR, DATA_ARCHIVE_NAME), 'r') as zip_:
    zip_.extractall(path = os.path.join(LOCAL_DIR_NAME, 'train'))
```

In [0]:

```
TRAIN_FILE_PATH = 'sign-language/train/sign_mnist_train.csv'
TEST_FILE_PATH = 'sign-language/train/sign_mnist_test.csv'
```

In [0]:

```
import pandas as pd

train_df = pd.read_csv(TRAIN_FILE_PATH)
test_df = pd.read_csv(TEST_FILE_PATH)
```

In [8]:

```
train_df.shape, test_df.shape
```

Out[8]:

```
((27455, 785), (7172, 785))
```

In [0]:

```
IMAGE_DIM = 28
```

In [0]:

```
def row_to_label(_row):
    return _row[0]

def row_to_one_image(_row):
    return _row[1:].values.reshape((IMAGE_DIM, IMAGE_DIM, 1))
```

In [0]:

```
def to_images_and_labels(_dataframe):

    llll = _dataframe.apply(lambda row: row_to_label(row), axis = 1)
    mmmm = _dataframe.apply(lambda row: row_to_one_image(row), axis = 1)

    data_dict_ = { 'label': llll, 'image': mmmm }

    reshaped_ = pd.DataFrame(data_dict_, columns = ['label', 'image'])

    return reshaped_
```

In [0]:

```
train_df_reshaped = to_images_and_labels(train_df)
test_df_reshaped = to_images_and_labels(test_df)
```

Задание 2

Реализуйте глубокую нейронную сеть со сверточными слоями. Какое качество классификации получено? Какая архитектура сети была использована?

Возьмём *LeNet-5*.

In [0]:

```
! pip install tensorflow-gpu --pre --quiet
```

In [0]:

```
import tensorflow as tf
```

In [0]:

```
from tensorflow.keras.utils import to_categorical
import numpy as np

X_train = tf.keras.utils.normalize(np.asarray(list(train_df_reshaped['image'])),
                                   axis = 1)
X_test = tf.keras.utils.normalize(np.asarray(list(test_df_reshaped['image'])),
                                   axis = 1)

y_train = to_categorical(train_df_reshaped['label']
                        .astype('category').cat.codes.astype('int32'))
y_test = to_categorical(test_df_reshaped['label']
                        .astype('category').cat.codes.astype('int32'))
```

In [16]:

```
X_train.shape, y_train.shape, X_test.shape, y_test.shape
```

Out[16]:

```
((27455, 28, 28, 1), (27455, 24), (7172, 28, 28, 1), (7172, 24))
```

In [0]:

```
CLASSES_N = y_train.shape[1]
```

In [0]:

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import AveragePooling2D, Conv2D, Dense, Flatten

model = tf.keras.Sequential()

model.add(Conv2D(6, kernel_size = (5, 5), strides = (1, 1),
                activation = 'tanh', padding = 'same',
                input_shape = (IMAGE_DIM, IMAGE_DIM, 1)))
model.add(AveragePooling2D(pool_size = (2, 2), strides = (2, 2),
                           padding = 'valid'))
model.add(Conv2D(16, kernel_size = (5, 5), strides = (1, 1),
                 activation = 'tanh', padding = 'valid'))
model.add(AveragePooling2D(pool_size = (2, 2), strides = (2, 2),
                           padding = 'valid'))
model.add(Flatten())
model.add(Dense(120, activation = 'tanh'))
model.add(Dense(84, activation = 'tanh'))
model.add(Dense(CLASSES_N, activation = 'softmax'))
```

In [0]:

```
model.compile(optimizer = 'adam',
              loss = 'categorical_crossentropy',
              metrics = ['categorical_accuracy'])
```

In [20]:

```
model.summary()
```

Model: "sequential"

Layer (type)	Output Shape	Param #
=====		
conv2d (Conv2D)	(None, 28, 28, 6)	156
=====		
average_pooling2d (AveragePo	(None, 14, 14, 6)	0
=====		
conv2d_1 (Conv2D)	(None, 10, 10, 16)	2416
=====		
average_pooling2d_1 (Average	(None, 5, 5, 16)	0
=====		
flatten (Flatten)	(None, 400)	0
=====		
dense (Dense)	(None, 120)	48120
=====		
dense_1 (Dense)	(None, 84)	10164
=====		
dense_2 (Dense)	(None, 24)	2040
=====		
Total params: 62,896		
Trainable params: 62,896		
Non-trainable params: 0		

In [0]:

```
history = model.fit(x = X_train, y = y_train, epochs = 20,
                     validation_split = 0.15, verbose = 0)
```

In [0]:

```
%matplotlib inline

import matplotlib.pyplot as plt
import seaborn as sns
from matplotlib import rcParams

rcParams['figure.figsize'] = 8, 6

sns.set()
sns.set_palette(sns.color_palette('hls'))

def plot_accuracy(_history,
                  _train_acc_name = 'accuracy',
                  _val_acc_name = 'val_accuracy'):

    plt.plot(_history.history[_train_acc_name])
    plt.plot(_history.history[_val_acc_name])

    plt.title('Model accuracy')

    plt.ylabel('Accuracy')
    plt.xlabel('Epoch')

    plt.legend(['Train', 'Validation'], loc = 'right')

    plt.show()

def plot_loss(_history):

    plt.plot(_history.history['loss'])
    plt.plot(_history.history['val_loss'])

    plt.title('Model loss')

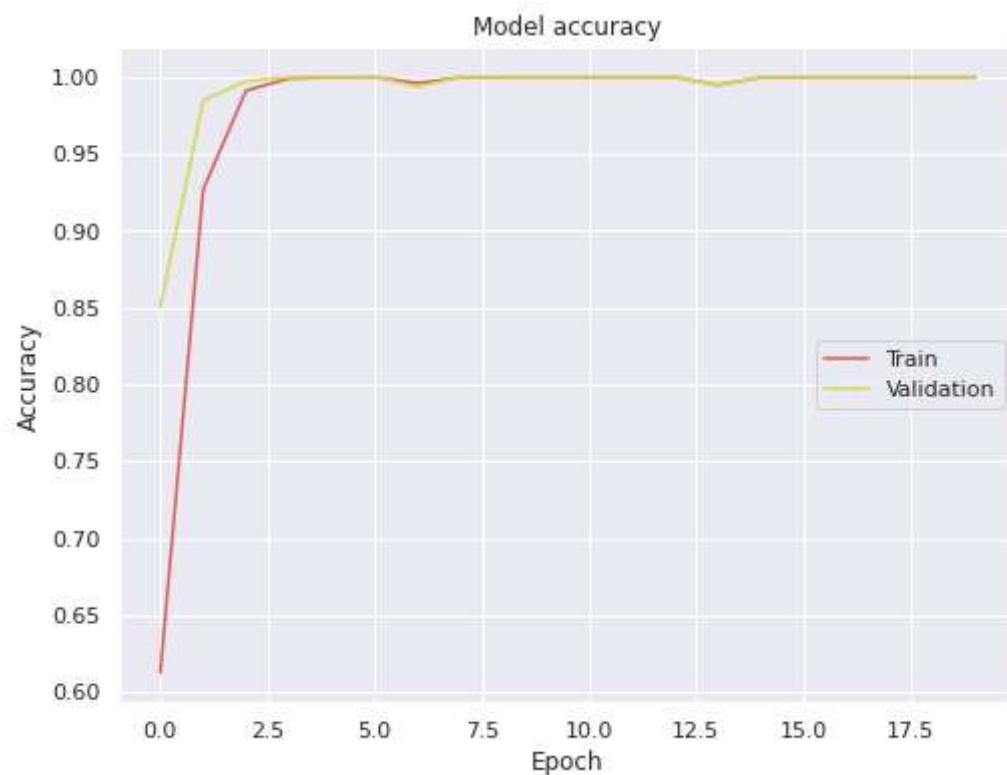
    plt.ylabel('Loss')
    plt.xlabel('Epoch')

    plt.legend(['Train', 'Validation'], loc = 'right')

    plt.show()
```

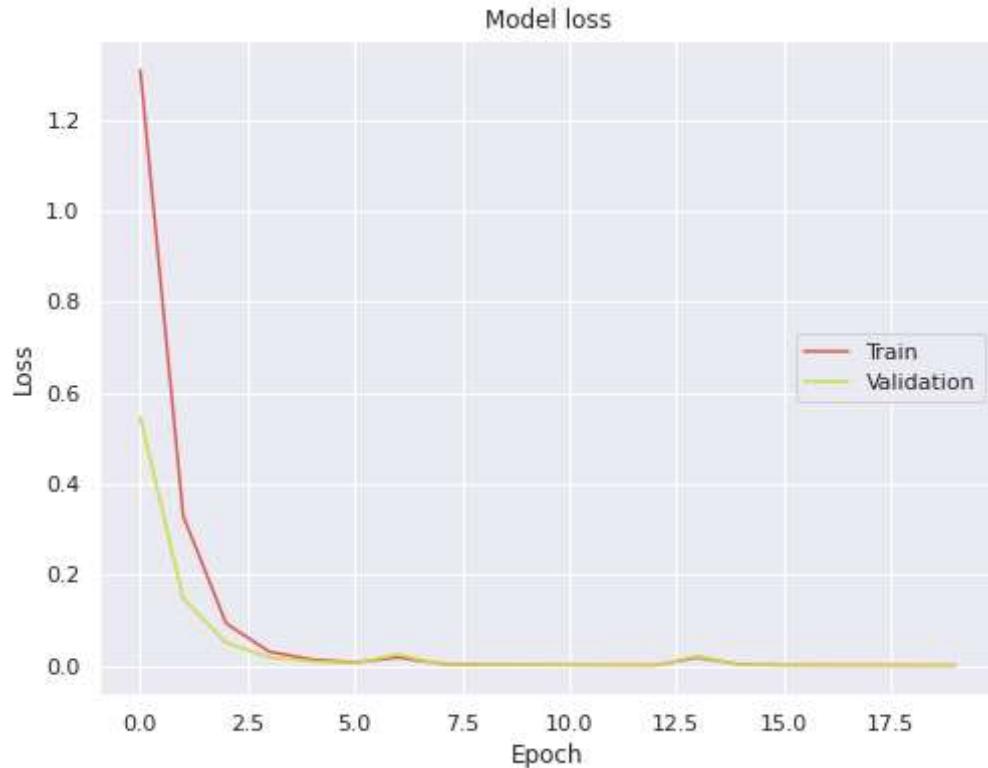
In [23]:

```
plot_accuracy(history, 'categorical_accuracy', 'val_categorical_accuracy')
```



In [24]:

```
plot_loss(history)
```



In [25]:

```
results = model.evaluate(X_test, y_test)  
print('Test loss, test accuracy:', results)
```

```
225/225 [=====] - 1s 2ms/step - loss: 0.7977 - categorical_accuracy: 0.8358  
Test loss, test accuracy: [0.7976991534233093, 0.835750162601471]
```

За 20 эпох удалось достичь точности 83% на тестовой выборке.

Задание 3

Примените дополнение данных (*data augmentation*). Как это повлияло на качество классификатора?

In [0]:

```
def augment_image(image):

    image = tf.image.convert_image_dtype(image, tf.float32)
    image = tf.image.resize_with_crop_or_pad(image, IMAGE_DIM + 6, IMAGE_DIM + 6)
    image = tf.image.random_crop(image, size = [IMAGE_DIM, IMAGE_DIM, 3])

return image.numpy()
```

In [27]:

```
X_train_augmented = np.zeros_like(X_train)
```

```
for i, img in enumerate(X_train):  
    X_train_augmented[i] = augment_image(img)  
  
X_train_augmented.shape
```

Out[27]:

(27455, 28, 28, 1)

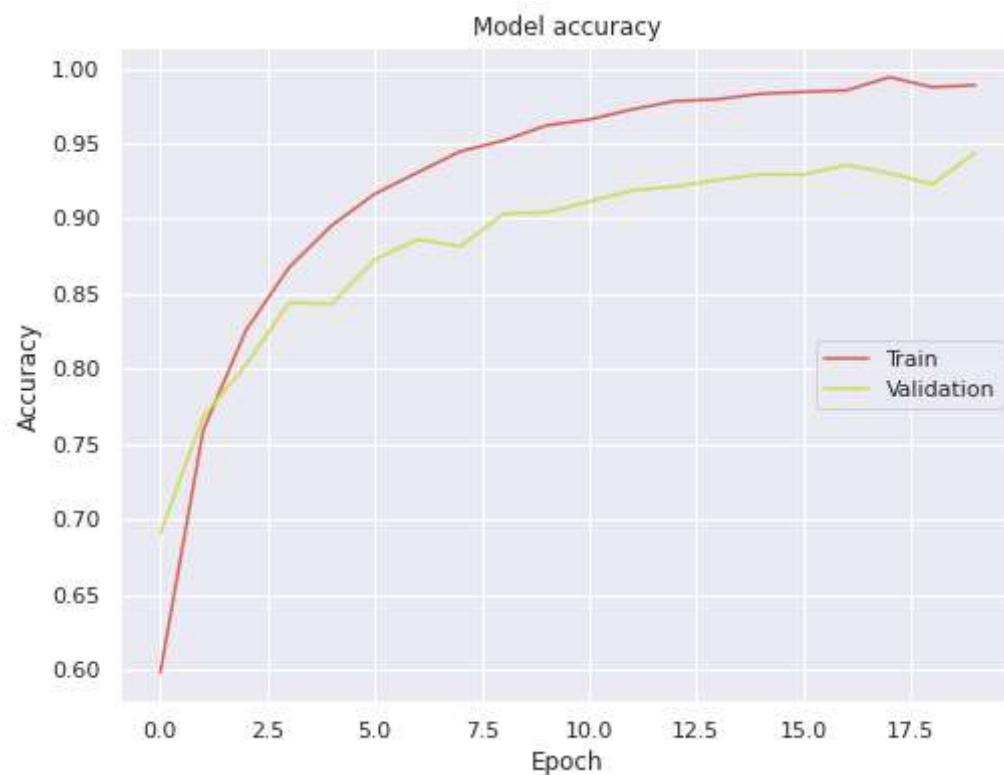
In [0]:

```
y_train_augmented = y_train
```

In [0]:

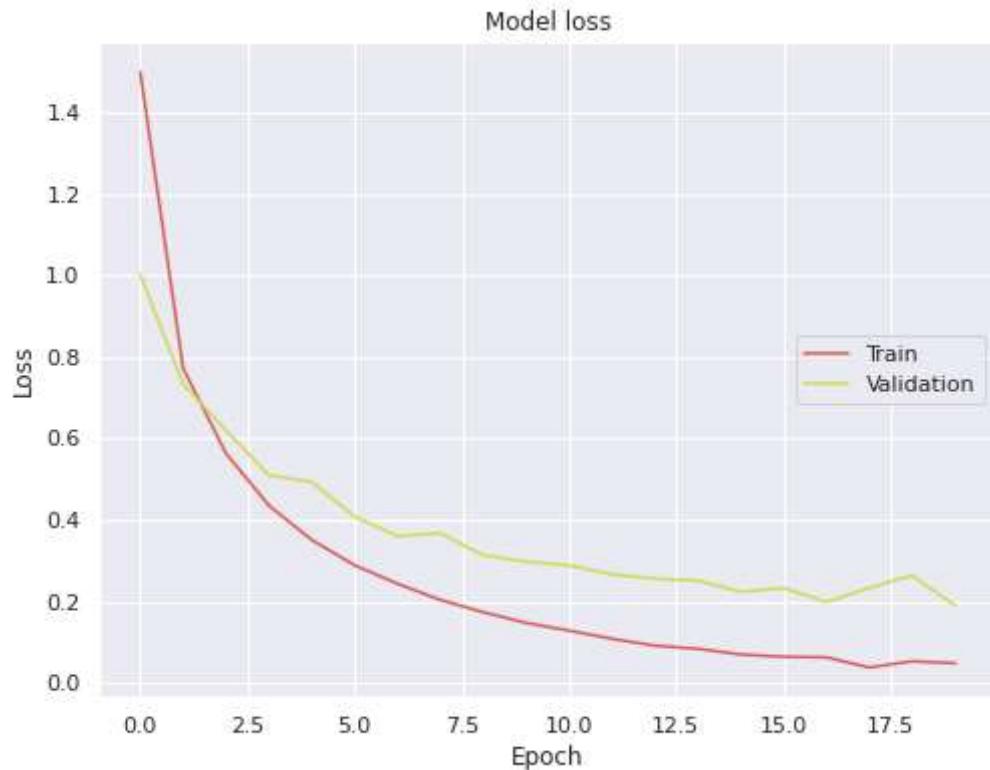
In [30]:

```
plot_accuracy(history_2, 'categorical_accuracy', 'val_categorical_accuracy')
```



In [31]:

```
plot_loss(history_2)
```



In [32]:

```
results_2 = model.evaluate(X_test, y_test)
```

```
print('Test loss, test accuracy:', results_2)
```

```
225/225 [=====] - 1s 2ms/step - loss: 0.3523 - categorical_accuracy: 0.9131
Test loss, test accuracy: [0.3523258864879608, 0.9131343960762024]
```

После того, как сеть обучилась на тех же данных, к которым был применён *data augmentation*, точность предсказания на тестовой выборке увеличилась до 91%.

Задание 4

Поэкспериментируйте с готовыми нейронными сетями (например, *AlexNet*, *VGG16*, *Inception* и т.п.), применив передаточное обучение. Как это повлияло на качество классификатора? Можно ли было обойтись без него?

Какой максимальный результат удалось получить на контрольной выборке?

Лабораторная работа №7

Рекуррентные нейронные сети для анализа текста

Набор данных для предсказания оценок для отзывов, собранных с сайта *imdb.com*, который состоит из 50,000 отзывов в виде текстовых файлов.

Отзывы разделены на положительные (25,000) и отрицательные (25,000).

Данные предварительно токенизированы по принципу «мешка слов», индексы слов можно взять из словаря (*imdb.vocab*).

Обучающая выборка включает в себя 12,500 положительных и 12,500 отрицательных отзывов, контрольная выборка также содержит 12,500 положительных и 12,500 отрицательных отзывов.

Данные можно скачать на сайте Kaggle: <https://www.kaggle.com/iarunava/imdb-movie-reviews-dataset> (<https://www.kaggle.com/iarunava/imdb-movie-reviews-dataset>) <https://ai.stanford.edu/~amaas/data/sentiment/> (<https://ai.stanford.edu/~amaas/data/sentiment/>)

Задание 1

Загрузите данные. Преобразуйте текстовые файлы во внутренние структуры данных, которые используют индексы вместо слов.

Будем брать первые MAX_LENGTH слов, а если в отзыве слов меньше, чем это число, то применять паддинг.

In [0]:

```
import warnings  
  
warnings.filterwarnings('ignore')
```

In [0]:

```
from google.colab import drive  
  
drive.mount('/content/drive', force_remount = True)
```

Mounted at /content/drive

In [0]:

```
BASE_DIR = '/content/drive/My Drive/Colab Files/mo-2'  
  
import sys  
  
sys.path.append(BASE_DIR)  
  
import os
```

In [0]:

```
DATA_ARCHIVE_NAME = 'imdb-dataset-of-50k-movie-reviews.zip'
```

```
LOCAL_DIR_NAME = 'imdb-sentiments'
```

In [0]:

```
from zipfile import ZipFile

with ZipFile(os.path.join(BASE_DIR, DATA_ARCHIVE_NAME), 'r') as zip_:
    zip_.extractall(LOCAL_DIR_NAME)
```

In [0]:

```
DATA_FILE_PATH = 'imdb-sentiments/IMDB Dataset.csv'
```

In [0]:

```
import pandas as pd

all_df = pd.read_csv(DATA_FILE_PATH)
```

In [0]:

```
df_test = all_df.sample(frac = 0.1)

df_train = all_df.drop(df_test.index)
```

In [0]:

```
df_train.shape, df_test.shape
```

Out[9]:

```
((45000, 2), (5000, 2))
```

In [0]:

```
import nltk

nltk.download('punkt')
```

```
[nltk_data] Downloading package punkt to /root/nltk_data...
[nltk_data]   Package punkt is already up-to-date!
```

Out[10]:

```
True
```

In [0]:

```
MAX_LENGTH = 40
STRING_DTYPE = '<U12'
PADDING_TOKEN = 'PAD'
LIMIT_OF_TOKENS = 100000
```

In [0]:

```
from nltk import word_tokenize
import numpy as np
import string
import re

def tokenize_string(_string):
    return [tok_.lower() for tok_ in word_tokenize(_string)
            if not re.fullmatch('[' + string.punctuation + ']+', tok_)]

def pad(A, length):
    arr = np.empty(length, dtype = STRING_DTYPE)
    arr.fill(PADDING_TOKEN)
    arr[:len(A)] = A
    return arr

def tokenize_row(_sentence):
    return pad(tokenize_string(_sentence)[:MAX_LENGTH], MAX_LENGTH)

def encode_row(_label):
    return 1 if _label == 'positive' else 0

def encode_and_tokenize(_dataframe):

    tttt = _dataframe.apply(lambda row: tokenize_row(row['review']), axis = 1)
    llll = _dataframe.apply(lambda row: encode_row(row['sentiment']), axis = 1)

    data_dict_ = { 'label': llll, 'tokens': tttt }

    encoded_and_tokenized_ = pd.DataFrame(data_dict_,
                                           columns = [ 'label', 'tokens' ])

    return encoded_and_tokenized_
```

In [0]:

```
df_train_tokenized = encode_and_tokenize(df_train)
df_test_tokenized = encode_and_tokenize(df_test)
```

In [0]:

```
from collections import Counter

def get_tokens_list(_dataframe):

    all_tokens_ = []

    for sent_ in _dataframe['tokens'].values:
        all_tokens_.extend(sent_)

    tokens_counter_ = Counter(all_tokens_)

    return [t for t, _ in tokens_counter_.most_common(LIMIT_OF_TOKENS)]
```

In [0]:

```
tokens_list = get_tokens_list(pd.concat([df_train_tokenized,
                                         df_test_tokenized]))
```

In [0]:

```
word_to_int_dict = {}

word_to_int_dict.update(
    {t : i for i, t in enumerate(tokens_list)})
```

In [0]:

```
def intize_row(_tokens):
    return np.array([word_to_int_dict[t]
                    if t in word_to_int_dict
                    else 0
                    for t in _tokens])

def encode_and_tokenize(_dataframe):

    iii = _dataframe.apply(lambda row: intize_row(row['tokens']), axis = 1)

    data_dict_ = { 'label': _dataframe['label'], 'ints': iii }

    intized_ = pd.DataFrame(data_dict_, columns = ['label', 'ints'])

    return intized_
```

In [0]:

```
df_train_intized = encode_and_tokenize(df_train_tokenized)
df_test_intized = encode_and_tokenize(df_test_tokenized)
```

Задание 2

Реализуйте и обучите двунаправленную рекуррентную сеть (*LSTM* или *GRU*).

Какого качества классификации удалось достичь?

In [0]:

```
! pip install tensorflow-gpu --pre --quiet
```

In [0]:

```
import tensorflow as tf

tf.compat.v1.logging.set_verbosity(tf.compat.v1.logging.ERROR)

from tensorflow import keras
```

In [0]:

```
# To fix memory Leak: https://github.com/tensorflow/tensorflow/issues/33009

tf.compat.v1.disable_eager_execution()
```

Здесь будем использовать такую конфигурацию рекуррентного *LSTM*-слоя, которая позволит использовать очень быструю *cuDNN* имплементацию.

In [0]:

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Bidirectional, LSTM, Dense

# The requirements to use the cuDNN implementation are:
# 1. `activation` == `tanh`
# 2. `recurrent_activation` == `sigmoid`
# 3. `recurrent_dropout` == 0
# 4. `unroll` is `False`
# 5. `use_bias` is `True`
# 6. `reset_after` is `True`
# 7. Inputs, if use masking, are strictly right-padded.

model = tf.keras.Sequential()

model.add(Bidirectional(LSTM(100, return_sequences = False),
                       merge_mode = 'concat', input_shape = (MAX_LENGTH, 1)))
model.add(Dense(1, activation = 'sigmoid'))
```

In [0]:

```
model.compile(optimizer = 'adam',
              loss = 'binary_crossentropy',
              metrics = ['accuracy']))
```

```
model.summary()
```

Model: "sequential"

Layer (type)	Output Shape	Param #
bidirectional (Bidirectional (None, 200))		81600
dense (Dense)	(None, 1)	201
<hr/>		
Total params: 81,801		
Trainable params: 81,801		
Non-trainable params: 0		

In [0]:

```
X_train_intized = np.asarray(list(df_train_intized['ints'].values),
                           dtype = float)[..., np.newaxis]
X_test_intized = np.asarray(list(df_test_intized['ints'].values),
                           dtype = float)[..., np.newaxis]

y_train_intized = np.asarray(list(df_train_intized['label'].values))
y_test_intized = np.asarray(list(df_test_intized['label'].values))
```

In [0]:

In [0]:

```
%matplotlib inline

import matplotlib.pyplot as plt
import seaborn as sns
from matplotlib import rcParams

rcParams['figure.figsize'] = 8, 6

sns.set()
sns.set_palette(sns.color_palette('hls'))

def plot_accuracy(_history,
                  _train_acc_name = 'accuracy',
                  _val_acc_name = 'val_accuracy'):

    plt.plot(_history.history[_train_acc_name])
    plt.plot(_history.history[_val_acc_name])

    plt.title('Model accuracy')

    plt.ylabel('Accuracy')
    plt.xlabel('Epoch')

    plt.legend(['Train', 'Validation'], loc = 'right')

    plt.show()

def plot_loss(_history):

    plt.plot(_history.history['loss'])
    plt.plot(_history.history['val_loss'])

    plt.title('Model loss')

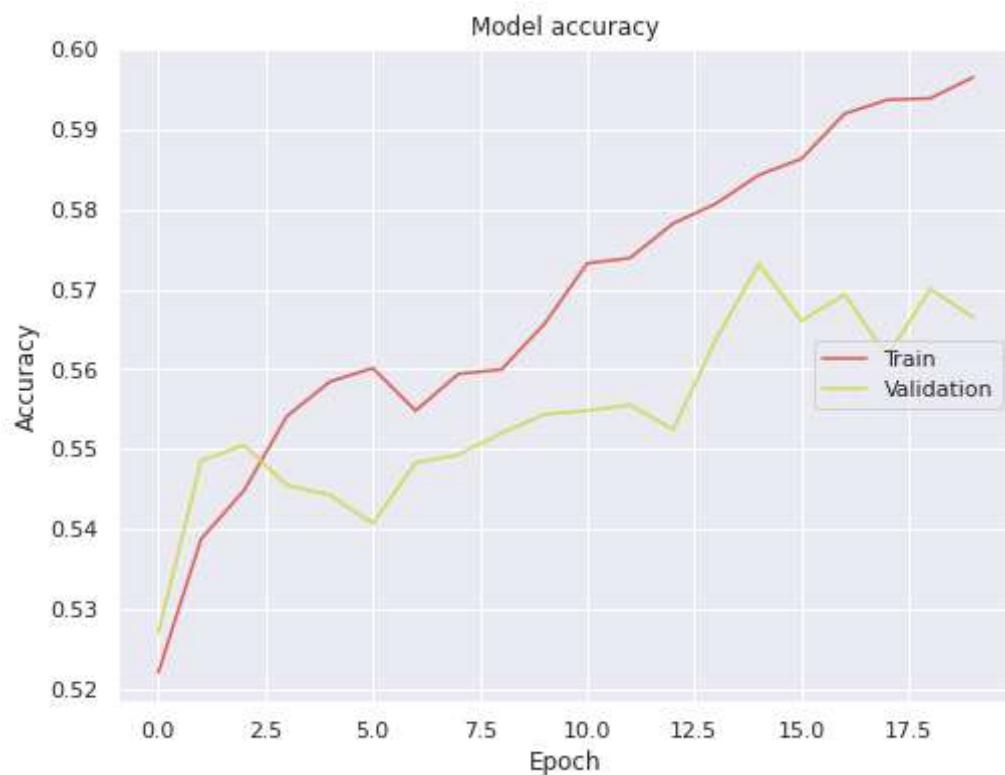
    plt.ylabel('Loss')
    plt.xlabel('Epoch')

    plt.legend(['Train', 'Validation'], loc = 'right')

    plt.show()
```

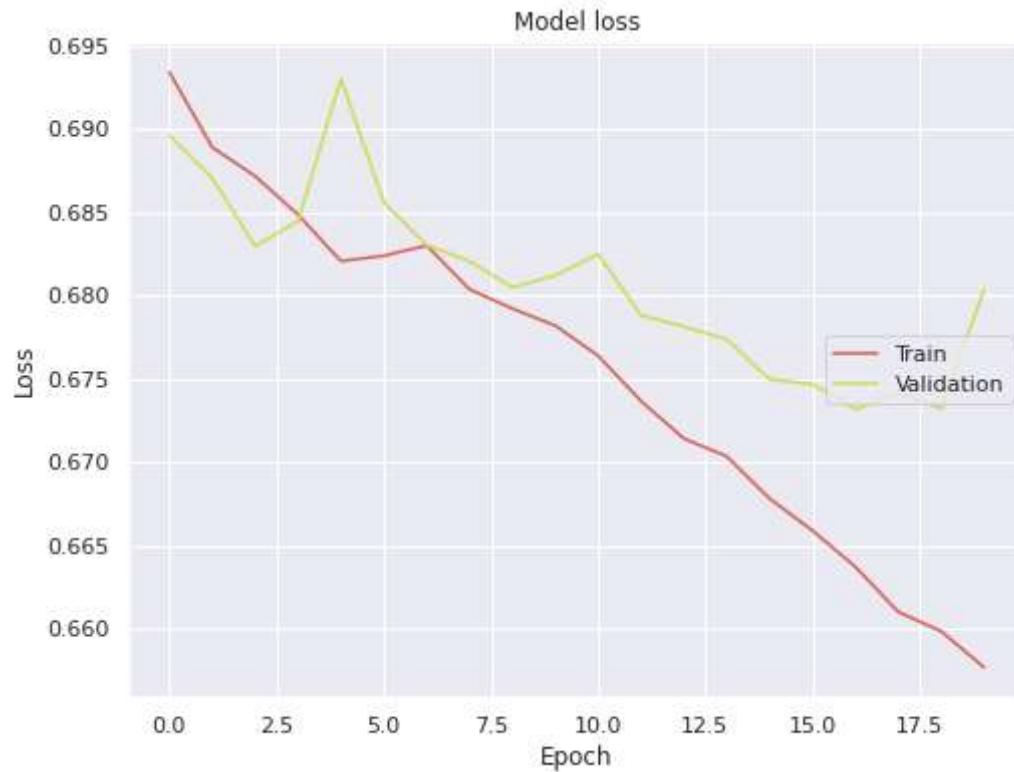
In [0]:

```
plot_accuracy(history)
```



In [0]:

```
plot_loss(history)
```



In [0]:

```
results = model.evaluate(X_test_intized, y_test_intized)
print('Test loss, test accuracy:', results)
```

Test loss, test accuracy: [0.6782044233322143, 0.571]

На валидационной выборке удалось достичь точности 57%.

Задание 3

Используйте индексы слов и их различное внутреннее представление (*word2vec*, *glove*). Как влияет данное преобразование на качество классификации?

Используем 300-мерные вектора *FastText* — лучшую на сегодняшний день имплементацию word2vec:
<https://fasttext.cc/docs/en/english-vectors.html> (<https://fasttext.cc/docs/en/english-vectors.html>). Файл пришлось доработать — 9-я строка не читалась.

In [0]:

```
# VECTORS_ARCHIVE_NAME = 'wiki-news-300d-1M-fixed.zip'  
  
# VECTORS_FILE_NAME = 'wiki-news-300d-1M-fixed.vec'  
  
# VECTORS_LOCAL_DIR_NAME = 'vectors'
```

In [0]:

```
# with ZipFile(os.path.join(BASE_DIR, VECTORS_ARCHIVE_NAME), 'r') as zip_:  
#     zip_.extractall(VECTORS_LOCAL_DIR_NAME)
```

Создадим уменьшенный словарь, содержащий только встреченные токены, чтобы уменьшить нагрузку на Google Drive:

In [0]:

```
# def build_vectors_dict(_actual_tokens, _vectors_file_path,  
#                         _unknown_token = 'unknown'):  
  
#     vec_data_ = pd.read_csv(_vectors_file_path, sep = ' ',  
#                            header = None, skiprows = [9])  
  
#     actual_vectors_ = [x for x in vec_data_.values  
#                        if x[0] in _actual_tokens or x[0] == _unknown_token]  
  
#     return actual_vectors_
```

In [0]:

```
# actual_vectors = build_vectors_dict(tokens_list,  
#                                       os.path.join(VECTORS_LOCAL_DIR_NAME,  
#                                                   VECTORS_FILE_NAME))
```

In [0]:

```
# vectors_np = np.array(actual_vectors)  
  
# vectors_dict = dict(zip(vectors_np[:, 0], vectors_np[:, 1:]))  
  
# vectors_dict_file_name = 'word-vec-dict-{}-items'.format(len(vectors_dict))  
  
# vectors_dict_file_path = os.path.join(BASE_DIR, vectors_dict_file_name)  
  
# np.savez_compressed(vectors_dict_file_path, vectors_dict, allow_pickle = True)
```

In [0]:

```
vectors_dict_file_path = (  
    './drive/My Drive/Colab Files/mo-2/word-vec-dict-56485-items.npz')
```

In [0]:

```
vectors_dict_data = np.load(vectors_dict_file_path, allow_pickle = True)
vectors_dict = vectors_dict_data['arr_0'][()]
```

In [0]:

```
VECTORS_LENGTH = 300
```

In [0]:

```
def tokens_to_vectors(_word_to_vec_dict, _tokens, _unknown_token):
    return [_word_to_vec_dict[t]
            if t in _word_to_vec_dict
            else _word_to_vec_dict[_unknown_token]
            for t in _tokens]

def row_to_vectors(_tokens):
    return np.array(tokens_to_vectors(vectors_dict, _tokens, 'unknown'))

def vectorize(_dataframe):
    vvvv = _dataframe.apply(lambda row: row_to_vectors(row['tokens']), axis = 1)
    data_dict_ = { 'label': _dataframe['label'], 'vectors': vvvv }
    vectorized_ = pd.DataFrame(data_dict_, columns = ['label', 'vectors'])

    return vectorized_
```

In [0]:

```
df_train_vectorized = vectorize(df_train_tokenized)
df_test_vectorized = vectorize(df_test_tokenized)
```

In [0]:

```
X_train_vectorized = np.asarray(list(df_train_vectorized['vectors'].values),
                                 dtype = float)
X_test_vectorized = np.asarray(list(df_test_vectorized['vectors'].values),
                               dtype = float)

y_train_vectorized = np.asarray(list(df_train_vectorized['label'].values))
y_test_vectorized = np.asarray(list(df_test_vectorized['label'].values))
```

In [0]:

```
model_2 = tf.keras.Sequential()

model_2.add(Bidirectional(LSTM(100, return_sequences = False),
                         merge_mode = 'concat',
                         input_shape = (MAX_LENGTH, VECTORS_LENGTH)))
model_2.add(Dense(1, activation = 'sigmoid'))
```

In [0]:

```
model_2.compile(optimizer = 'adam',
                 loss = 'binary_crossentropy',
                 metrics = ['accuracy'])

model_2.summary()
```

Model: "sequential_1"

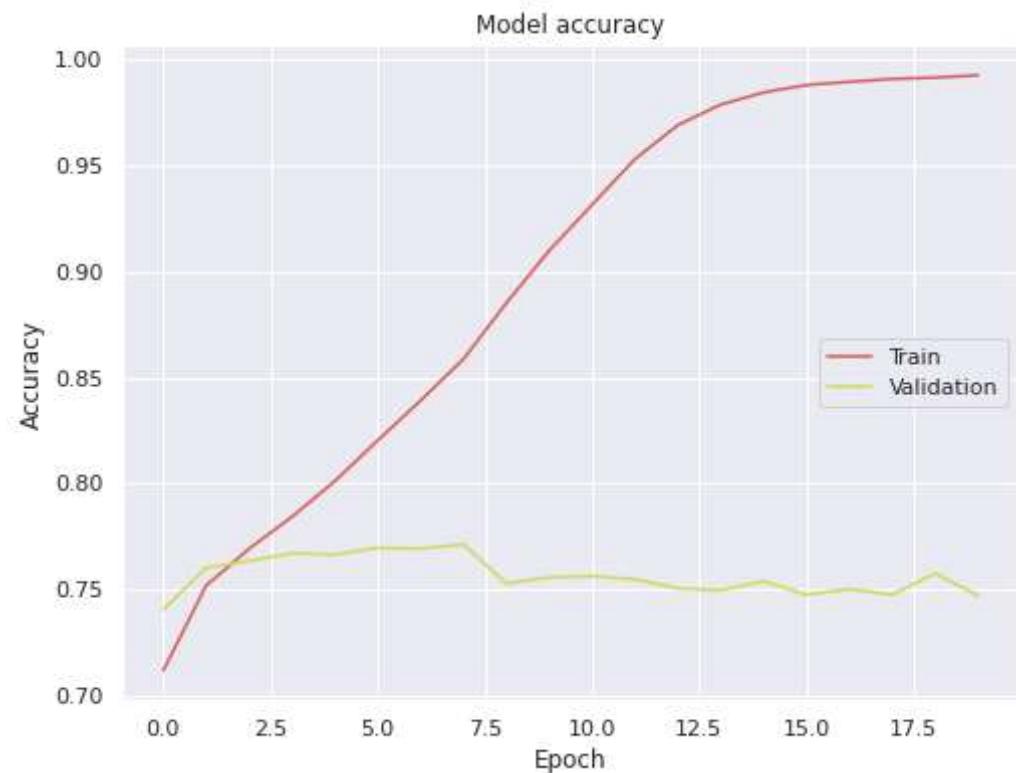
Layer (type)	Output Shape	Param #
bidirectional_1 (Bidirection (None, 200)		320800
dense_1 (Dense)	(None, 1)	201
Total params:	321,001	
Trainable params:	321,001	
Non-trainable params:	0	

In [0]:

```
history_2 = model_2.fit(x = X_train_vectorized, y = y_train_vectorized,
                         epochs = 20, validation_split = 0.15, verbose = 0)
```

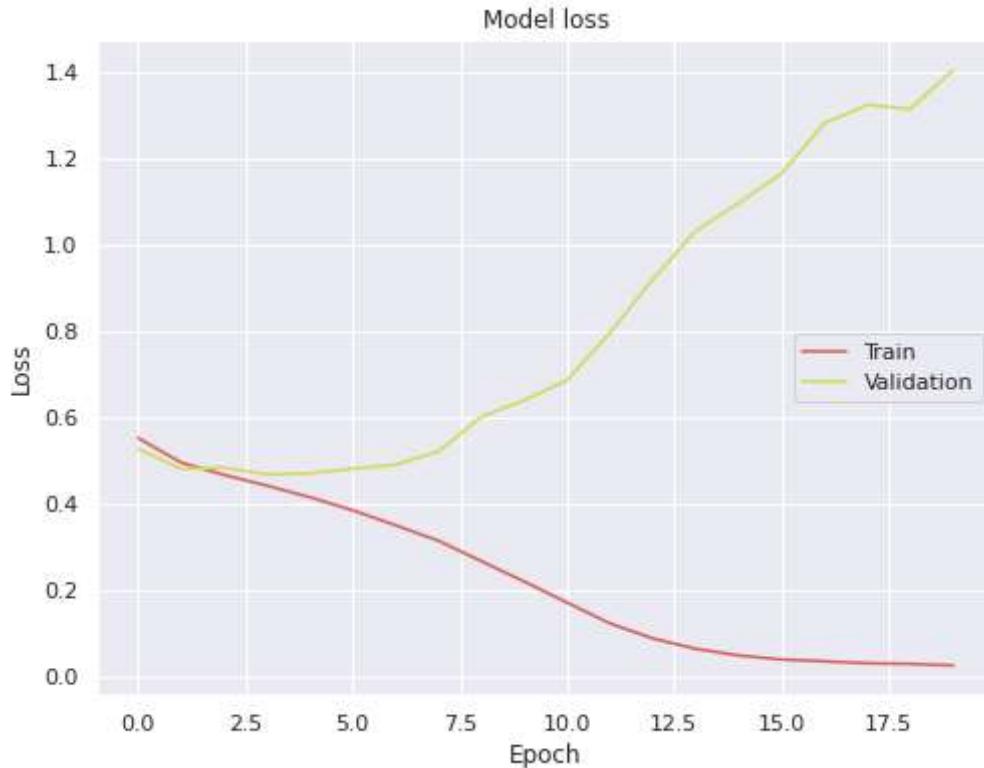
In [44]:

```
plot_accuracy(history_2)
```



In [45]:

```
plot_loss(history_2)
```



In [46]:

```
results_2 = model_2.evaluate(X_test_vectorized, y_test_vectorized)  
print('Test loss, test accuracy:', results_2)
```

Test loss, test accuracy: [1.384592835521698, 0.7472]

Как и ожидалось, использование эмбеддингов показало лучший результат, чем кодирование слов просто целыми числами — 74%.

Задание 4

Поэкспериментируйте со структурой сети (добавьте больше рекуррентных, полно связных или сверточных слоев). Как это повлияло на качество классификации?

In [0]:

```
model_3 = tf.keras.Sequential()

model_3.add(Bidirectional(LSTM(5, return_sequences = True),
                         merge_mode = 'concat',
                         input_shape = (MAX_LENGTH, VECTORS_LENGTH)))
model_3.add(LSTM(1, return_sequences = False))
model_3.add(Dense(10, activation = 'linear'))
model_3.add(Dense(1, activation = 'sigmoid'))
```

In [48]:

```
model_3.compile(optimizer = 'adam',
                 loss = 'binary_crossentropy',
                 metrics = ['accuracy'])

model_3.summary()
```

Model: "sequential_2"

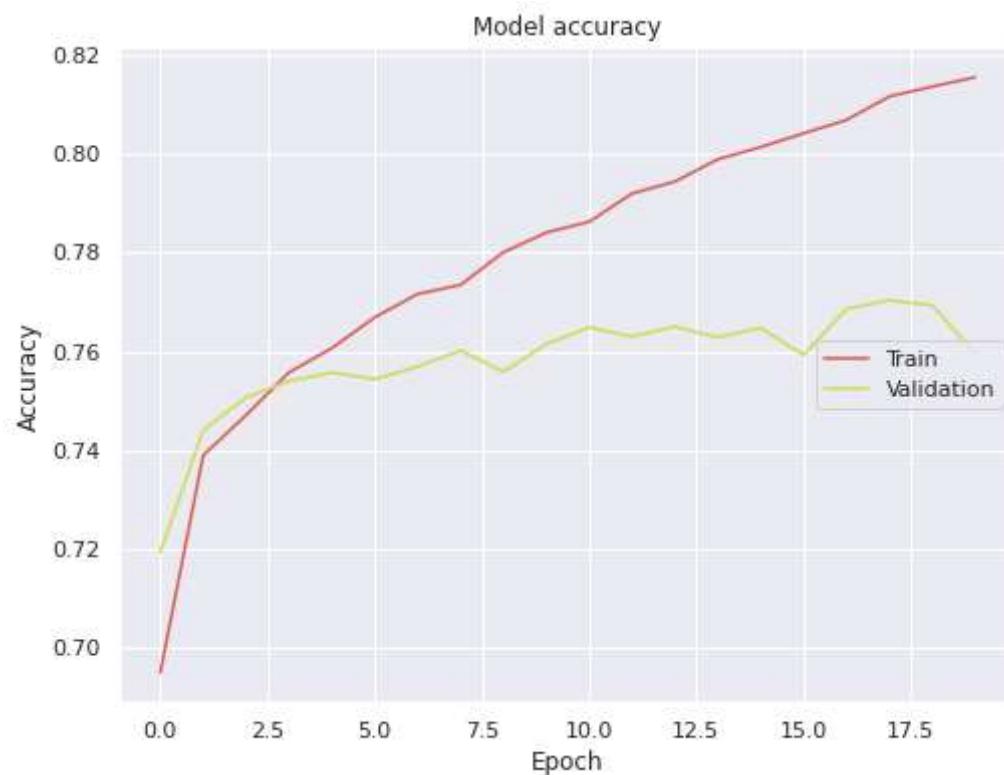
Layer (type)	Output Shape	Param #
=====		
bidirectional_2 (Bidirection (None, 40, 10)		12240
lstm_3 (LSTM)	(None, 1)	48
dense_2 (Dense)	(None, 10)	20
dense_3 (Dense)	(None, 1)	11
=====		
Total params:	12,319	
Trainable params:	12,319	
Non-trainable params:	0	

In [0]:

```
history_3 = model_3.fit(x = X_train_vectorized, y = y_train_vectorized,
                         validation_split = 0.15, epochs = 20, verbose = 0)
```

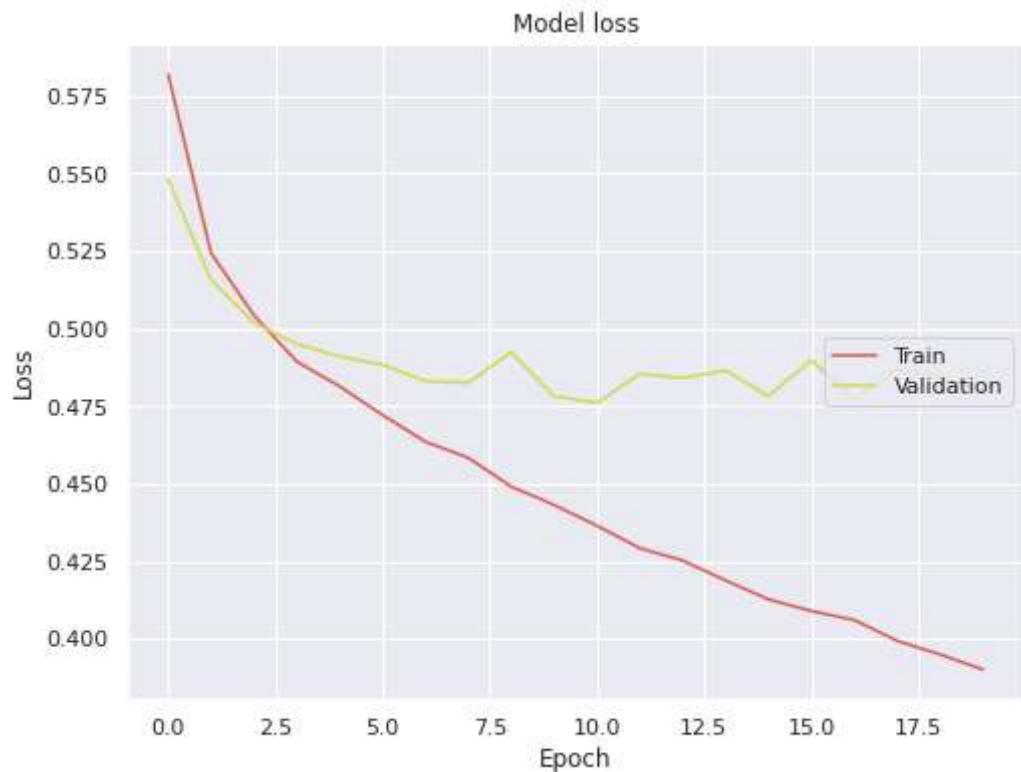
In [50]:

```
plot_accuracy(history_3)
```



In [51]:

```
plot_loss(history_3)
```



In [52]:

```
results_3 = model_3.evaluate(X_test_vectorized, y_test_vectorized)  
print('Test loss, test accuracy:', results_3)
```

Test loss, test accuracy: [0.4730978265762329, 0.7682]

Добавление ещё одного рекуррентного слоя ненамного улучшило результат — точность 76% на тестовой выборке.

Задание 5

Используйте предобученную рекуррентную нейронную сеть (например, *DeepMoji* или что-то подобное).

Какой максимальный результат удалось получить на контрольной выборке?

На своих моделях удалось достичнуть максимальной точности 76% на тестовой выборке.

Лабораторная работа №8

Рекуррентные нейронные сети для анализа временных рядов

Набор данных для прогнозирования временных рядов, который состоит из среднемесячного числа пятен на солнце, наблюдавшихся с января 1749 по август 2017.

Данные в виде csv-файла можно скачать на сайте Kaggle: <https://www.kaggle.com/robervalt/sunspots/> (<https://www.kaggle.com/robervalt/sunspots/>)

Задание 1

Загрузите данные. Изобразите ряд в виде графика. Вычислите основные характеристики временного ряда (сезонность, тренд, автокорреляцию).

In [0]:

```
import warnings  
warnings.filterwarnings('ignore')
```

In [2]:

```
from google.colab import drive  
drive.mount('/content/drive', force_remount = True)
```

Mounted at /content/drive

In [0]:

```
BASE_DIR = '/content/drive/My Drive/Colab Files/mo-2'  
  
import sys  
  
sys.path.append(BASE_DIR)  
  
import os
```

In [0]:

```
DATA_ARCHIVE_NAME = 'sunspots.zip'  
  
LOCAL_DIR_NAME = 'sunspots'
```

In [0]:

```
from zipfile import ZipFile

with ZipFile(os.path.join(BASE_DIR, DATA_ARCHIVE_NAME), 'r') as zip_:
    zip_.extractall(LOCAL_DIR_NAME)
```

In [0]:

```
DATA_FILE_PATH = 'sunspots/Sunspots.csv'
```

In [0]:

```
import pandas as pd

all_df = pd.read_csv(DATA_FILE_PATH, parse_dates = ['Date'], index_col = 'Date')
```

In [8]:

```
print(all_df.shape)
```

(3252, 2)

In [9]:

```
all_df.keys()
```

Out[9]:

```
Index(['Unnamed: 0', 'Monthly Mean Total Sunspot Number'], dtype='object')
```

In [0]:

```
from statsmodels.tsa.seasonal import seasonal_decompose

additive = seasonal_decompose(all_df['Monthly Mean Total Sunspot Number'],
                               model = 'additive', extrapolate_trend = 'freq')
```

In [0]:

```
%matplotlib inline

import matplotlib.pyplot as plt
import seaborn as sns
from matplotlib import rcParams

rcParams['figure.figsize'] = 12, 8

sns.set()
sns.set_palette(sns.color_palette('hls'))

def plot_loss(_history):

    plt.plot(_history.history['loss'])
    plt.plot(_history.history['val_loss'])

    plt.title('Model loss')

    plt.ylabel('Loss')
    plt.xlabel('Epoch')

    plt.legend(['Train', 'Validation'], loc = 'right')

    plt.show()
```

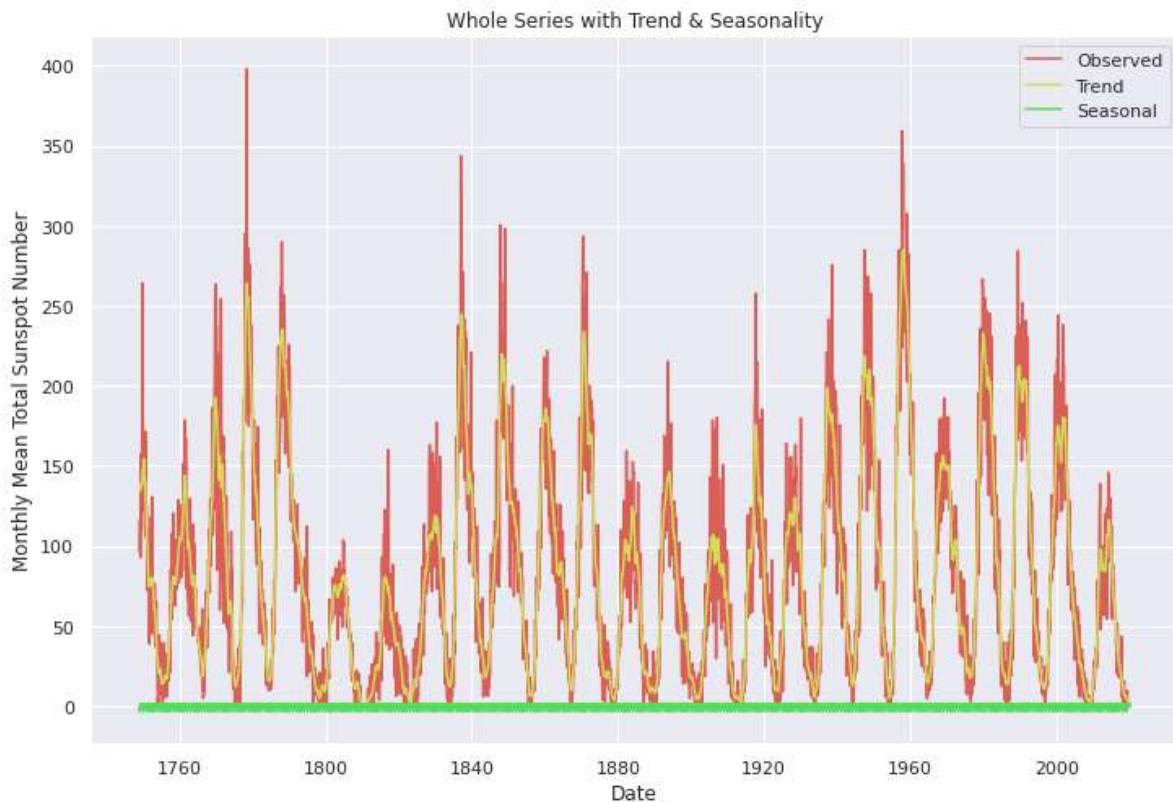
In [12]:

```
sns.lineplot(data = additive.observed, label = 'Observed')
sns.lineplot(data = additive.trend, label = 'Trend')
sns.lineplot(data = additive.seasonal, label = 'Seasonal')

plt.xlabel('Date')
plt.ylabel('Monthly Mean Total Sunspot Number')

plt.title('Whole Series with Trend & Seasonality')

plt.show()
```



Рассмотрим подробнее на небольшом промежутке:

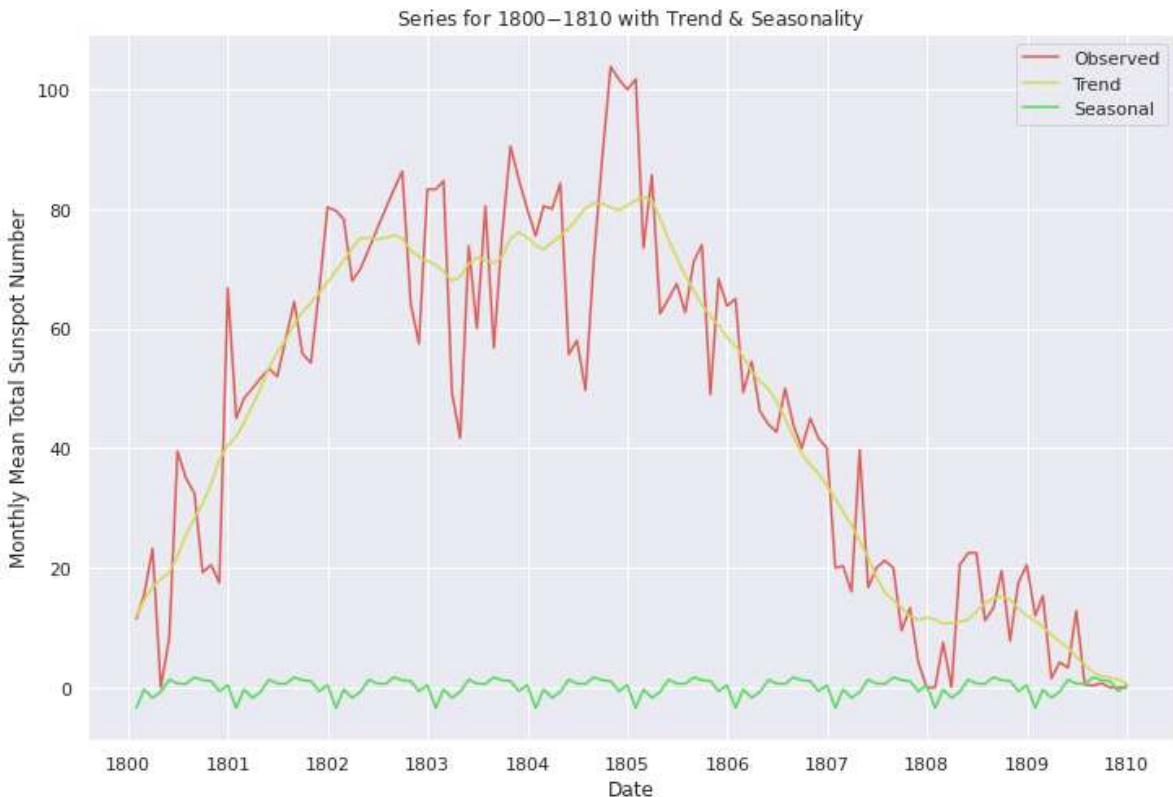
In [13]:

```
sns.lineplot(data = additive.observed['1800-01-01':'1810-01-01'], label = 'Observed')
sns.lineplot(data = additive.trend['1800-01-01':'1810-01-01'], label = 'Trend')
sns.lineplot(data = additive.seasonal['1800-01-01':'1810-01-01'], label = 'Seasonal')

plt.xlabel('Date')
plt.ylabel('Monthly Mean Total Sunspot Number')

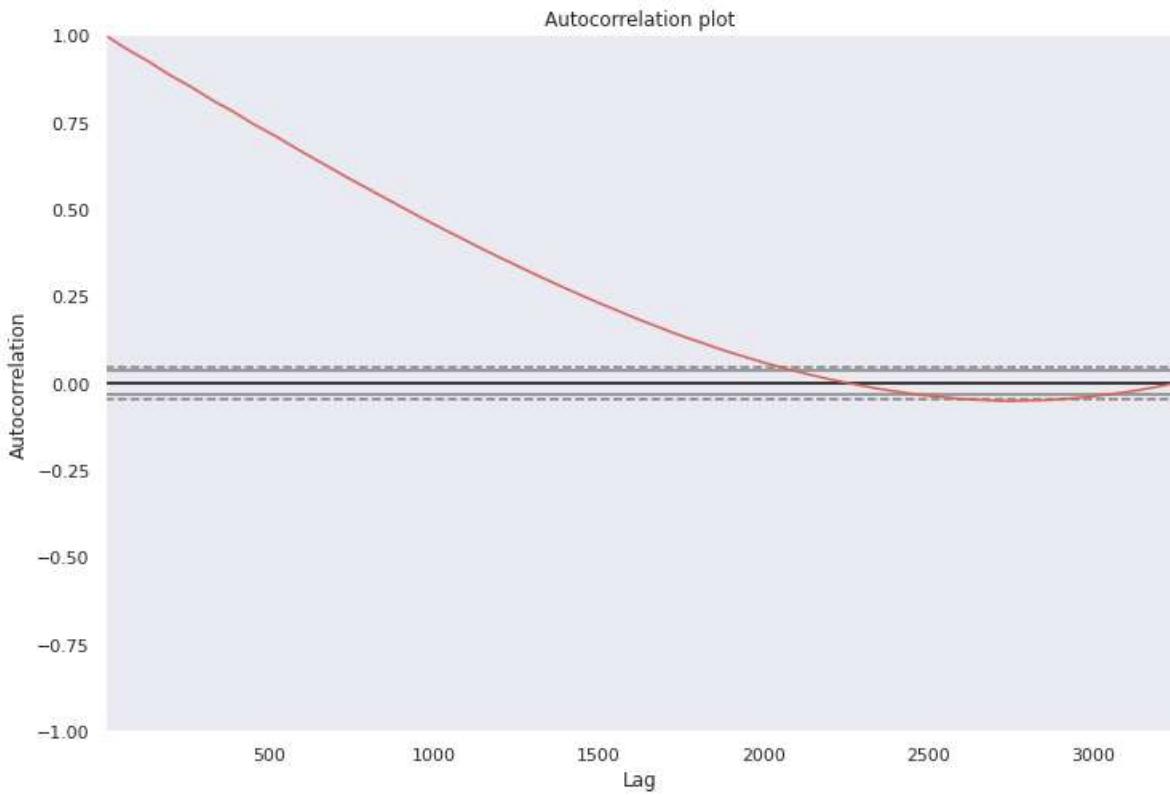
plt.title('Series for 1800$-$1810 with Trend & Seasonality')

plt.show()
```



In [14]:

```
from pandas.plotting import autocorrelation_plot  
  
autocorrelation_plot(all_df.values.tolist())  
  
plt.title('Autocorrelation plot')  
  
plt.show()
```



Задание 2

Для прогнозирования разделите временной ряд на обучающую, валидационную и контрольную выборки.

Этот шаг будет применён автоматически с помощью индексации массива данных и как параметр `validation_split` метода `model.fit()`.

Задание 3

Примените модель ARIMA для прогнозирования значений данного временного ряда.

In [0]:

```
! pip install pmdarima --quiet
```

In [16]:

```
from statsmodels.tsa.arima_model import ARIMA

model = ARIMA(all_df['Monthly Mean Total Sunspot Number'].values,
              order = (1, 0, 2))

model_fit = model.fit(disp = 0)

print(model_fit.summary())
```

ARMA Model Results

```
=====
==                                         Dep. Variable:                  y
No. Observations:                      32
52
Model:                             ARMA(1, 2)   Log Likelihood:        -15098.8
79
Method:                            css-mle    S.D. of innovations:     25.1
20
Date:      Mon, 20 Apr 2020    AIC:                   30207.7
57
Time:          04:10:50    BIC:                   30238.1
92
Sample:                           0    HQIC:                   30218.6
60

=====
```

```
==                                         coef      std err       z      P>|z|      [0.025      0.97
5]
-----
-- const      81.1334     11.977     6.774      0.000     57.660     104.6
07
ar.L1.y      0.9826     0.003     284.234      0.000      0.976      0.9
89
ma.L1.y     -0.4063     0.018    -22.947      0.000     -0.441     -0.3
72
ma.L2.y     -0.1140     0.017     -6.894      0.000     -0.146     -0.0
82
```

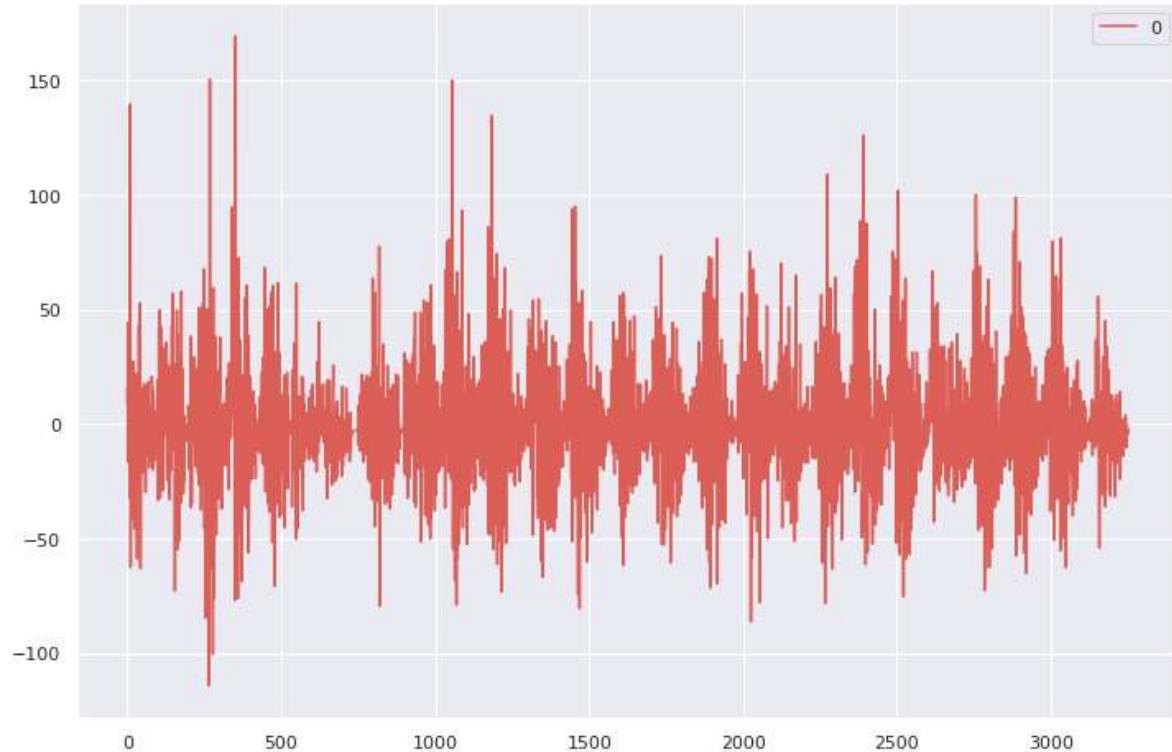
Roots

```
=====
=                                         Real      Imaginary      Modulus      Frequenc
y
-----
- AR.1      1.0177      +0.0000j      1.0177      0.000
0
MA.1       1.6743      +0.0000j      1.6743      0.000
0
MA.2      -5.2373      +0.0000j      5.2373      0.500
0
```



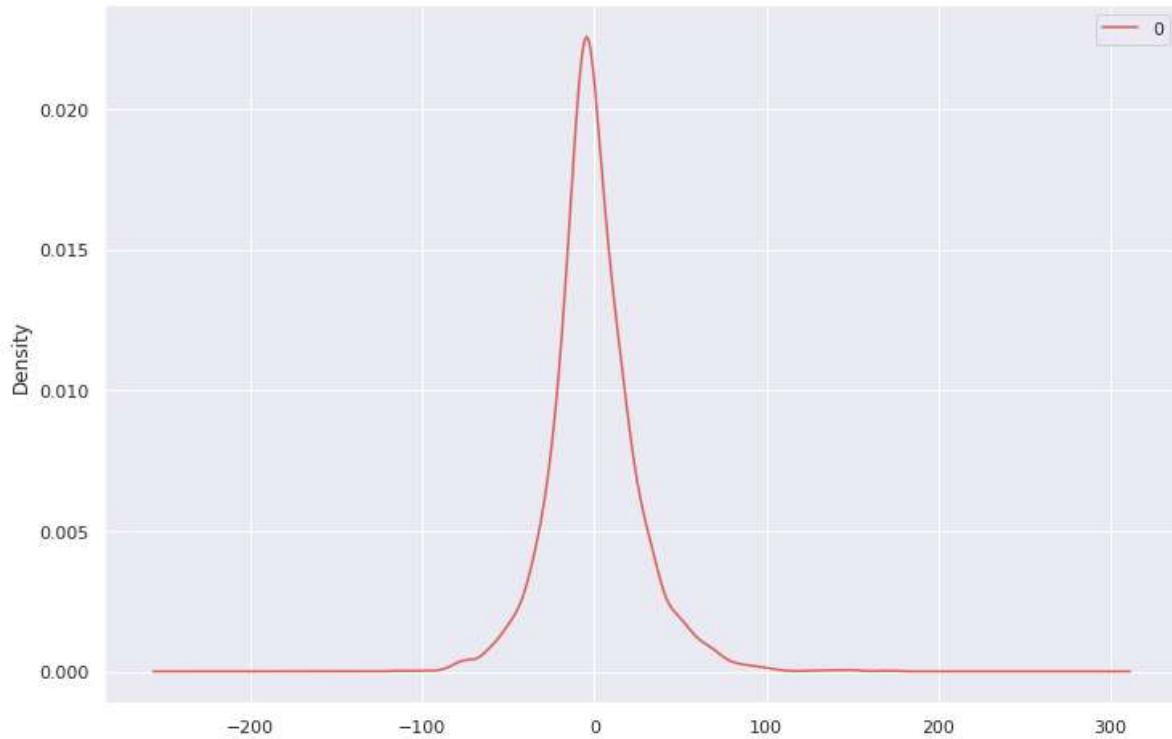
In [17]:

```
residuals = pd.DataFrame(model_fit.resid)  
residuals.plot()  
plt.show()
```



In [18]:

```
residuals.plot(kind = 'kde')  
plt.show()
```



Задание 4

Повторите эксперимент по прогнозированию, реализовав рекуррентную нейронную сеть (с как минимум 2 рекуррентными слоями).

Сначала нужно создать датасет из данных.

In [0]:

```
TEST_PERIOD = 600
```

In [0]:

```
OBSERVATIONS_PER_CYCLE = 11 * 12
```

In [0]:

```
TIME_STEPS = OBSERVATIONS_PER_CYCLE
```

In [0]:

```
! pip install tensorflow-gpu --pre --quiet
```

In [0]:

```
import tensorflow as tf

tf.compat.v1.logging.set_verbosity(tf.compat.v1.logging.ERROR)

from tensorflow import keras
```

In [0]:

```
import numpy as np
from datetime import timezone

def timeseries_to_dataset(_X_ts, _time_steps):

    samples_n_ = len(_X_ts) - _time_steps

    _X_norm = tf.keras.utils.normalize(_X_ts).squeeze()

    print(_X_ts.shape, _X_norm.shape)

    X_ = np.zeros((samples_n_, _time_steps))
    y_ = np.zeros((samples_n_,))

    for i in range(samples_n_):

        X_[i] = _X_norm[i:(i + _time_steps)]
        y_[i] = _X_norm[(i + _time_steps)]

    return X_[..., np.newaxis], y_
```

In [25]:

```
X_as_ds, y_as_ds = timeseries_to_dataset(
    all_df['Monthly Mean Total Sunspot Number'].values,
    TIME_STEPS)

X, y = X_as_ds[:TEST_PERIOD], y_as_ds[:TEST_PERIOD]

X_test, y_test = X_as_ds[-TEST_PERIOD:], y_as_ds[-TEST_PERIOD:]

(3252,), (3252,)
```

In [26]:

```
print(X.shape, X_test.shape, y.shape, y_test.shape)
```

```
(2520, 132, 1) (600, 132, 1) (2520,) (600,)
```

In [0]:

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import LSTM, Dense

model = tf.keras.Sequential()

model.add(LSTM(2, activation = 'relu', return_sequences = True,
              input_shape = X.shape[-2:]))
model.add(LSTM(12, activation = 'relu'))
model.add(Dense(1))
```

In [28]:

```
model.compile(optimizer = 'adam',
              loss = 'mse')

model.summary()
```

Model: "sequential"

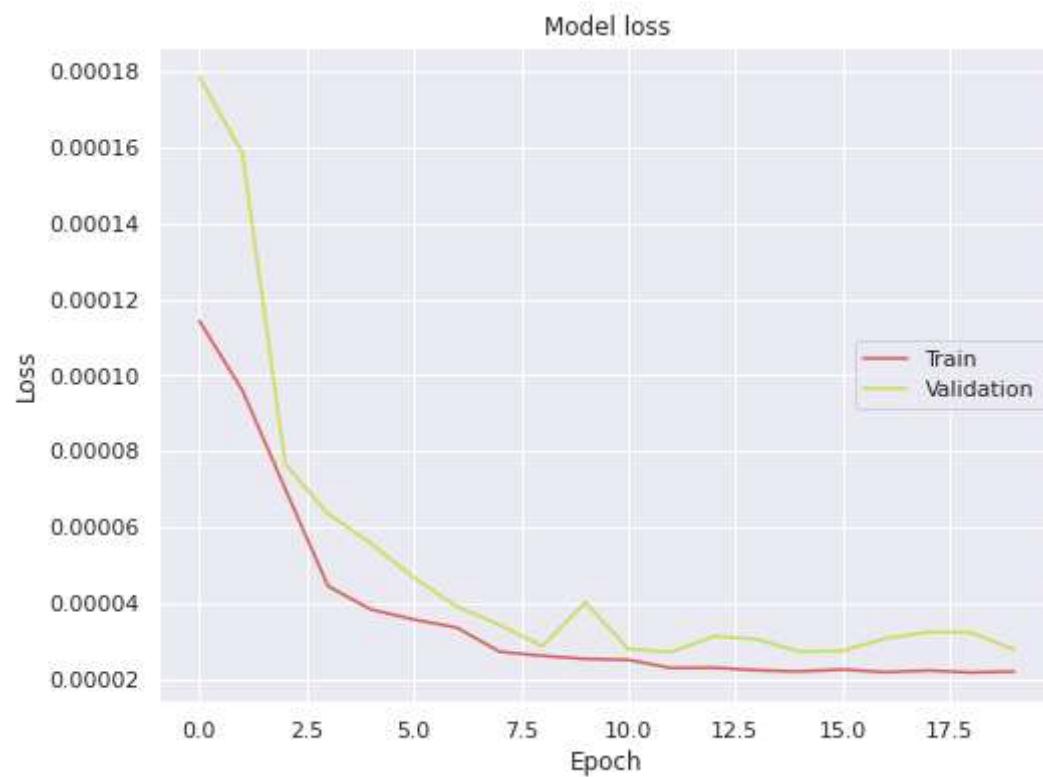
Layer (type)	Output Shape	Param #
lstm (LSTM)	(None, 132, 2)	32
lstm_1 (LSTM)	(None, 12)	720
dense (Dense)	(None, 1)	13
Total params:	765	
Trainable params:	765	
Non-trainable params:	0	

In [0]:

```
history = model.fit(x = X, y = y, epochs = 20, validation_split = 0.15,
                     verbose = 0)
```

In [30]:

```
rcParams['figure.figsize'] = 8, 6  
plot_loss(history)
```



In [31]:

```
results = model.evaluate(X_test, y_test)  
print('Test mse:', results)
```

```
19/19 [=====] - 0s 26ms/step - loss: 1.9438e-05  
Test mse: 1.9438315575825982e-05
```

In [32]:

```
y_pred = model.predict(X_test[20][np.newaxis, ...])
```

```
print(y_pred, y_test[20])
```

```
[[0.01421428]] 0.011741172416758197
```

Задание 5

Сравните качество прогноза моделей.

Какой максимальный результат удалось получить на контрольной выборке?